
Oliver Hauke

ist Mathematiker und IT-Referent im Kompetenzzentrum „Analyse und Auswertung“ des Statistischen Bundesamtes. Er verantwortet die Weiterentwicklung der technischen Infrastruktur des Forschungsdatenzentrums und berät das Netzwerk empirische Steuerforschung in der effizienten Nutzung der Systeme.

Annette Kristiansen

ist Ökonomin und Referentin im Referat „Unternehmenssteuern“ des Statistischen Bundesamtes. Sie beschäftigt sich mit der Zusammenführung der Unternehmenssteuerstatistiken und betreut das Netzwerk empirische Steuerforschung. Für ihre externe Promotion an der Universität Bremen untersucht sie die technologische Vielfalt multinationaler Unternehmen.

EFFIZIENTE AUSWERTUNG DES BUSINESS-TAX-PANELS MITHILFE VON R

Oliver Hauke, Annette Kristiansen

🔑 **Schlüsselwörter:** Effiziente Analysen, R-Programmierung, Forschungsdaten, Unternehmenssteuerstatistik, Business-Tax-Panel, Netzwerk empirische Steuerforschung

ZUSAMMENFASSUNG

Das Forschungsdatenzentrum des Statistischen Bundesamtes baut seine technische Infrastruktur gezielt aus, um der Wissenschaft erweiterte Analysemöglichkeiten amtlicher Daten bereitzustellen. Seit November 2025 steht Forschenden exklusiver Zugang zu diesen erweiterten Systemressourcen in R und Stata zur Verfügung. R-basierte Tools – insbesondere Apache Arrow, Parquet und DuckDB – ermöglichen es, gängige Analysen großer Forschungsdatensätze in Echtzeit auszuführen. Am Beispiel des Business-Tax-Panel (2013 bis 2019) werden die erzielbaren Effizienzgewinne bei der Auswertung umfangreicher steuerstatistischer Daten im Rahmen des Netzwerks empirische Steuerforschung demonstriert.

🔑 **Keywords:** Efficient analysis – R programming – research data – corporate tax statistics – Business Tax Panel – empirical tax research network

ABSTRACT

The Research Data Centre at the Federal Statistical Office is strategically expanding its technical infrastructure to provide researchers with enhanced analytical capabilities for official data. Since November 2025, researchers have had exclusive access to these extended system resources in R and Stata. R-based tools – particularly Apache Arrow, Parquet, and DuckDB – enable real-time analysis of large research datasets. Using the Business Tax Panel (2013–2019), this paper demonstrates the achievable efficiency gains in analysing large-scale tax statistics within the empirical tax research network.

Inhaltsverzeichnis

1	Einleitung	4
1.1	Handlungsbedarf	4
1.1.1	Steigende Datenmenge in der amtlichen Statistik	4
1.1.2	Steigende Anforderungen der Wissenschaft und Öffentlichkeit	4
1.2	Vorschreitende Innovation der Datenverarbeitungstechnologien	5
1.2.1	Ausgangslage	5
1.2.2	Vormarsch von Open Source	5
1.2.3	Fokus auf R	5
1.2.4	Hoch-performante Datenverarbeitungsmethoden	6
1.3	Umsetzung im StBA und FDZ	6
1.4	Diese Arbeit	6

Dokument-Metadaten

Titel: EFFIZIENTE AUSWERTUNG DES BUSINESS-TAX-PANELS MITHILFE VON R
Autoren: Oliver Hauke, Annette Kristiansen
Veröffentlichung: WISTA 01/2026
Erstellungsdatum: 5. Dezember 2025 um 18:04 Uhr

Dokumentstatistik

Abschnitt	Wörter	Zeichen	Tab.	Abb.	Fußn.	Quellen	Vorgabe
Insgesamt	1 235	11 260	0	0	0	1	30 000 Z.
Zusammenfassung	81	707	—	—	—	—	800 Z.
Abstract	85	623	—	—	—	—	700 Z.
Einleitung (inkl. Unterabschnitte)	1 231	11 260	0	0	0	1	—

Schlüsselwörter & Keywords

Typ	Anzahl
Schlüsselwörter	6
Keywords	6

1

Einleitung

Spannungsfeld, Weiterentwicklung zur Lösung und Technologie-Empfehlung

Einbauen: Forschungsdatenzentrum des Statistischen Bundesamts, hier kurz FDZ Netzwerk empirischer Steuerforschung, hier kurz NeSt.

1.1 Handlungsbedarf

1.1.1 Steigende Datenmenge in der amtlichen Statistik

- › Qualitätsbericht. Wachsende Datenmenge in der amtlichen Statistik, Verweis auf (Statistisches Bundesamt 2023)
- › Datenverarbeitung im StBA ...
- › neues NeSt Produkt BTP zeigt Umfang, hoch interessant für Wissenschaft
- › Datenverarbeitungsaufgaben des StBA erklären
- › Nicht mehr durch vorhandene Systemkapazitäten (insb. Arbeitsspeicher) gedeckt
- › Herausforderungen (größere Datenmengen, komplexere Analysen, schnellere Antworten notwendig)
 - › hohe Anforderungen der Öffentlichkeit und besonders Wissenschaft. Verweis auf Gutachten des Stat. Beirats und Gründung “Netzwerk emp. Steuerforschung”
 - › Schnelle Bereitstellung von am besten vollständigen, wenig Anonymisierten Datensätzen an Wissenschaft via FDZ. Erste Analysen seitens StBA und hohe Expertise erwartet (Exploration der Daten nötig)
 - › Bereitstellung von Zusatzdokumentation durch StBA. Metadatenreport
 - › schnelle Bereitstellung,
 - › zeitnahe Nutzung in FDZ
 - › keine Wartezeiten in FDZ
 - › sofortig Antworten auf Analysefragen
 - › Erhöhte Komplexität Analysen mit größeren, Komplexeren Datensätzen
- › Rückstände/Altlasten: weiterentwickelnde Infrastruktur, nicht state of the art (ausgelegt auf Konsistenz und Zuverlässigkeit, nicht Schnelligkeit), gesetzlicher Auftrag
 - › hauptsächlich SAS für große Datenmenge verwendet, funktioniert, aber langsam
 - › FDZ Bund integriert in Standardarbeitsplätze

des StBA

- › Bereitstellungsaufwände und Abhängigkeiten moderner Software

Annette: -> Impuls aus der Wissenschaft, dann Fachbereich - Fachbereich/Verbund im Grunde Hauptnutzende da Tools und Daten zur Verfügung stehen Technische Möglichkeit entwickelt sich weiter usw..

Der Sachverständigenrat zur Begutachtung der gesamtwirtschaftlichen Entwicklung (2023) hat in seinem Gutachten 2023/24 auf eine technisch veraltete Infrastruktur und auf die fehlende Nutzerfreundlichkeit hingewiesen. Seitdem hat sich die Infrastruktur in dem Forschungsdatenzentrum des Bundes verbessert. Seit Januar 2025 besteht ein Remote Access System als neuer Zugangsweg für die Wissenschaft. Im Bereich der Steuerstatistiken wird derzeit geprüft, inwiefern auch Einzeldaten aus diesem Bereich über Remote Access genutzt werden können. Als Übergang und Erleichterung für bestehende Forschungsprojekte wird in diesem Kapitel 2

Die amtliche Statistik steht vor der Herausforderung, bei stetig wachsenden Datenmengen und sich ändernden Nutzeranforderungen qualitativ hochwertige und zeitnahe statistische Informationen bereitzustellen (Statistisches Bundesamt 2023). Dabei spielt die Effizienz der verwendeten statistischen Verfahren eine zentrale Rolle für die Leistungsfähigkeit des gesamten statistischen Systems.

In den vergangenen Jahren haben sich die Rahmenbedingungen für die Produktion amtlicher Statistiken erheblich verändert. Die Digitalisierung hat nicht nur zu einer Vervielfachung der verfügbaren Datenquellen geführt, sondern auch neue Möglichkeiten für die statistische Analyse eröffnet. Gleichzeitig sind die Erwartungen der Nutzer an Aktualität und Detailliertheit der Statistiken gestiegen.

Diese Entwicklungen erfordern eine kontinuierliche Evaluation und Optimierung der eingesetzten Verfahren. Ziel der vorliegenden Studie ist es daher, die Effizienz verschiedener statistischer Verfahren systematisch zu bewerten und Handlungsempfehlungen für die Praxis abzuleiten.

1.1.2 Steigende Anforderungen der Wissenschaft und Öffentlichkeit

FDZ, NeSt

- › Schnelle Reaktionen erforderlich
- › Komplexere (Forschungsfragen) zu beantworten
- › FDZ erklären
- › Gutachten BMF ansprechen
- › NeSt erklären, Bedarfe durch Produkt BTP beantworten.. aber wie kann es in angeme

1.2 Vorschreitende Innovation der Datenverarbeitungstechnologien

1.2.1 Ausgangslage

SAS für amtl. Statistik und SAS/Stata für FDZ

- › SAS, zsl. Stata in den FDZ. Session zu SAS Ablösung
- › Weiterentwicklung der Infrastruktur: neue Server für R im StBA und für FDZ eigene neue Server für R und Stata
- › hohe Lizenzkosten, Trend zu Abonnements und Cloud nachteilig, technologiLOCK und Privacy.
- › Kommen bei unseren Anwendungen Kapazität an ihre Grenzen und Performanz in anderen Technologien höher.

Anforderungen an Modernisierung

- › hohe Performanz, schnelle Ergebnisse, idealenfalls in Echtzeit (d.h. wenigen Sekunden)
- › moderne Interfaces, möglichst leichte Nutzung, wenig Schulungsbedarf, Allgemeinwissen von Statistiker u.Ä. Fachrichtungen (Werkzeug, nicht Gegenstand der Untersuchung)
- › leicht einrichtbar, wenig Abhängigkeiten zu vielen Tools, die sich ständig weiterentwickeln, sodass hohe Wartungsaufwände entstehen.

1.2.2 Vormarsch von Open Source

- › in der internationalen amtlichen Statistik seit Jahren auf dem Vormarsch. Langsam steigt auch Verbreitung von R steigt auch in den dt. Statistikämtern.

1.2.3 Fokus auf R

R verbreitung steigt, bei uns in Kinderschuhen. Wie fängt man denn am besten an? Was ist von anfang an der richtige Weg Daten in R zu verarbeiten?

R ist weltweit bekannt und verbreitet als die Lingua Franca für Statistik, Methodologie und Data Science. Dies macht R zu der natürlichen Wahl für die amtlichen Statistik mit viele attraktive Vorteile.

- › aktive globale Community sorgt für schnelle Innovation und Verbesserung
- › CRAN bietet offiziell aktuell Zusatzfunktionalitäten in Form von X R-Paketen. Darunter sind viele klassische Pakete für Datenverarbeitung und -analyse.
- › R
 - › The reasons why the official statistics community is rapidly embracing R are clear. S. Erfolg / Wachs-

tum der Conference uRos <https://r-project.ro/conference2025.html#Presentations>

- › R lingua franca for statisticians, methodologists and data scientists worldwide -> nativ geeignet für amtl. Statistik
- › R Open Source bietet Vorteile
 - › aktive globale Community
 - › support from the industry
 - › it combines a vast amount of functionalities for data preparation, methodology, visualisation and application building
 - › free = ideal environment for sharing, collaboration and industrialising official statistics
 - › Packages CRAN, github...

Arrow bspw. hatte in 2024 und 2025 jeweils 4 Major Releases mit diversen neuen Funktionalitäten und Performanz-Verbesserung

Neue Entwicklung zu R in der dt. OSS, bei Integration in Statistikproduktion und Datenbereitstellung direkt mit den richtigen Features und Methoden beginnen. Wie die folgenden...

Open Source -> breite Auswahl an Paketen zum Einlesen, Transformieren und Auswerten von Daten.

- › Unterscheidung klassischer/r-nativer Methoden (base-r, readr / vroom und data.table), effiziente/moderne Methoden (arrow, duckdb, polars)
- › Klassische Methoden
 - › base-r zu vermeiden
 - › readr
 - › in tidyverse
 - › nutzerfreundlich, einfach zu lernen / nutzen
 - › data.table
 - › benchmarking: <https://cran.r-project.org/web/packages/data.table/vignettes/datatable-benchmarking.html>
 - › datenformate in R: qs, rds
 - › dtplyr?

As we start working with larger and larger datasets, the basic tools of the tidyverse start to look a little slow. In the last few years several packages more suited to large datasets have emerged. Some of these are column, rather than row, oriented. Some use parallel processing. Some are vector optimized. Speedy databases that have made their way into the R ecosystem are data.table, arrow, polars and duckdb. All of these are available for Python as well. Each of these carries with it its own interface and learning curve. duckdb, for example is a dialect of SQL, an entirely different language so our dplyr code above has to look like this in SQL: S. <https://www.r->

bloggers.com/2024/04/the-truth-about-tidy-wrappers-3/ Technische Lösungsansätze.

1.2.4 Hoch-performante Datenverarbeitungsmethoden

Als Desktopanwendung konzipiert ist R nicht für hoch-performante Auswertungen von Big Data bekannt. Wie unsere Untersuchung zeigen wird, beansprucht R nativ übermäßige Systemressourcen, um die Nutzerfreundlichkeit zu erhöhen. Dadurch dass R Open Source ist ändern dies jedoch diverse Entwicklerteams weltweit und stellen R Zusatzfunktionen in Form von R-Paketen zur Verfügung die in R hoch-performante Auswertung großer Datenmengen ermöglichen.

- › R darüber hinaus vermehrt hoch-performante Analysetools, die sich ständig verbessern
- › ermöglichen sehr schnelle Verarbeitung von Daten, mit einem sehr hohen Gesamtvolumen, das sogar den verfügbaren RAM übersteigt.
- › sollte möglichst leicht nutzbar sein, nativ in R ohne viele Abhängigkeiten (organisatorische Einschränkungen)

1.3 Umsetzung im StBA und FDZ

-
- › möglichst leicht nutzbar und gewohnt/verbreitet -> R+dpplr
 - › wechselnde Nutzende (Forscher) unterschiedlicher Fachbereiche mit unterschiedlichen Analytischen und technischen Kenntnissen
 - › stabil
 - › schnell, optimale Nutzung vorhandener GWAP Zeit und KDFV Zeitraum
 - › ressourcensparend (RAM Problematik)
 - › möglichst leicht nutzbar mit den vorhandenen Systemen und organisatorischen Strukturen ergibt Anforderungen
 - › hohe-performanz bereits mit R Grundlagenwissen
 - › minimale Anforderungen an zsl. Software
 - › NeSt Förderung, Datenprodukterstellung, Bereitstellung der FDZ auch technischen Infrastruktur und Knowhow der effizienten Nutzung
 - › Bereitstellung des OSS seit Nov. 2025
 - › Vorbereitend Exploration und Beratung in geeigneten Äußerst effizienten Methoden -> Ergebnisse in Echtzeit
 - › Szenario FDZ GWAP Besuch, statt KDFV, sofort Ergebnisse
 - › Diese Arbeit

- › Modernisierung der aml. Stat, FDZs -> Zugangswege, Kapazitäten, ...
- › Technische Weiterentwicklung, stärkere Hardware, leichtere Bereitstellung, virtualisierung
- › Schnelle Weiterentwicklung von Open-Source Software, R, div. Packages, e.g. Verweis auf Changelog von Arrow, Polars

1.4 Diese Arbeit

Ausbreitung von R - gleich die richtige Technologie auswählen und einsetzen. Aber welche ist die "richtige"? Was für Unterschiede (Vorteile / Nachteile) haben die Technologien. Dies will dieser Artikel im Falle des BTP untersuchen. Kontrollierte Benchmark und weitere (qualitative) Aspekte, wie Userexperience.

Zielgruppe: alle Datenanalytiker mit rudimentären R-Kenntnisse, aber breit, FDZ, aml. Stat,

Wir fokussieren uns auf folgende zentrale Forschungsfragen:

1. Methodische Effizienz: Wie unterscheiden sich verschiedene statistische Verfahren hinsichtlich ihrer Rechenzeit und Speicheranforderungen bei gleichbleibender Ergebnisqualität?
2. Skalierbarkeit: Welche Verfahren zeigen die beste Performance bei wachsenden Datenmengen, und wo liegen die kritischen Grenzen?
3. Praktische Anwendbarkeit: Welche Infrastrukturanforderungen stellen moderne Auswertungsmethoden an Forschungsdatenzentren?

Literatur

Statistisches Bundesamt (2023). Qualitätshandbuch der amtlichen Statistik. Version 7.0. Wiesbaden. URL: <https://www.destatis.de>.