
Oliver Hauke

ist Mathematiker und IT-Referent im Kompetenzzentrum „Analyse und Auswertung“ des Statistischen Bundesamtes. Er verantwortet die Weiterentwicklung der technischen Infrastruktur des Forschungsdatenzentrums des Statistischen Bundesamts und berät das Netzwerk empirische Steuerforschung in effizienter Datenanalyse.

Annette Kristiansen

ist Ökonomin und Referentin im Referat „Unternehmenssteuern“ des Statistischen Bundesamtes. Sie beschäftigt sich mit der Zusammenführung der Unternehmenssteuerstatistiken und betreut Arbeiten für das Netzwerk empirische Steuerforschung.

EFFIZIENTE AUSWERTUNG DES BUSINESS-TAX-PANELS MITHILFE VON R

Oliver Hauke, Annette Kristiansen

🔑 **Schlüsselwörter:** Effiziente Analysen, R-Programmierung, Forschungsdaten, Unternehmenssteuerstatistik, Business-Tax-Panel, Netzwerk empirische Steuerforschung

ZUSAMMENFASSUNG

Das Forschungsdatenzentrum des Statistischen Bundesamtes baut seine technische Infrastruktur gezielt aus, um der Wissenschaft erweiterte Analysemöglichkeiten amtlicher Daten bereitzustellen. Seit November 2025 steht Forschenden exklusiver Zugang zu diesen erweiterten Systemressourcen in R und Stata zur Verfügung. R-basierte Tools – insbesondere Apache Arrow, Parquet und DuckDB – ermöglichen es, gängige Analysen großer Forschungsdatensätze in Echtzeit auszuführen. Am Beispiel des Business-Tax-Panel (2013 bis 2019) werden die erzielbaren Effizienzgewinne bei der Auswertung umfangreicher steuerstatistischer Daten im Rahmen des Netzwerks empirische Steuerforschung demonstriert.

🔑 **Keywords:** Efficient analysis – R programming – research data – corporate tax statistics – Business Tax Panel – empirical tax research network

ABSTRACT

The Research Data Centre at the Federal Statistical Office is strategically expanding its technical infrastructure to provide researchers with enhanced analytical capabilities for official data. Since November 2025, researchers have had exclusive access to these extended system resources in R and Stata. R-based tools – particularly Apache Arrow, Parquet, and DuckDB – enable real-time analysis of large research datasets. Using the Business Tax Panel (2013–2019), this paper demonstrates the achievable efficiency gains in analysing large-scale tax statistics within the empirical tax research network.

Inhaltsverzeichnis

1	Einleitung	5
1.1	Voranschreitende Innovation	5
2	Anwendungsfall Business-Tax-Panel	6
2.1	Datengrundlage	6
2.2	Auswertungsbedarfe	6
2.2.1	Deskriptive Eckdaten	7
2.2.2	Regressionen	7
2.3	Technische Spezifikationen	7
3	Ausbau der Analyseinfrastruktur	7
3.1	Ausgangslage	7
3.2	R-Server des Statistischen Bundesamts	8
3.3	OnSite-Server des FDZ	8
4	Datenverarbeitungsmethoden	8
4.1	Anforderungen	9
4.2	Klassische Methoden in R	9
4.3	Hoch-performante Methoden in R	10
4.4	Gültigkeit von externen Benchmarks	10
5	Performanzvergleich	11
5.1	Versuchsaufbau	11
5.2	Vergleichswert in SAS und Stata	11
5.3	Kleiner Vergleich zwischen R, SAS und Stata	11
5.4	Größere Datenmengen in R	15
6	Ergebnis für das vollständige BTP	15
6.1	Ergebnis	15
6.2	Vergleich zu SAS, (Stata), Datatable	16
7	Fazit	16
7.1	Kernaussage des Artikels	16
7.2	Auswirkung auf IT-Infrastruktur und Beratung	16
7.3	Auswirkungen auf die Statistikproduktion	16
7.4	Auswirkungen auf die FDZ	17
7.5	Auswirkung auf die Wissenschaft	17
7.6	Schlussbemerkung	17
	Anhang	17
	Weitere Performancemessungen für kleinere Datenmengen.	17

Dokument-Metadaten

Titel: EFFIZIENTE AUSWERTUNG DES BUSINESS-TAX-PANELS MITHILFE VON R
Autoren: Oliver Hauke, Annette Kristiansen
Veröffentlichung: WISTA 01/2026
Erstellungsdatum: 7. Dezember 2025 um 14:15 Uhr

Dokumentstatistik

Abschnitt	Wörter	Zeichen	Fußn.	Quellen	Vorgabe	Status
Insgesamt	4 684	38 672	14	23	30 000 Z.	✗
Zusammenfassung	81	707	—	—	800 Z.	
Abstract	85	623	—	—	700 Z.	
Autor 1 (O. Hauke)	—	327	—	—	350 Z.	
Autor 2 (A. Kristiansen)	—	256	—	—	350 Z.	
Einleitung	1 231	12 524	5	7	—	
Anwendungsfall Business-Tax-Panel	125	1 271	0	1	—	
Technische Infrastruktur	145	1 475	1	1	—	
Datenverarbeitungsmethoden	810	8 241	3	5	—	
Performanzvergleich	999	10 163	4	6	—	
Ergebnis für das vollständige BTP	84	854	0	1	—	
Fazit	407	4 140	1	2	—	

Schlüsselwörter (≤ 5) ✗

- ✚ Effiziente Analysen
- ✚ R-Programmierung
- ✚ Forschungsdaten
- ✚ Unternehmenssteuerstatistik
- ✚ Business-Tax-Panel
- ✚ Netzwerk empirische Steuerforschung

Keywords (≤ 5) ✗

- ✚ Efficient analysis
- ✚ R programming
- ✚ research data
- ✚ corporate tax statistics

- ✚ Business Tax Panel
- ✚ empirical tax research network

Tabellen (10)

Nr.	Beschreibung
Tabelle 1	StBA R-Server Ausbau (Anfang 2025)
Tabelle 2	FDZ OnSite-Server Spezifikationen
Tabelle 3	Versionen verfügbarer R-Packages
Tabelle 4	Baselines in SAS und Stata (anhand 1% des simuliertes BTP)
Tabelle 5	Performanz Messungen für die Fallzahlberechnung anhand 1% des BTP
Tabelle 6	Performanz Messungen für die Regressionsberechnung anhand 1% des BTP
Tabelle 7	Performanz Messungen für die Fallzahlberechnung anhand 10% des BTP
Tabelle 8	Performanz Messungen für die Regressionsberechnung anhand 10% des BTP
Tabelle 9	Benchmarkergebnisse für Fallzahlen (kleine Stichproben des BTP)
Tabelle 10	Benchmarkergebnisse für Regression (kleine Stichproben des BTP)

Abbildungen (0)

Nr.	Beschreibung
Abbildung 1	Strategien zur Performanz-Optimierung im FDZ-Bund

1

Einleitung

1. Steigende Datenmengen, höhere Bedarfe der Öffentlichkeit an Aktualität und Detailliertheit -> Modernisierung der Datenverarbeitungsinfrastruktur nötig um mithalten zu können
2. Zugespitzt in FDZ. Forschende fordern mehr umfangreiche Daten (BMF Gutachten) und die technischen Möglichkeiten sie auszuwerten (SVR Gutachten).
3. Gründung NeSt, neue umfangreiche Datenquelle für emp. Steuerforschung BTP mit hohem Analysepotenzial (S. [?@sec-btp](#))
4. Große Schritte in 2025, Erweiterung der R-Server. NeSt auch Modernisierung der FDZ Infrastruktur geführt. Technisches Fundament (S. Kapitel 3)
5. Vorteile von R Open Source, Vielfalt R-Packages, aktive weltweite Community, wachsende Verbreitung in OS, natürliche Wahl R. bieten Effizienz, hohe Nutzerfreundlichkeit (s. Kapitel 4). Frage nach besten Möglichkeiten, die Anforderungen XYZ bedient (s. Kapitel 5)
 1. Wachsende Community auch in Official Statistics, s. uRos
6. zeigen, dass die Methoden sogar das ganze BTP sehr effizient auswerten können, in Sek, obwohl es den verfügbaren Arbeitsspeicher übersteigt (s. Kapitel 6). Ableitung praktischer Implikationen.

Insbesondere die Wissenschaft erwartet, dass die Forschungsdatenzentrum des statistischen Bundesamts (hier kurz FDZ) und dem Forschungsdatenzentrum der Statistischen Ämter der Länder zeitnah auch umfangreiche Datensätze für ausgiebigere wissenschaftliche Auswertungen zur Verfügung stellt. In dem FDZ haben Forschende die Möglichkeit, eigene Analysen mit amtlicher Mikrodaten durchführen. Der Zugangsweg "Onsite-Nutzung" ermöglicht den Zugriff zu formal anonymisierten Einzeldaten ermöglichen. Forschende können selbst ein Gastwissenschaftsarbeitsplatz (GWAP) in den Liegenschaften des FDZ nutzen oder via kontrollierter Datenfernverarbeitung (KDFV) können entwickelte Auswertungsprogramme durch das FDZ ausgeführt werden. Jedoch hatte die Wissenschaft in Wissenschaftlicher Beirat beim Bundesministerium der Finanzen (2020) Kritik am Datenbestand für empirische Steuerforschung und dessen Aktualität geäußert. In Sachverständigenrat zur Begutachtung der gesamtwirtschaftlichen Entwicklung (2023) wurde

darüber hinaus die technisch veraltete Infrastruktur des FDZ bemängelt.

Um diese Situation zu verbessern, hat das Bundesfinanzministerium im Jahre 2022 das "Netzwerk empirischer Steuerforschung" (NeSt) gegründet.^[1] Vorangetrieben durch das NeSt konnte das Statistische Bundesamt bereits erfolgreich den Datenbestand erweitern. Insbesondere steht seit 2023 das Business-Tax-Panel (BTP) zur Verfügung und wird bereits erneuert (in [?@sec-btp](#) beschrieben). Es vernetzt verschiedene Unternehmensstatistiken und birgt mit fast 3 000 Merkmalen einerseits ein großes Analysepotenzial, andererseits hohe technische Anforderungen an die Analysewerkzeuge.^[2]

1.1 Voranschreitende Innovation

Anforderungen: Performanz auf neuem Stand der Technik, schnelle Ergebnisse, idealerweise in Echtzeit (d.h. wenigen Sekunden). Leichte Nutzung / geringe Entwickleraufwände (im FDZ für viele Fachrichtungen zugänglich), moderne Interfaces, möglichst leichte Nutzung, wenig Schulungsbedarf, leicht einrichtbar, wenig Abhängigkeiten zu vielen Tools, die sich ständig weiterentwickeln, sodass hohe Wartungsaufwände entstehen, stabil, optimale Nutzung vorhandener GWAP Zeit und KDFV Zeitraum, ressourcensparend (RAM Problematik)

Um diesen Herausforderungen zu bewältigen, hat das Statistische Bundesamt in 2025 wesentliche Meilensteine in der Modernisierung der technischen Analyseinfrastruktur erreicht (dargestellt in Kapitel 3). Anfang 2025 wurden die R-Server für Auswertungen und Datenverarbeitungen in der Statistikproduktion modernisiert und stark erweitert. Seit November 2025 stehen auch dem FDZ neue R- und Stata-Analyseserver (sog. FDZ OnSite-Server) für wissenschaftliche Auswertungen zur Verfügung.

Um die technischen Mittel bereitzustellen, hat eine weitere Initiative des NeSt die Modernisierung IT-Infrastruktur des FDZ vorangetrieben. [Dadurch bietet das FDZ seit November 2025 neue Server mit großen Systemkapazitäten für R und Stata für wissenschaftliche Auswertungen an.](#) Erstmals können die vollen Kapazitäten neben der KDFV auch an den GWAPs genutzt werden, um große Datensätze im Vollmaterial auszuwerten. Wir werden in den FDZ OnSite-Servern demonstrieren, dass viele Auswertungsbedarfe das BTP im Vollmaterial innerhalb von Sekunden beantwortet werden können. Da die Datenmenge des BTP den verfügbaren Arbeitsspeicher weit-

^[1] https://www.bundesfinanzministerium.de/Web/DE/Themen/Steuern/Steuerliche_Themengebiete/NeSt/netzwerk-fuer-empirische-steuerforschung.html

^[2] <https://www.forschungsdatenzentrum.de/de/steuern/btp>

erhin übertrifft, sind geeigneten Programmiermethoden notwendig (untersucht in Kapitel 6).

Neben den bisherigen Hauptwerkzeuge für Datenverarbeitung sind für die Statistikproduktion aktuell SAS und Stata in dem FDZ, findet R als Lingua Franca in der Statistik, Methodologie und Datenwissenschaft und somit auf natürlich weise Einzug in die amtliche Statistik.¹³

Als Open Source Software mit einer weltweit aktiven Community, bietet R Zugang zu sehr vielen Funktionen der Datenverarbeitung (in Form von sog. R-Paketen), die ein breites Spektrum an Nutzerfreundlichkeit und Performanz bieten. Die gleiche Datenverarbeitung kann abhängig von der Software-Nutzung, einige Stunden dauern oder in wenigen Sekunden fertigs ein. Nur die richtige Nutzung geeigneter R-Pakete ermöglicht es, Datenverarbeitungsbedarfe anhand großer Datenmengen in Sekunden nachvollziehbar auszuführen (beschrieben in Kapitel 4). Dadurch stellt sich die Frage welche Programmiermethoden geeignet sind, die neuen Datenverarbeitungsbedarfe mit der spezifischen neuen Infrastruktur zu bedienen (diskutiert in Kapitel 5). Durch die Beantwortung können für den Statistikerstellungsprozesses Werkzeuge abgeleitet werden, die Informationsbedarfe der Öffentlichkeit schnell anhand wachsender Datenmengen zu bedienen. Die Bewertung muss sorgfältig durchgeführt werden, da sich die betrachteten R-Pakete schnell weiterentwicklung, meist mit mehreren großen Releases innerhalb eines Jahres, aber die organisatorischen Strukturen nicht erlauben, jede neue Version einzurichten.

- wechselnde Nutzende (Forscher) unterschiedliche Fachbereiche mit unterschiedlichen Analyse- und t

2

Anwendungsfall Business-Tax-Panel

2.1 Datengrundlage

Das Business-Tax-Panel kombiniert die Angaben aus verschiedenen Ertrags- sowie Umsatzsteuerstatistiken im Quer- und Längsschnitt. Verfügbar sind Informationen aus den folgenden Statistiken: Gewerbe-, Körperschaftsteuer, Umsatzsteuer-Voranmeldung und -Veranlagung, Statistik über die Personengesellschaften und Gemeinschaften, Einnahmenüberschussrechnung und einige Merkmale aus dem Statistischen Unternehmensregister. Insgesamt

deckt der Forschungsdatensatz eine Vielzahl an Analysemöglichkeiten, wie zum Beispiel Analyse von Anpassungsreaktionen oder Verteilungsanalysen, die für die evidenzbasierte steuerpolitische Entscheidungen nötig sind, ab.

Für die vielfältigen Analysewünsche der Forschenden, der damit einhergehenden Dokumentation des Datensatzes in den Metadatenreports (!!hier Fußnote für MDR - siehe Deskriptive Eckdaten 1.) des FDZ, und den Auswertungsbedarf des Fachbereiches ist der Datensatz möglichst wenig beschränkt worden und dadurch ressourcenintensive. Anstelle einer Stichprobe wurden die zugrundeliegenden Vollerhebungen verwendet. Die erste Version des BTP (2013 bis 2019) besteht aus ca. 67 Millionen Beobachtungen. Mit der Aktualisierung um das Berichtsjahr 2020 wird die Zahl der Beobachtungen sich auf ca. 78 Millionen erhöhen. Auch der Merkmalsumfang von zurzeit über 2.700 Merkmalen wird durch Erweiterung von Berichtsjahren steigen.

Bereits aktuell und insbesondere durch die regelmäßige Erweiterung um Berichtsjahre steht der Fachbereich sowie das FDZ vor der Herausforderung den hohen Bedarf an Speicherkapazität, Arbeitsspeicher und Prozessorleistung zu decken. Daher wird das BTP als Anwendungsfall herangezogen

2.2 Auswertungsbedarfe

Um den Auswertungsbedarf des Fachbereichs und der FDZ bereitzustellen, werden unterschiedliche Analysetechniken verwendet. Im Fachbereich ergibt sich zusätzlich der Bedarf die Daten je nach Statistik und Tabelle zu bearbeiten. Auch die Forschenden bearbeiten die Daten um sie für die jeweilige Analyse aufzubereiten. Daher wird die Datenbearbeitung und anschließende Analyse als zweiter Anwendungsbedarf getestet.

Die Körperschaftsteuerstatistik zeigt über die Jahre eine Zunahme der Steuerpflichtigen mit Verlustvortrag im jeweiligen Berichtsjahr (GENESIS Code 73211-0002). Für den zweiten Anwendungsfall wird das Vorliegen eines Verlustvortrages im jeweiligen Berichtsjahr als versucht anhand verschiedener Einflussfaktoren zu erklären. Anzunehmen ist, dass Personalkosten den Verlustvortrag erhöhen können, daher wird die Zahl der Sozialversicherungspflichtig Beschäftigten sowie die Summe der Löhne und Gehälter als erklärende Variable verwendet. Der jeweilige Gesamtbetrag der Einkünfte und die abgezogenen Spenden können ebenfalls den Verlustvortrag beeinflussen. Um den Internationalisierungsgrad des Unternehmens zu erfassen wird

¹³Wachstum der uRos s. <https://r-project.ro/conference2025.html#Presentations>

ein Dummy für aufgenommen der Anzeigt, ob das Unternehmen auslandskontrolliert ist.

2.2.1 Deskriptive Eckdaten

1. deskriptive Eckdaten, für BTP als Panel im Quer- und Längsschnitt: Fallzahl pro Statistik und Jahr (s.MDR Produkt S. 9f https://www.forschungsdatenzentrum.de/sites/default/files/btp_2013-2019_on-site_mdr-prod.pdf)

Kennzahlen um inhaltlose Testdaten zu generieren werden folgende Eckdaten benötigt und im nächsten BTP berücksichtigt:

- › Befüllung
- › Statistische Eckdaten univariate (Quantile),
- › ggf. multivariate (gemeinsame Verteilung)

Exemplarisch, neues BTP beinhaltet dies. Regelmäßige Updates beschleunigen.

2.2.2 Regressionen

2. Verlustvorträge¹⁴ (s. Vortrag NeSt) als Indikator für ... und Einflussgrößen auf Verlustvorträge, für Vermutung von Einfluss der Unternehmensgröße (großes Gesamtvolumen, Löhne, Spenden, tätige Personen; Auslandskontrolle oder WZ) auf positive Verlustvorträge.

2.3 Technische Spezifikationen

AK: Habe ich im Bereich Datengrundlage integriert.

Für die vielfältigen Analysewünsche der Forschenden, den Auswertungsbedarf des Fachbereiches bspw. für Sonderauswertungen und der Erstellung des Metadatenreports des Forschungsdaten zentrums ist der Datensatz konzipiert. Für die Abdeckung aller Anforderungen ist der Datensatz möglichst wenig beschränkt worden und dadurch ressourcenintensive. Der damit einhergehende hohe Bedarf an Speicherkapazität, Arbeitsspeicher und Prozessorleistung stellt sowohl im Fachbereich als auch im Forschungsdatenzentrum eine Herausforderung dar.

Für die vielfältigen Analysewünsche der Forschenden, den Auswertungsbedarf des Fachbereiches bspw. für Sonderauswertungen und der Erstellung des Metadatenreports des Forschungsdaten zentrums ist der Datensatz konzipiert. Für die Abdeckung aller Anforderungen ist der Datensatz möglichst wenig beschränkt worden und dadurch ressourcenintensive. Der damit einhergehende hohe Bedarf an Speicherkapazität, Arbeitsspeicher und

Prozessorleistung stellt sowohl im Fachbereich als auch im Forschungsdatenzentrum eine Herausforderung dar.

- › Technische Herausforderung:
 - › effiziente und verständliche Speicherung
 - › Herausfiltern großer Datenmengen irrelevanter Merkmale
- › Umfang über verfügbaren Arbeitsspeicher
- › Besonders breit mit 3000 Merkmalen, 69 Mio. Beobachtung, sodass zeilenbasierte Formate problematisch sind.
- › Technische Herausforderung:
 - › effiziente und verständliche Speicherung
 - › Herausfiltern großer Datenmengen irrelevanter Merkmale

3

Ausbau der Analyseinfrastruktur

Im Jahr 2025 konnten mit der Bereitstellung neuer Analyseserver wesentliche Fortschritte beim Ausbau der analytischen Infrastruktur des Statistischen Bundesamts und des FDZ erzielt werden.

Die Einführung der neuen Systeme stellt einen bedeutenden Schritt dar, da der Ausbau der Infrastruktur in den formalen Strukturen der Bundesverwaltung ein mehrjähriges Unterfangen ist. Auch Änderungen von Softwareversionen in der abgeschotteten Infrastruktur können organisatorisch aufwändig sein, sodass für die folgenden Darstellungen nicht immer die neuesten Versionen der betrachteten Software zur Verfügung stehen — ein Umstand, der die realistischen Rahmenbedingungen der laufenden Statistikproduktion widerspiegelt. Um dennoch langfristig leistungsstark zu bleiben, wurde die neue Infrastruktur von Beginn an zukunftsorientiert konzipiert und bietet moderne Software auf einer deutlich erweiterten Hardwarebasis.

3.1 Ausgangslage

Das Hauptwerkzeug für die Statistikproduktion ist die kommerzielle Analysesoftware [SAS 9.4](#), für das dedizierte Server bereitgestellt werden.¹⁵ SAS 9.4 verarbeitet Daten

¹⁵Da SAS bereits langjährig eingesetzt wird, ist für die kommenden Performanzvergleiche zu beachten, dass die SAS-Server nicht über die neueste Hardware verfügen. SAS wurde in 2025 auf Version 9.4M8 aktualisiert. Die neueste Version

¹⁴Vortrag Annette 2024 JK

überwiegend zeilenorientiert und belastet den Arbeitsspeicher daher nur gering – ein entscheidender Vorteil in der amtlichen Statistik, da auch große Datenmengen auf mit geringeren Hardwareanforderungen verarbeitet werden können. Für viele Anwendungsfälle ist jedoch die spaltenbasierte Datenverarbeitung effizienter. In R sind neuere Verfahren verfügbar, die moderne Prozessor- und Arbeitsspeicher gezielt ausnutzen, können die Laufzeiten gegenüber SAS erheblich verkürzen (siehe Kapitel 4 und Kapitel 5).

Im FDZ ist – neben SAS – die kommerzielle Software *Stata* das am stärksten nachgefragte Auswertungswerkzeug. *Stata* wird in vielen wissenschaftlichen Fachrichtungen genutzt, da sie ohne tiefgreifende Programmierkenntnisse eingesetzt werden kann, gleichzeitig aber spezialisierte Verfahren, insbesondere für ökonometrische Analysen, bereitstellt. Bei großen Datenmengen stößt *Stata* jedoch an seine Grenzen, da Daten vollständig in den Arbeitsspeicher geladen werden müssen, und nur ausgewählte Operationen erlauben die parallelisierte Datenverarbeitung. Durch die manuelle Variablenauswahl lassen sich größere Datensätze bearbeiten, der Speicherbedarf bleibt aber begrenzend. Bisher waren die GWAP-Arbeitsplätze auf die Single-Core-Version mit begrenztem RAM beschränkt und damit für viele Produkte des FDZ unzureichend, während leistungsfähigere Server vor der Bereitstellung des OnSite-Server nur in der KDFV verfügbar waren.

3.2 R-Server des Statistischen Bundesamts

Seit Jahren steht im Statistischen Bundesamt ein Server für die Open-Source *Statistiksoftware R* und *Python* zur Verfügung, der für die Datenverarbeitung in der Statistikproduktion sowie im KDFV des FDZ genutzt wird. R wird aufgrund seiner großen internationalen Community, der Vielzahl spezialisierter Pakete für Datenanalyse, spaltenbasierte Verarbeitung und Visualisierung sowie der schnellen Weiterentwicklung zunehmend in der amtlichen Statistik eingesetzt.

Seit Anfang 2025 konnte der R- und Python-Server signifikant erweitert werden. Verwendet wird die kommerziell unterstützte *Posit Workbench*, um die Funktionen Projekt-Sharing, Git-Integration, Positron-Features bereitstellen zu können. Zusätzlich wurden die Systemressourcen deutlich ausgebaut, wie die Tabelle 1 zeigt.

Die neue Oberfläche und IDE erhöhen die Nutzerfreundlichkeit, die neuesten R-Versionen stehen bereit, und Pakete können schnell installiert werden. So können moderne Analyse- und Visualisierungsmethoden effizient

genutzt werden – sodass aktuell über 200 aktive Nutzende das System nutzen.

3.3 OnSite-Server des FDZ

Seit November 2025 steht der sogenannte OnSite-Server exklusiv im FDZ für alle OnSite-Nutzungen bereit. Er bietet jeweils dedizierte Stata- und R-Server an den GWAP-Arbeitsplätzen sowie via KDFV mit gleichermaßen umfangreichen Analysekapazitäten, wie in Tabelle 2 aufgeführt. Alle Analyseserver sind über schnelle Direktverbindungen an den Netzwerkspeicher angebunden, sodass R und Stata nahtlos kombiniert werden können.

Stata/MP ist nun einheitlich auf leistungsstarken Multi-Core-Servern verfügbar. Zudem steht erstmals R für OnSite-Nutzungen bereit: Aufbau und Softwarebasis orientieren sich am zentralen R-Server des Statistischen Bundesamts, sind jedoch dediziert für FDZ-Anwendungen.

Die R-Server unterstützen moderne, speichereffiziente Verfahren, mit denen auch Datenmengen oberhalb des Arbeitsspeichers flexibel, stabil und schneller verarbeitet werden können – Details dazu siehe Kapitel 4.

4

Datenverarbeitungsmethoden

Wir betrachten in diesem Artikel die Performanz von sog. Datenverarbeitungsmethoden, d.h. Softwarelösungen, die Daten einlesen, modifizieren, aggregieren, auswerten oder analysieren.⁶

Wir sprechen in diesem Artikel vereinfacht von einer hochperformanten Methode, sobald die betrachtete Datenverarbeitungsmethode in der Lage ist, Datenmengen überhalb des verfügbaren Arbeitsspeichers flexibel und effizient zu nutzen. SAS erfüllt den Großteil dieser Definition – lediglich die Effizienz lässt sich deutlich steigern.

Um Datenauswertung auf höhere Datenmengen

⁶Das Schreiben von Daten wird in unserer Untersuchung vernachlässigt, da es sich bei den Veröffentlichungen des Statistischen Bundesamtes oder den Ergebnissen der Wissenschaft im FDZ um kleine Tabellen handelt, die meist keine große Performanz erfordern. Dennoch bieten die in Kapitel 4.3 vorstellten Lösungen auch hohe Performanz im Schreiben von Daten. Aufgrund der externen Abhängigkeiten verzichten wir auf die Betrachtung von Datenbanken und Spark. Die Werkzeuge sind auch in Programmiersprachen wie Python verfügbar. Dort gibt es weitere Möglichkeiten für hohe Performanz. Wir fokussieren uns auf den standard R-Nutzenden.

ist SAS 9.4M9. S. https://documentation.sas.com/doc/en/pgmsascdc/9.4_3.5/whatsdiff/upgradeswhatsnew94.html

Tabelle 1

StBA R-Server Ausbau (Anfang 2025)

[!htb]

Komponente	Vorher	Nachher
Anzahl Server	1	10
Arbeitsspeicher (jeweils)	700 GB	1 TB
Kernanzahl (jeweils)	72	96
Core Speed (jeweils)	TBA	TBA
GPUs (jeweils)	keine	2× A6000 (je 48 GB)

Tabelle 2

FDZ OnSite-Server Spezifikationen

[!htb]

Komponente	Umfang
Stata-Server	3
R-Server	6
Arbeitsspeicher (jeweils)	512 GB
Kernanzahl (jeweils)	16
CPU-Geschwindigkeit (jeweils)	3.1 GHz

skalieren zu können ist ein Paradigmenwechsel von der “vollständigen Verarbeitung im RAM” zu der Auslagerung aus dem RAM notwendig. Vollständig im RAM sind Daten zwar sehr schnell und einfach zu nutzen, jedoch beansprucht der Transport in den RAM (Einlesen) einen Hauptteil der Laufzeit und der verfügbare RAM reicht i.d.R. nicht für größere Datenmengen. Die nachfolgenden Technologien sind auch in der Lage Daten überhalb des RAMs zu verarbeiten. Durch moderne Hardware und Software kann dies sogar sehr schnell erfolgen.

4.1 Anforderungen

Die wichtigsten Anforderungen bedient R anhand der folgenden Funktionen. - hohe Usability - hohe Performanz

Optimierung der Gesamtaufwände (incl. Entwicklerzeit), nicht nur Laufzeit (Gomolka, Blaschke und Hirsch (2021)).

4.2 Klassische Methoden in R

R-Base ist zweckdienlich für Einsteiger, abhängigkeitsfreie Infrastrukturen, jedoch weder in Usability, noch Performanz empfehlenswert. Basieren auf CSV-Format. R Objekte können auch effizient binär abgespeichert werden `rds`, `qs`.

Hervorragende Ergänzungen zu R-Base:

- › [data.table](#) (Barrett u. a. 2006): Ein ausgereiftes R-Paket, das Datenverarbeitung deutlich schneller macht als Standard-R-Funktionen. Es nutzt den verfügbaren Arbeitsspeicher besonders effizient und ist seit vielen Jahren bewährt. Die Syntax orientiert sich an der R-Basisyntax, erfordert aber spezielle Kenntnisse. Solange die Daten in den Arbeitsspeicher passen, ist `data.table` in den meisten Fällen die performanteste klassische Lösung.
- › [tidyverse](#) (Wickham u. a. 2019): Ein Ökosystem von R-Paketen, das besonders auf einfache Bedienung und Lesbarkeit des Codes ausgelegt ist. Eine eigene Programmiersyntax (`dplyr`-Syntax) orientiert sich an menschlicher Sprache und macht den Code auch für Einsteiger gut verständlich. Diese nutzerfreundliche Syntax ist so beliebt, dass sie von vielen anderen R-Paketen übernommen wurde. Für mittlere Datenmengen, die in den Arbeitsspeicher passen, ist `tidyverse` eine ausgewogene Wahl zwischen Nutzerfreundlichkeit und Performanz.
- › [collapse](#) (Krantz 2020): Ein spezialisiertes R-Paket für schnelle statistische Berechnungen und Datentransformationen. Es kombiniert hohe Performanz mit einem breiten Funktionsumfang für komplexe Datenanalysen. `Collapse` ist besonders effizient bei Aggregationen und Gruppierungsoperationen und bietet dabei eine konsistente Syntax.

[TABELLE DPLYR BEISPIEL]

4.3 Hoch-performante Methoden in R

Ab mittleren Datenmengen (relativ zu CPU und RAM) ist die nachfolgend beschriebene Variablenselektion eine oft notwendige [Best Practice](#), die direkt spürbare Performanzgewinne birgt. Darüberhinaus kann die Datenaufteilung kombiniert mit sog. Lazy-Computation gewinnbringend sein:

- › [Variablenselektion](#): Beim Einlesen von DatenAuswahl der benötigten Variablen in der Einlesefunktion ist wesentliche Best-Practices (besonders für klassische Methoden, da dies das Risiko für RAM-Abbrüche und Wartezeiten deutlich reduziert). Das Einlesen zunächst aller Daten (ggf. mit Variablenselektion zu einem späteren Zeitpunkt) verursacht unnötige Wartezeiten, Ressourcenbelegung und kann zu Abbrüchen führen. Auch Stata profitiert Beschleunigung von 39.9% in R und 33.9% in Gomolka, Blaschke und Hirsch (2021).
- › [Datenaufteilung](#): Wenn der Arbeitsspeicher nicht ausreicht, um die benötigten Daten einzulesen, bietet eine Aufteilung auf mehrere RAM-Gerechte Datenpakete helfen. Für klassische Methoden kombiniert mit der mehrfachen Variablenselektion. Die folgenden hoch-performanten Techniken, kommen auch direkt mehreren Dateien nutzen, ohne manuell die Datensätze zusammenzuführen.
- › [Lazy-Computation](#): Ohne das Nutzende ihren Code verändern müssen, speichert die Lazy-Computation geplante Datenverarbeitungsschritte im Hintergrund, ohne sie sofort auszuführen. Erst wenn ein konkretes Ergebnis abgefragt wird, führt das System die Berechnung durch. Dadurch werden nur die tatsächlich benötigten Daten verarbeitet und unnötige Schritte vermieden – ohne dass der Nutzende seinen Code ändern muss. z. B. durch Lazy-Computation[~lazy] – ohne dass eine manuelle Variablenauswahl erforderlich ist (siehe Kapitel 4).

Datenformat Apache [Parquet](#) - R zeigt große Performanzvorteile gegenüber Stata für FDZ Aufgaben: “Note that using parquet and R reduces the computing time compared to the optimised Stata approach by 65.1% from 77.6 to 27.1 seconds” (Gomolka, Blaschke und Hirsch (2021)) - Die u.g. Parquet-Dateien werden bereits standardmäßig im FDSZ angeboten. - Datenformat, spaltenbasiert, komprimiert, ... - tba - s. Vortrag

Für hohe performante Verarbeitung von Datenmengen überhalb des RAMs betrachten wir die folgenden Werkzeuge, die in Form von R-Paketen verfügbar sind:

- › [arrow](#) (Richardson u. a. 2019): Ein C++-basiertes R-Paket, das speziell für die Arbeit mit großen

Datensätzen entwickelt wurde. Es ermöglicht die Verarbeitung von Daten, die größer als der verfügbare Arbeitsspeicher sind, durch intelligente Datenaufteilung und Parallelisierung. Arrow ist optimal auf das Parquet-Dateiformat abgestimmt und kann Berechnungen automatisch optimieren (Lazy-Computation). Damit ist Arrow besonders geeignet für Datensätze, die mehrere Gigabyte oder sogar Terabyte umfassen.

- › [duckdb](#) (Mühleisen und Raasveldt 2020): Ein eingebettetes Datenbanksystem, das ohne separaten Datenbankserver direkt in R genutzt werden kann. Es verarbeitet Daten spaltenweise, was besonders bei analytischen Abfragen auf großen Datensätzen sehr schnell ist. DuckDB nutzt die bekannte SQL-Syntax für Datenabfragen und kann nahtlos mit Arrow-Daten zusammenarbeiten. Das System verwaltet den Arbeitsspeicher intelligent und kann auch Daten verarbeiten, die größer als der verfügbare RAM sind.
- › [polars](#) (Shima, Bacher und u.a. 2022): Ein Rust-basiertes R-Paket, das durch die Programmiersprache Rust besonders effizient arbeitet. Es bietet sowohl eine Python-orientierte Syntax als auch eine dplyr-kompatible Variante (tidypolars), die für R-Nutzende vertrauter ist. Polars nutzt moderne Optimierungstechniken und ist für sehr große Datensätze ausgelegt. Die Rust-Implementierung sorgt für hohe Geschwindigkeit bei gleichzeitig sparsamer Nutzung der Systemressourcen.

4.4 Gültigkeit von externen Benchmarks

[Veröffentlichte Benchmarks](#) kommen zu unterschiedlichen Ergebnissen, daher ist die Untersuchung in eigener Infrastruktur mit relevanten Use Cases (Datenmengen) und verfügbaren Package-Versionen wichtig und wird im folgenden Kapitel 5 durchgeführt.^{17|18|19}

Die auf den Servern des StBA und FDZ verfügbaren [Packageversionen](#) lassen sich aus organisatorischen Gründen nicht flexibel ändern, da die Genehmigung und Einrichtung neuer Packages nur auf Antrag durch unser R-Betriebsteam erfolgt (i.d.R. innerhalb von 1-2 Tagen). Die Package-Versionen, die zum Zeitpunkt des in Kapitel 5 dargestellten Performanz-Vergleiches verfügbar waren, können Tabelle 3 entnommen werden. Ultimates Optimum nicht wichtig, langfristig stabil gute Performanz

¹⁷Benchmark von Data.table: <https://cran.r-project.org/web/packages/data.table/vignettes/datatable-benchmarking.html>

¹⁸Benchmark von DuckDB <https://duckdblabs.github.io/db-benchmark/>

¹⁹<https://ddotta.github.io/cookbook-rpolars/benchmarking.html>

ist entscheidend.

5

Performanzvergleich

RAM nicht aussagekräftig!!!

5.1 Versuchsaufbau

Um zwischen den in Abschnitt Kapitel 4 vorgestellten Datenverarbeitungsmethoden abzuwägen, haben wir deren Performanz in einem systematischen Vergleich der Performance auf dem SAS-Server des Statistischen Bundesamtes und den neuen OnSite R- und Stata-Servern des FDZ gemessen. Weiterführende Performanzmessung sowie der vollständig reproduzierbare Code sind auf [Opencode verfügbar](http://www.opencode.de/URL-To-Be-Announced)¹⁰.

Für die Untersuchung wurden simulierte Einzeldaten in verschiedenen Größen (0,1%/1%/10% von den insgesamt 67 Millionen Beobachtungen des BTP) betrachtet. Sie wurden aus öffentlich verfügbaren Informationen generiert, um die wesentlichen Strukturen des BTP für unsere Analyse künstlich nachzubilden. Abgrenzend zu den im FDZ bereitgestellten Datenstrukturfiles wurden die Testdaten nicht aus echten Mikrodaten abgeleitet. Der simulierte Datensatz ist ausschließlich für technische Testzwecke der nachfolgenden Anwendungsfälle bestimmt:

1. [Fallzahlen](#) (pro Statistik und Jahr),
2. [Regression](#) (Einflussfaktoren auf Verlustvorträge).

Um eine zuverlässige Performanz-Messung zu erhalten, wurde jede Datenverarbeitungsmethode dreifach angewandt. Der Vergleich erfolgt anhand der mittleren Messung der [Laufzeit](#) der Auswertung (real verstrichene Zeit).

Daneben ist die Erfassung des [Arbeitsspeicher](#) der Auswertung entscheidend, da ein übermäßiger Arbeitsspeicherverbrauch zu schwerwiegenden Abbrüchen führen kann. Dennoch

[Festplattenspeicher](#) ist ausreichend vorhanden, aber unnötige Belegung sollte vermieden werden. Feine Abstufungen der Zielgrößen sind für unsere Aufgaben nicht gleichermaßen relevant. Eine Methode, die die betrachteten Auswertungen in unter 10 Sekunden mit weniger als 4 GB Arbeitsspeicher durchführen kann, wird bereits als optimal bewertet. Weitere Optimierungen sind in diesem

¹⁰www.opencode.de/URL-To-Be-Announced.

Fall nicht erforderlich. Falls bereits die gewünschte Performanz erreicht wurde, rückt die Reduktion des Entwicklungsaufwand in den Vordergrund. Entsprechend sind Aspekte wie einfache Anwendbarkeit und Nachvollziehbarkeit – selbst für unerfahrene Nutzende – ausschlaggebend.

5.2 Vergleichswert in SAS und Stata

Klassisch werden die betrachteten Auswertungsaufgaben im Statistischen Bundesamt hauptsächlich mit SAS und im FDZ mit Stata gelöst. Um die nachfolgenden Ergebnisse einzuordnen, haben wir die Performanzmessungen für 1% des simulierten BTP-Daten (etwa. 800.000 Beobachtungen) in SAS und Stata durchgeführt.

Die Ergebnisse in Tabelle 4 zeigen, dass der umfangreiche Arbeitsspeicher des FDZ OnSite-Servers nicht ausreicht, um das ganze BTP in Stata einzulesen, sodass zwingend mit Variablenselektion gearbeitet werden muss. SAS zeigt seine Stärke anhand der geringen Beanspruchung des Arbeitsspeichers, benötigt aber mit etwa 2,3 Minuten pro Auswertung die doppelte Laufzeit gegenüber Stata.

5.3 Kleiner Vergleich zwischen R, SAS und Stata

RAM Messung: <http://adv-r.had.co.nz/memory.html>

Für 1% der simulierten BTP Daten, reduzieren die R-Datenverarbeitungsmethode alle Zielgrößen gegenüber SAS und Stata erheblich (siehe Tabelle 5 und Tabelle 6). Selbst klassische R-Methoden sind um den Faktor 7 schneller und benötigen nur 33 % des Festplattenspeichers. `{polars}`, `{duckdb}` und `{arrow}` lösen die betrachteten Auswertungen sogar

- › in [unter 2 Sekunden](#) (27-fach schneller),
- › mit [unter 300 MB Arbeitsspeicher](#) – `{duckdb}` und `{polars}`¹¹ sogar mit [unter 5 MB](#) (10-fach weniger)¹² –
- › und nur mit [5 GB Festplattenspeicher](#) (6-fach weniger gegenüber SAS und Stata).

Unter den klassischen R-Methoden bietet `{data.table}` die beste Performanz. Dabei ist wesentlich zu beachten, dass die Einlesefunktion `fread` direkt die relevanten Variablen auswählt. Dadurch lassen sich unsere Auswer-

¹¹Lediglich in der Arbeitsspeicherbeanspruchung, ist SAS deutlich besser als klassische R-Methoden. Gegenüber hochperformanten R-Methoden benötigt SAS jedoch den 10-fachen Arbeitsspeicher.

¹²`{arrow}` benötigt mit 274 MB deutlich mehr Arbeitsspeicher als `{polars}` und `{duckdb}`, aber kommt dennoch mit minimalen Entwicklungsumgebungen aus, bspw. einem standardmäßigen Laptop.

Tabelle 3
Versionen verfügbarer R-Packages

[!htb]	
Software	Version
SAS	9.4 (M8)
Stata	19 MP
R	4.5
{data.table}	1.17.8
{readr}	tba
{dplyr}	tba
{vroom}	tba
{arrow}	20.0.0.2
{duckdb}	1.3.2
{polars}	1.0.1

Tabelle 4
Baselines in SAS und Stata (anhand 1% des simuliertes BTP)

[!htb]				
Software	Anwendung	Arbeitsspeicher	Laufzeit	Festplattenspeicher
SAS	Fallzahl	65 MB	2.4 Min.	33 GB
	Regression	7 MB	2.8 Min.	33 GB
Stata	Fallzahl	33 GB	55,2 Sek.	32 GB
	Regression	33 GB	55,8 Sek.	32 GB

tungen um einen Faktor 3 beschleunigen und vor allem der Arbeitsspeicher um einen Faktor 1.000 reduzieren.

Alle hoch-performanten Methoden sind dermaßen effizient, dass die Datenmenge von 800.000 Beobachtungen nicht mehr ausreicht, um zwischen den besten Methoden zu differenzieren. Daher erhöhen wir im nächsten Experiment die Datenmenge auf 8.000.000 Beobachtungen (10% BTP).

Tabelle 5

Performanz Messungen für die Fallzahlberechnung anhand 1% des BTP

[!htb]

Package	Dateiformat	Optimierung	Arbeitsspeicher	Laufzeit	Festplattenspeicher
{polars}	Parquet	-	3,3 MB	1,0 Sek	4,9 GB
{duckdb}	Parquet	-	4,8 MB	1,5 Sek	4,9 GB
{arrow}	Parquet	Variablenauswahl	273,7 MB	1,7 Sek	4,9 GB
{data.table}	CSV	Variablenauswahl	42,9 MB	2,5 Sek	13,0 GB
{arrow}	Parquet	Datenaufteilung (gleichmäßig)	229,7 MB	2,8 Sek	4,9 GB
{arrow}	Parquet	-	272,8 MB	2,8 Sek	4,9 GB
{arrow}	Parquet	-	230,4 MB	3,8 Sek	4,9 GB
{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	229,9 MB	3,9 Sek	4,8 GB
{data.table}	CSV	-	33,7 GB	7,4 Sek	13,0 GB
{data.table}	CSV	Datenaufteilung (Berichtsjahr)	50,4 GB	13,6 Sek	10,5 GB

Tabelle 6

Performanz Messungen für die Regressionsberechnung anhand 1% des BTP

[!htb]

Package	Dateiformat	Optimierung	Arbeitsspeicher	Laufzeit	Festplattenspeicher
{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	529,7 MB	3,8 Sek	4,8 GB
{dplyr}	CSV	Variablenauswahl	154,8 MB	13,2 Sek	13,0 GB

5.4 Größere Datenmengen in R

Auch für 10 % der simulierten BTP-Daten, kann R die beiden betrachteten Auswertungen in Echtzeit mit minimalem Arbeitsspeicher beantworten (siehe Tabelle 7 und Tabelle 8). Die Auswertungsmethoden mit der höchsten Performanz nutzen alle das {parquet} und erreichen:

1. {arrow} benötigt nur 4,7 Sekunden und 230 MB Arbeitsspeicher,
2. {duckdb} benötigt nur 5,1 Sekunden und 4,7 MB Arbeitsspeicher.

[tba: Plot der Performanz unterschiede]

Unerwarteterweise ist die Laufzeit von {polars} für diese Datenmenge mit 1,2 Minuten weit abgeschlagen, obwohl das gleiche Auswertungsskript für kleinere Datenmengen immer die geringste Laufzeit aufwies. Da {polars} das jüngste der betrachteten R-Packages ist, vermuten wir Performanzprobleme in der vorliegenden Version 1.0.1¹³. Zudem hat es noch größere Entwicklungsaufwände beansprucht, da der an Python angelehnte Syntaxstil deutlich von üblicher Programmierung in R abweicht. Öffentliche Hilfestellung bezieht sich hauptsächlich auf Python (oder Rust), was sich in den Antworten der KI-Chatassistenten widerspiegelt.

Klassische Methoden kommen bei der betrachteten Datenmenge bereits an ihre Grenzen. Falls in {data.table} unbeachtet der vollständige Datensatz eingelesen wird, werden in unserem Anwendungsfall die verfügbaren 512 GB Arbeitsspeicher vollständig beansprucht. Schon wenn klassische Methoden auf Datenmengen von ca. 25-33% des verfügbaren Arbeitsspeichers angewandt werden, ist somit deutlich mehr Erfahrung der Nutzenden notwendig, um die relevanten Variablen manuell geschickt zu selektieren unter Beobachtung des Arbeitsspeicherverbrauchs.

Somit kommen wir insgesamt zu dem Ergebnis, dass {arrow} kombiniert mit {parquet} für die Bewältigung unserer Aufgaben die beste Datenverarbeitungsmethode ist, da die Methodik hervorragende Performanz und zugleich hohe Nutzerfreundlichkeit bietet. Im Detail haben uns der folgenden Mehrwerte überzeugt:

1. Für die relevanteste Datenmenge von 8 Mio. Beobachtungen zeigte {arrow} die geringsten Laufzeiten unter 5 Sekunden, was der Fachstatistik Antworten auf Sonderanfragen in Echtzeit ermöglicht und der Wissenschaft alle denkbaren explorativen Analysen auszuweiten.

¹³ Das R-Package {polars} Version 1.0.1 war nur der erste Minor Release nach einer kompletten Überarbeitung. Inzwischen sind 5 neuere Major Releases mit diversen Performanz-Verbesserungen verfügbar.

2. auch die Nutzererfahrung gefiel uns mit {arrow} am besten und somit waren die einhergehenden Entwicklungsaufwände gegenüber den Anderen Methoden am geringsten.
3. {arrow} verwendet die anschauliche {tidyverse} Syntax nativ. Vorhandener Code lässt sich zum Großteil änderungsfrei und ohne Performanzverluste auf {arrow} übertragen. {duckdb} kann bei Kenntnissen in SQL zu bevorzugen sein und {polars} mit Erfahrungen in Python.
4. Beide Anwendungen ließen sich in unter 20 nachvollziehbaren Zeilen in {arrow} programmieren.¹⁴
5. Obwohl nicht alle Features aus {tidyverse} für {arrow} verfügbar sind, ließ sich bisher immer eine Lösung finden, um die gewünschte Auswertung umzusetzen, bspw. durch Kombination mit {duckdb} oder andere Funktionsaufrufe.
6. {arrow} spart ausreichend Arbeitsspeicher (mit Verbrauch unter 1 GB) (tba: Fußnote zu duckdb/polars). Der Arbeitsspeicherverbrauch von {arrow} ist in unserer Auswertung nahezu konstant abhängig von der Datenmenge, sodass {arrow} leicht auf noch größere Datenmengen skalieren kann
7. Dadurch das {arrow} die Nutzung auch von mehreren {parquet} Dateien unterstützt spart gegenüber CSV mind. 50% der Festplatte (für das reale BTP sogar 80%+) und ermöglicht schnelle Nutzung auch von Datenmengen überhalb des verfügbaren Arbeitsspeichers.

[tba: Plot RAM-Bedarf abhängig von der Datenmenge]

6

Ergebnis für das vollständige BTP

Anwendung der besten Methode auf die echten Daten des vollständige BTP ergibt:

- › Performanz von {arrow} Fallzahlen (ein paar Sekunden) und Regression (Sekunden)
- › leicht lesbar in {arrow}

6.1 Ergebnis

[Ergebnistabelle Fallzahl, ggf. als Heatmap]

-> Zukünftige Nutzung für MDR wird umgesetzt.

[Model Summary?]

¹⁴ www.opencode.de/URL-To-Be-Announced.

Tabelle 7

Performanz Messungen für die Fallzahlberechnung anhand 10% des BTP

[!htb]					
Package	Dateiformat	Optimierung	Arbeitsspeicher	Laufzeit	Festplattenspeicher
{arrow}	Parquet	Datenaufteilung (gleichmäßig)	229,9 MB	4,7 Sek	48,8 GB
{duckdb}	Parquet	-	4,7 MB	5,1 Sek	49,4 GB
{arrow}	Parquet	Variablenauswahl	702,1 MB	7,5 Sek	49,4 GB
{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	4,7 MB	11,7 Sek	48,1 GB
{arrow}	Parquet	-	230,4 MB	17,0 Sek	49,4 GB
{arrow}	Parquet	-	701,2 MB	20,6 Sek	49,4 GB
{data.table}	CSV	Variablenauswahl	427,5 MB	23,6 Sek	130,2 GB
{polars}	Parquet	-	3,3 MB	1,2 Min	49,4 GB
{data.table}	CSV	-	336,0 GB	2,2 Min	130,2 GB
{data.table}	CSV	Datenaufteilung (Berichtsjahr)	506,4 GB	5,0 Min	104,6 GB

Tabelle 8

Performanz Messungen für die Regressionsberechnung anhand 10% des BTP

[!htb]					
Package	Dateiformat	Optimierung	Arbeitsspeicher	Laufzeit	Festplattenspeicher
{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	782,1 MB	5,2 Sek	48,1 GB
{dplyr}	CSV	Variablenauswahl	1,5 GB	1,9 Min	130,2 GB

6.2 Vergleich zu SAS, (Stata), Datatable

- › Ergebnis in SAS
- › (optional) Datatable ohne selektives Einlesen führt zu RAM Crash (RAM-Fehler?)
- › (optional) Datatable Sel.

Real world application unserer Ergebnisse auf das Echte BTP

Ergebnis für gesamten Datensatz

-> Größere Speicherreduktion, da das echte BTP mehr fehlende Werte enthält, als anhand der externen Daten angenommen.

7

Fazit

7.1 Kernaussage des Artikels

Wir empfehlen eine Datenhaltung im Parquet-Format und R incl. {arrow} + {parquet} (bei Bedarf {duckdb}, {polars}) zu erproben und zu etablieren! Denn unsere Untersuchung demonstriert ganz neue Möglichkeiten, an-

alytische Fragestellungen anhand großer Datenmengen in Echtzeit zu beantworten.

7.2 Auswirkung auf IT-Infrastruktur und Beratung

- › Fokus auf Hardware und Software mit größtem Mehrwert (weniger RAM und R anstatt Spark, GPUs, Datenbanken, Cloud, ...)
- › Fokus auf Maintainance und Patching von R, Parquet und hier genannte Packages {arrow}, {duckdb}, {polars}
- › Etablierung dieser Softwarelösungen kann langfristig...
 - › die Hardwareanforderungen reduzieren
 - › die Analysesoftwarevielfalt verschlanken, somit Beschaffungen einsparen (besserer Ausdruck?)
- › Schulungsangebot benötigt für “hoch-performante Auswertungen in R”
- › eigener Beitrag zu Open Source entscheidend, um die Etablierung zu fördern.

7.3 Auswirkungen auf die Statistikproduktion

- › Steigerung der Effizienz und Reaktionsgeschwindigkeit
- › (Vorsichtig!/? Annette, lieber weg oder rein?) Vereinfachung der Statistikproduktion, durch leicht nachvollziehbaren Code und Fokus auf Wissensaufbau in R
- › Aufbau eines Datenbestands in Parquet
- › Anwendung auf weitere Produkte

- › Überarbeitung des BTP
- › Mindeststeuer (oder?)
- › DRG
- › TPP 2

7.4 Auswirkungen auf die FDZ

- › Berücksichtigung in Mustersyntaxen und Nutzendenberatung im FDZ Bund. Teilen von Code-Snippets und Templates fördern.
- › mögliche Vereinfachung der Betreuung (Fokus auf R, Reduktion von Performanz- und Programmierproblemen)
- › Bereitstellung von Parquet in geeigneter Aufteilung empfohlen
- › Erprobung im FDZ Bund Vorbild für andere FDZ
- › Optimierung von Hardware und Software Angebot

7.5 Auswirkung auf die Wissenschaft

- › Verwendung von R bietet am FDZ Bund einen deutlichen [Wettbewerbsvorteil in der emp. Forschung](#). Lediglich R ist (am GWAP und via KDFV) am FDZ Bund in der Lage große Datenmengen innerhalb von Sekunden zu analysieren und Datenmengen überhalb des verfügbaren Arbeitsspeicher, wie das BTP, ohne vorherige Variablenselektion auszuwerten.
 - › Vollmaterial kann statt Stichproben angeboten werden. Erleichtert die FDZ Betreuung und GWAP/KDFV-Verfügbarkeit
 - › mehr explorative oder komplexe Analysen sind in kürzerer Zeit möglich.
- › Dazu ist R als frei verfügbare Open-Source Software leicht zu lernen und {arrow} bietet hoch-performante Analysen selbst für R-Basiskenntnisse. Empfehlung an die emp. Wissenschaft, sich verstärkt mit R zu befassen.
- › Für analoge über-RAM-Verarbeitungen bietet Stata aktuell keine Lösung. SAS bietet bei weitem nicht hier gemessene Performanz von R. R hervorragende Möglichkeiten bietet Performanz und Anwenderfreundlichkeit zu übertreffen.
- › Weiteres Vorgehen: [NeSt-Pilotprojekt](#). Aus dem realen Use Case Optimierung der Systemkonfiguration und Beratungsbedarfe identifizieren.

7.6 Schlussbemerkung

Die Analyse großer Datensätze in der amtlichen Statistik und den Forschungsdatenzen können von einem signifikanten Performanz-Boost profitieren, wenn die vorgestellten Werkzeuge adaptiert werden. [Arrow](#), [DuckDB](#), [Polars](#) und

[Parquet](#) – bieten das Potenzial, die Effizienz erheblich zu steigern und neue Analysemöglichkeiten zu eröffnen.

Der Übergang erfordert jedoch eine [koordinierte Anstrengung](#) von Infrastrukturbetreibern, amtlicher Statistik, Forschungsdatenzentren und Forschenden. Die systematische Wissensaufbau, Dokumentation und Verbreitung von Best Practices wird entscheidend für den Erfolg sein.

Die amtliche Statistik kann von diesen Entwicklungen in mehrfacher Hinsicht profitieren: [schnellere Erkenntnisgewinnung](#), [umfassendere Analysen](#) und [effizientere Ressourcennutzung](#). Dies trägt letztlich zur Stärkung der evidenzbasierten Politik- und Gesellschaftsberatung bei.

Anhang

Inhalte für die Veröffentlichung in Open Code.

Weitere Performancemessungen für kleinere Datenmengen.

Tabelle 9

Benchmarkergebnisse für Fallzahlen (kleine Stichproben des BTP)

[!htb]

Beob.	Package	Dateiformat	Optimierung	Arbeitsspeicher	Laufzeit	Festplattenspeicher
10.000	{polars}	Parquet	-	3,3 MB	0,4 Sek	492,6 MB
10.000	{data.table}	CSV	Variablenauswahl	4,4 MB	0,7 Sek	1,3 GB
10.000	{arrow}	Parquet	Variablenauswahl	230,7 MB	1,1 Sek	492,6 MB
10.000	{readr}	CSV	Variablenauswahl	9,3 MB	1,2 Sek	1,3 GB
10.000	{arrow}	Parquet	-	229,8 MB	1,6 Sek	492,6 MB
10.000	{duckdb}	Parquet	-	4,7 MB	2,9 Sek	492,6 MB
10.000	{data.table}	CSV	-	3,4 GB	3,6 Sek	1,3 GB
10.000	{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	229,9 MB	4,2 Sek	486,9 MB
10.000	{arrow}	Parquet	-	230,4 MB	4,6 Sek	492,6 MB
10.000	{data.table}	CSV	Datenaufteilung (Berichtsjahr)	5,1 GB	4,8 Sek	1,0 GB
10.000	{arrow}	Parquet	Datenaufteilung (gleichmäßig)	229,9 MB	7,1 Sek	483,5 MB
10.000	{readr}	CSV	-	1,7 GB	8,6 Sek	1,3 GB
10.000	{arrow}	CSV	-	27,4 MB	15,7 Sek	1,3 GB
10.000	{data.table}	CSV.GZ	-	4,7 GB	21,2 Sek	421,9 MB
10.000	{base}	CSV	-	9,7 GB	4,9 Min	1,3 GB
1.000	{data.table}	CSV	Variablenauswahl	0,6 MB	0,1 Sek	129,8 MB
1.000	{readr}	CSV	Variablenauswahl	2,7 MB	0,2 Sek	129,8 MB
1.000	{polars}	Parquet	-	3,3 MB	0,4 Sek	48,1 MB
1.000	{data.table}	CSV	-	341,8 MB	0,9 Sek	129,8 MB
1.000	{duckdb}	Parquet	-	4,7 MB	1,1 Sek	48,1 MB
1.000	{arrow}	Parquet	Variablenauswahl	226,2 MB	1,2 Sek	48,1 MB
1.000	{arrow}	Parquet	-	225,3 MB	1,4 Sek	48,1 MB
1.000	{arrow}	CSV	-	3,5 MB	1,5 Sek	129,8 MB
1.000	{data.table}	CSV.GZ	-	491,7 MB	2,7 Sek	42,1 MB
1.000	{data.table}	CSV	Datenaufteilung (Berichtsjahr)	510,9 MB	2,8 Sek	104,5 MB
1.000	{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	229,9 MB	2,9 Sek	53,5 MB
1.000	{arrow}	Parquet	-	230,4 MB	3,7 Sek	48,1 MB
1.000	{arrow}	Parquet	Datenaufteilung (gleichmäßig)	229,7 MB	4,0 Sek	50,5 MB
1.000	{readr}	CSV	-	197,4 MB	4,9 Sek	129,8 MB
1.000	{base}	CSV	-	713,4 MB	23,3 Sek	129,8 MB

Tabelle 10

Benchmarkergebnisse für Regression (kleine Stichproben des BTP)

[!htb]

Beob.	Package	Dateiformat	Optimierung	Arbeitsspeicher	Laufzeit	Festplattenspeicher
10.000	{dplyr}	CSV	Variablenauswahl	17,6 MB	1,3 Sek	1,3 GB
10.000	{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	459,3 MB	5,0 Sek	486,9 MB
10.000	{dplyr}	CSV	-	1,8 GB	10,8 Sek	1,3 GB
1.000	{dplyr}	CSV	Variablenauswahl	4,2 MB	0,3 Sek	129,8 MB
1.000	{dplyr}	CSV	-	206,9 MB	6,4 Sek	129,8 MB
1.000	{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	452,5 MB	6,8 Sek	53,5 MB

Literatur

- Barrett, Tyson u. a. (2006). data.table: Extension of ‘data.frame’. R package version 1.17.8. URL: <https://CRAN.R-project.org/package=data.table>.
- Gomolka, Matthias, Jannick Blaschke und Christian Hirsch (2021). Working with Large Data at the RDSC. Technical Report 2021-04. Frankfurt am Main: Deutsche Bundesbank. URL: <https://www.bundesbank.de/en/bundesbank/research/rdsc/publications/methodology-reports/working-with-large-data-at-the-rdsc-623988>.
- Krantz, Sebastian (2020). collapse: Advanced and Fast Data Transformation in R. R package version 2.1.5. DOI: 10.5281/zenodo.8433090. URL: <https://sebkranz.github.io/collapse/>.
- Mühleisen, Hannes und Mark Raasveldt (2020). duckdb: DBI Package for the DuckDB Database Management System. R package version 1.4.2. URL: <https://CRAN.R-project.org/package=duckdb>.
- Richardson, Neal u. a. (2019). arrow: Integration to ‘Apache’ ‘Arrow’. R package version 22.0.0. URL: <https://CRAN.R-project.org/package=arrow>.
- Sachverständigenrat zur Begutachtung der gesamtwirtschaftlichen Entwicklung (2023). Jahresgutachten 2023/24: Wachstumsschwäche überwinden – In die Zukunft investieren. Jahresgutachten. Wiesbaden: Sachverständigenrat zur Begutachtung der gesamtwirtschaftlichen Entwicklung. URL: <https://www.sachverstaendigenrat-wirtschaft.de/jahresgutachten-2023.html>.
- Shima, Tatsuya, Etienne Bacher und u. a. (2022). polars: R Bindings for the ‘polars’ Rust Library. R package version 1.6.0, <https://github.com/pola-rs/r-polars>, <https://rpolars.r-universe.dev/polars>. URL: <https://pola-rs.github.io/r-polars/>.
- Wickham, Hadley u. a. (2019). „Welcome to the tidyverse“. In: Journal of Open Source Software 4.43, S. 1686. DOI: 10.21105/joss.01686.
- Wissenschaftlicher Beirat beim Bundesministerium der Finanzen (Okt. 2020). Notwendigkeit, Potenzial und Ansatzpunkte einer Verbesserung der Dateninfrastruktur für die Steuerpolitik. Gutachten. Gutachten des Wissenschaftlichen Beirats. Berlin: Bundesministerium der Finanzen. URL: <https://www.bundesfinanzministerium.de/Content/DE/Downloads/Ministerium/Wissenschaftlicher-Beirat/Gutachten/2020-10-30-gutachten-dateninfrastruktur-steuerpolitik.html>.