
Oliver Hauke

ist Mathematiker und IT-Referent im Kompetenzzentrum „Analyse und Auswertung“ des Statistischen Bundesamtes. Er verantwortet die Weiterentwicklung der technischen Infrastruktur des Forschungsdatenzentrums und berät das Netzwerk empirische Steuerforschung in der effizienten Nutzung der Systeme.

Annette Kristiansen

ist Ökonomin und Referentin im Referat „Unternehmenssteuern“ des Statistischen Bundesamtes. Sie beschäftigt sich mit der Zusammenführung der Unternehmenssteuerstatistiken und betreut das Netzwerk empirische Steuerforschung. Für ihre externe Promotion an der Universität Bremen untersucht sie die technologische Vielfalt multinationaler Unternehmen.

EFFIZIENTE AUSWERTUNG DES BUSINESS-TAX-PANELS MITHILFE VON R

Oliver Hauke, Annette Kristiansen

🔑 **Schlüsselwörter:** Effiziente Analysen, R-Programmierung, Forschungsdaten, Unternehmenssteuerstatistik, Business-Tax-Panel, Netzwerk empirische Steuerforschung

ZUSAMMENFASSUNG

Das Forschungsdatenzentrum des Statistischen Bundesamtes baut seine technische Infrastruktur gezielt aus, um der Wissenschaft erweiterte Analysemöglichkeiten amtlicher Daten bereitzustellen. Seit November 2025 steht Forschenden exklusiver Zugang zu diesen erweiterten Systemressourcen in R und Stata zur Verfügung. R-basierte Tools – insbesondere Apache Arrow, Parquet und DuckDB – ermöglichen es, gängige Analysen großer Forschungsdatensätze in Echtzeit auszuführen. Am Beispiel des Business-Tax-Panel (2013 bis 2019) werden die erzielbaren Effizienzgewinne bei der Auswertung umfangreicher steuerstatistischer Daten im Rahmen des Netzwerks empirische Steuerforschung demonstriert.

🔑 **Keywords:** Efficient analysis – R programming – research data – corporate tax statistics – Business Tax Panel – empirical tax research network

ABSTRACT

The Research Data Centre at the Federal Statistical Office is strategically expanding its technical infrastructure to provide researchers with enhanced analytical capabilities for official data. Since November 2025, researchers have had exclusive access to these extended system resources in R and Stata. R-based tools – particularly Apache Arrow, Parquet, and DuckDB – enable real-time analysis of large research datasets. Using the Business Tax Panel (2013–2019), this paper demonstrates the achievable efficiency gains in analysing large-scale tax statistics within the empirical tax research network.

Inhaltsverzeichnis

1	Einleitung	6
1.1	Handlungsbedarf	6
1.1.1	Steigende Datenmenge in der amtlichen Statistik	6
1.1.2	Steigende Anforderungen der Wissenschaft und Öffentlichkeit	6
1.2	Vorschreitende Innovation der Datenverarbeitungstechnologien	7
1.2.1	Ausgangslage	7
1.2.2	Vormarsch von Open Source	7
1.2.3	Fokus auf R	7
1.2.4	Hoch-performante Datenverarbeitungsmethoden	8
1.3	Umsetzung im StBA und FDZ	8
1.4	Diese Arbeit	8
2	Anwendungsfall Business-Tax-Panel	8
2.1	Datengrundlage	8
2.2	Auswertungsbedarfe	9
2.2.1	Deskriptive Eckdaten	9
2.2.2	Regressionen	9
2.3	Technische Spezifikationen	9
3	Technische Infrastruktur	10
3.1	Allgemeinn	10
3.2	SAS Server	10
3.3	StBA R-Server	10
3.4	FDZ OnSite-Server	10
4	Datenverarbeitungsmethoden	10
4.1	Anforderungen an Datenverarbeitungsmethoden	10
4.2	Sachstand	10
4.2.1	SAS und Stata	10
4.2.2	Empfehlung des FDSZ der deutschen Bundesbank	11
4.3	Analysewerkzeug R	11
4.4	Klassische Methoden in R	11
4.4.1	Base R	11
4.4.2	Data.table	11
4.4.3	Tidyverse	11
4.5	Best Practices in R	11
4.6	Hoch-performante Methoden in R	12
4.6.1	Apache Parquet	12
4.6.2	Apache Arrow	12
4.6.3	DuckDB	12
4.6.4	Polars	12
4.7	Package-Versionen	12
5	Performanzvergleich	12
5.1	Versuchsaufbau	12
5.2	Vergleichswert in SAS und Stata	13
5.3	Kleiner Vergleich zwischen R, SAS und Stata	13
5.4	Größere Datenmengen in R	15
6	Ergebnis für das vollständige BTP	15
6.1	Ergebnis	15
6.2	Vergleich zu SAS, (Stata), Datatable	16

7	Fazit	16
7.1	Kernaussage des Artikels	16
7.2	Auswirkung auf IT-Infrastruktur und Beratung	16
7.3	Auswirkungen auf die Statistikproduktion	16
7.4	Auswirkungen auf die FDZ	17
7.5	Auswirkung auf die Wissenschaft	17
7.6	Schlussbemerkung	17
	Anhang	17
	Weitere Performancemessungen für kleinere Datenmengen.	17

Dokument-Metadaten

Titel:	EFFIZIENTE AUSWERTUNG DES BUSINESS-TAX-PANELS MITHILFE VON R
Autoren:	Oliver Hauke, Annette Kristiansen
Veröffentlichung:	WISTA 01/2026
Erstellungsdatum:	5. Dezember 2025 um 21:06 Uhr

Dokumentstatistik

Abschnitt	Wörter	Zeichen	Tab.	Abb.	Fußn.	Quellen	Vorgabe
Insgesamt	4 782	38 361	8	0	8	9	30 000 Z.
Zusammenfassung	81	707	—	—	—	—	800 Z.
Abstract	85	623	—	—	—	—	700 Z.
Einleitung	1 231	12 423	0	0	3	3	—
Anwendungsfall Business-Tax-Panel	125	1 261	0	0	0	0	—
Technische Infrastruktur	145	1 463	0	0	0	0	—
Datenverarbeitungsmethoden	810	8 174	0	0	2	2	—
Performanzvergleich	999	10 082	0	0	2	2	—
Ergebnis für das vollständige BTP	84	847	0	0	0	0	—
Fazit	407	4 107	0	0	1	1	—

Schlüsselwörter & Keywords

Typ	Anzahl
Schlüsselwörter	6
Keywords	6

Tabellen

Nr.	Beschreibung
Tabelle 1	Versionen verfügbarer R-Packages
Tabelle 2	Baselines in SAS und Stata (anhand 1% des simuliertes BTP)
Tabelle 3	Performanz Messungen für die Fallzahlberechnung anhand 1% des BTP
Tabelle 4	Performanz Messungen für die Regressionsberechnung anhand 1% des BTP
Tabelle 5	Performanz Messungen für die Fallzahlberechnung anhand 10% des BTP
Tabelle 6	Performanz Messungen für die Regressionsberechnung anhand 10% des BTP
Tabelle 7	Benchmarkergebnisse für Fallzahlen (kleine Stichproben des BTP)
Tabelle 8	Benchmarkergebnisse für Regression (kleine Stichproben des BTP)

Abbildungen

Nr.	Beschreibung
Abbildung 1	Strategien zur Performanz-Optimierung im FDZ-Bund

1

Einleitung

Spannungsfeld, Weiterentwicklung zur Lösung und Technologie-Empfehlung

Einbauen: Forschungsdatenzentrum des Statistischen Bundesamts, hier kurz FDZ Netzwerk empirischer Steuerforschung, hier kurz NeSt.

1.1 Handlungsbedarf

1.1.1 Steigende Datenmenge in der amtlichen Statistik

- › Qualitätsbericht. Wachsende Datenmenge in der amtlichen Statistik, Verweis auf (Statistisches Bundesamt 2023)
- › Datenverarbeitung im StBA ...
- › neues NeSt Produkt BTP zeigt Umfang, hoch interessant für Wissenschaft
- › Datenverarbeitungsaufgaben des StBA erklären
- › Nicht mehr durch vorhandene Systemkapazitäten (insb. Arbeitsspeicher) gedeckt
- › Herausforderungen (größere Datenmengen, komplexere Analysen, schnellere Antworten notwendig)
 - › hohe Anforderungen der Öffentlichkeit und besonders Wissenschaft. Verweis auf Gutachten des Stat. Beirats und Gründung “Netzwerk emp. Steuerforschung”
 - › Schnelle Bereitstellung von am besten vollständigen, wenig Anonymisierten Datensätzen an Wissenschaft via FDZ. Erste Analysen seitens StBA und hohe Expertise erwartet (Exploration der Daten nötig)
 - › Bereitstellung von Zusatzdokumentation durch StBA. Metadatenreport
 - › schnelle Bereitstellung,
 - › zeitnahe Nutzung in FDZ
 - › keine Wartezeiten in FDZ
 - › sofortig Antworten auf Analysefragen
 - › Erhöhte Komplexität Analysen mit größeren, Komplexeren Datensätzen
- › Rückstände/Altlasten: weiterentwickelnde Infrastruktur, nicht state of the art (ausgelegt auf Konsistenz und Zuverlässigkeit, nicht Schnelligkeit), gesetzlicher Auftrag
 - › hauptsächlich SAS für große Datenmenge verwendet, funktioniert, aber langsam
 - › FDZ Bund integriert in Standardarbeitsplätze

des StBA

- › Bereitstellungsaufwände und Abhängigkeiten moderner Software

Annette: -> Impuls aus der Wissenschaft, dann Fachbereich - Fachbereich/Verbund im Grunde Hauptnutzende da Tools und Daten zur Verfügung stehen Technische Möglichkeit entwickelt sich weiter usw..

Der Sachverständigenrat zur Begutachtung der gesamtwirtschaftlichen Entwicklung (2023) hat in seinem Gutachten 2023/24 auf eine technisch veraltete Infrastruktur und auf die fehlende Nutzerfreundlichkeit hingewiesen. Seitdem hat sich die Infrastruktur in dem Forschungsdatenzentrum des Bundes verbessert. Seit Januar 2025 besteht ein Remote Access System als neuer Zugangsweg für die Wissenschaft. Im Bereich der Steuerstatistiken wird derzeit geprüft, inwiefern auch Einzeldaten aus diesem Bereich über Remote Access genutzt werden können. Als Übergang und Erleichterung für bestehende Forschungsprojekte wird in diesem Kapitel 2

Die amtliche Statistik steht vor der Herausforderung, bei stetig wachsenden Datenmengen und sich ändernden Nutzeranforderungen qualitativ hochwertige und zeitnahe statistische Informationen bereitzustellen (Statistisches Bundesamt 2023). Dabei spielt die Effizienz der verwendeten statistischen Verfahren eine zentrale Rolle für die Leistungsfähigkeit des gesamten statistischen Systems.

In den vergangenen Jahren haben sich die Rahmenbedingungen für die Produktion amtlicher Statistiken erheblich verändert. Die Digitalisierung hat nicht nur zu einer Vervielfachung der verfügbaren Datenquellen geführt, sondern auch neue Möglichkeiten für die statistische Analyse eröffnet. Gleichzeitig sind die Erwartungen der Nutzer an Aktualität und Detailliertheit der Statistiken gestiegen.

Diese Entwicklungen erfordern eine kontinuierliche Evaluation und Optimierung der eingesetzten Verfahren. Ziel der vorliegenden Studie ist es daher, die Effizienz verschiedener statistischer Verfahren systematisch zu bewerten und Handlungsempfehlungen für die Praxis abzuleiten.

1.1.2 Steigende Anforderungen der Wissenschaft und Öffentlichkeit

FDZ, NeSt

- › Schnelle Reaktionen erforderlich
- › Komplexere (Forschungsfragen) zu beantworten
- › FDZ erklären
- › Gutachten BMF ansprechen
- › NeSt erklären, Bedarfe durch Produkt BTP beantwortet.. aber wie kann es in angeme

1.2 Vorschreitende Innovation der Datenverarbeitungstechnologien

1.2.1 Ausgangslage

SAS für amtl. Statistik und SAS/Stata für FDZ

- › SAS, zsl. Stata in den FDZ. Session zu SAS Ablösung
- › Weiterentwicklung der Infrastruktur: neue Server für R im StBA und für FDZ eigene neue Server für R und Stata
- › hohe Lizenzkosten, Trend zu Abonnements und Cloud nachteilig, technologiLOCK und Privacy.
- › Kommen bei unseren Anwendungen Kapazität an ihre Grenzen und Performanz in anderen Technologien höher.

Anforderungen an Modernisierung

- › hohe Performanz, schnelle Ergebnisse, idealenfalls in Echtzeit (d.h. wenigen Sekunden)
- › moderne Interfaces, möglichst leichte Nutzung, wenig Schulungsbedarf, Allgemeinwissen von Statistiker u.Ä. Fachrichtungen (Werkzeug, nicht Gegenstand der Untersuchung)
- › leicht einrichtbar, wenig Abhängigkeiten zu vielen Tools, die sich ständig weiterentwickeln, sodass hohe Wartungsaufwände entstehen.

1.2.2 Vormarsch von Open Source

- › in der internationalen amtlichen Statistik seit Jahren auf dem Vormarsch. Langsam steigt auch Verbreitung von R steigt auch in den dt. Statistikämtern.

1.2.3 Fokus auf R

R verbreitung steigt, bei uns in Kinderschuhen. Wie fängt man denn am besten an? Was ist von anfang an der richtige Weg Daten in R zu verarbeiten?

R ist weltweit bekannt und verbreitet als die Lingua Franca für Statistik, Methodologie und Data Science. Dies macht R zu der natürlichen Wahl für die amtlichen Statistik mit viele attraktive Vorteile.

- › aktive globale Community sorgt für schnelle Innovation und Verbesserung
- › CRAN bietet offiziell aktuell Zusatzfunktionalitäten in Form von X R-Paketen. Darunter sind viele klassische Pakete für Datenverarbeitung und -analyse.
- › R
 - › The reasons why the official statistics community is rapidly embracing R are clear. S. Erfolg / Wachs-

tum der Conference uRos <https://r-project.ro/conference2025.html#Presentations>

- › R lingua franca for statisticians, methodologists and data scientists worldwide -> nativ geeignet für amtl. Statistik
- › R Open Source bietet Vorteile
 - › aktive globale Community
 - › support from the industry
 - › it combines a vast amount of functionalities for data preparation, methodology, visualisation and application building
 - › free = ideal environment for sharing, collaboration and industrialising official statistics
 - › Packages CRAN, github...

Arrow bspw. hatte in 2024 und 2025 jeweils 4 Major Releases mit diversen neuen Funktionalitäten und Performanz-Verbesserung

Neue Entwicklung zu R in der dt. OSS, bei Integration in Statistikproduktion und Datenbereitstellung direkt mit den richtigen Features und Methoden beginnen. Wie die folgenden...

Open Source -> breite Auswahl an Paketen zum Einlesen, Transformieren und Auswerten von Daten.

- › Unterscheidung klassischer/r-nativer Methoden (base-r, readr / vroom und data.table), effiziente/moderne Methoden (arrow, duckdb, polars)
- › Klassische Methoden
 - › base-r zu vermeiden
 - › readr
 - › in tidyverse
 - › nutzerfreundlich, einfach zu lernen / nutzen
 - › data.table
 - › benchmarking: <https://cran.r-project.org/web/packages/data.table/vignettes/datatable-benchmarking.html>
 - › datenformate in R: qs, rds
 - › dtplyr?

As we start working with larger and larger datasets, the basic tools of the tidyverse start to look a little slow. In the last few years several packages more suited to large datasets have emerged. Some of these are column, rather than row, oriented. Some use parallel processing. Some are vector optimized. Speedy databases that have made their way into the R ecosystem are data.table, arrow, polars and duckdb. All of these are available for Python as well. Each of these carries with it its own interface and learning curve. duckdb, for example is a dialect of SQL, an entirely different language so our dplyr code above has to look like this in SQL: S. <https://www.r->

bloggers.com/2024/04/the-truth-about-tidy-wrappers-3/ Technische Lösungsansätze.

1.2.4 Hoch-performante Datenverarbeitungsmethoden

Als Desktopanwendung konzipiert ist R nicht für hoch-performante Auswertungen von Big Data bekannt. Wie unsere Untersuchung zeigen wird, beansprucht R nativ übermäßige Systemressourcen, um die Nutzerfreundlichkeit zu erhöhen. Dadurch dass R Open Source ist ändern dies jedoch diverse Entwicklerteams weltweit und stellen R Zusatzfunktionen in Form von R-Paketen zur Verfügung die in R hoch-performante Auswertung großer Datenmengen ermöglichen.

- › R darüber hinaus vermehrt hoch-performante Analysetools, die sich ständig verbessern
- › ermöglichen sehr schnelle Verarbeitung von Daten, mit einem sehr hohen Gesamtvolumen, das sogar den verfügbaren RAM übersteigt.
- › sollte möglichst leicht nutzbar sein, nativ in R ohne viele Abhängigkeiten (organisatorische Einschränkungen)

1.3 Umsetzung im StBA und FDZ

-
- › möglichst leicht nutzbar und gewohnt/verbreitet -> R+dpplr
 - › wechselnde Nutzende (Forscher) unterschiedlicher Fachbereiche mit unterschiedlichen Analytischen und technischen Kenntnissen
 - › stabil
 - › schnell, optimale Nutzung vorhandener GWAP Zeit und KDFV Zeitraum
 - › ressourcensparend (RAM Problematik)
 - › möglichst leicht nutzbar mit den vorhandenen Systemen und organisatorischen Strukturen ergibt Anforderungen
 - › hohe-performanz bereits mit R Grundlagenwissen
 - › minimale Anforderungen an zsl. Software
 - › NeSt Förderung, Datenprodukterstellung, Bereitstellung der FDZ auch technischen Infrastruktur und Knowhow der effizienten Nutzung
 - › Bereitstellung des OSS seit Nov. 2025
 - › Vorbereitend Exploration und Beratung in geeigneten Äußerst effizienten Methoden -> Ergebnisse in Echtzeit
 - › Szenario FDZ GWAP Besuch, statt KDFV, sofort Ergebnisse
 - › Diese Arbeit

- › Modernisierung der amtl. Stat, FDZs -> Zugangswege, Kapazitäten, ...
- › Technische Weiterentwicklung, stärkere Hardware, leichtere Bereitstellung, virtualisierung
- › Schnelle Weiterentwicklung von Open-Source Software, R, div. Packages, e.g. Verweis auf Changelog von Arrow, Polars

1.4 Diese Arbeit

Ausbreitung von R - gleich die richtige Technologie auswählen und einsetzen. Aber welche ist die "richtige"? Was für Unterschiede (Vorteile / Nachteile) haben die Technologien. Dies will dieser Artikel im Falle des BTP untersuchen. Kontrollierte Benchmark und weitere (qualitative) Aspekte, wie Userexperience.

Zielgruppe: alle Datenanalytiker mit rudimentären R-Kenntnisse, aber breit, FDZ, amtl. Stat,

Wir fokussieren uns auf folgende zentrale Forschungsfragen:

1. Methodische Effizienz: Wie unterscheiden sich verschiedene statistische Verfahren hinsichtlich ihrer Rechenzeit und Speicheranforderungen bei gleichbleibender Ergebnisqualität?
2. Skalierbarkeit: Welche Verfahren zeigen die beste Performance bei wachsenden Datenmengen, und wo liegen die kritischen Grenzen?
3. Praktische Anwendbarkeit: Welche Infrastrukturanforderungen stellen moderne Auswertungsmethoden an Forschungsdatenzentren?

2

Anwendungsfall Business-Tax-Panel

2.1 Datengrundlage

Das Business-Tax-Panel kombiniert die Angaben aus verschiedenen Ertrags- sowie Umsatzsteuerstatistiken im Quer- und Längsschnitt. Verfügbar sind Informationen aus den folgenden Statistiken: Gewerbe-, Körperschaftsteuer, Umsatzsteuer-Voranmeldung und -Veranlagung, Statistik über die Personengesellschaften und Gemeinschaften, Einnahmenüberschussrechnung und einige Merkmale aus dem Statistischen Unternehmensregister. Insgesamt deckt der Forschungsdatensatz eine Vielzahl an Anal-

ysemöglichkeiten, wie zum Beispiel Analyse von Anpassungsreaktionen oder Verteilungsanalysen, die für die evidenzbasierte steuerpolitische Entscheidungen nötig sind, ab.

Für die vielfältigen Analysewünsche der Forschenden, der damit einhergehenden Dokumentation des Datensatzes in den Metadatenreports (!hier Fußnote für MDR - siehe Deskriptive Eckdaten 1.) des FDZ, und den Auswertungsbedarf des Fachbereiches ist der Datensatz möglichst wenig beschränkt worden und dadurch ressourcenintensive. Anstelle einer Stichprobe wurden die zugrundeliegenden Vollerhebungen verwendet. Die erste Version des BTP (2013 bis 2019) besteht aus ca. 67 Millionen Beobachtungen. Mit der Aktualisierung um das Berichtsjahr 2020 wird die Zahl der Beobachtungen sich auf ca. 78 Millionen erhöhen. Auch der Merkmalsumfang von zurzeit über 2.700 Merkmalen wird durch Erweiterung von Berichtsjahren steigen.

Bereits aktuell und insbesondere durch die regelmäßige Erweiterung um Berichtsjahre steht der Fachbereich sowie das FDZ vor der Herausforderung den hohen Bedarf an Speicherkapazität, Arbeitsspeicher und Prozessorleistung zu decken. Daher wird das BTP als Anwendungsfall herangezogen

2.2 Auswertungsbedarfe

Um den Auswertungsbedarf des Fachbereichs und des FDZ abzubilden wird die Tabelle zur Häufigkeitsverteilung der Beobachtungen je Jahr und Steuerstatistik (FDZ, 2024 -> IN QULLEN aufnehmen!) verwendet. Im Fachbereich ergibt sich zusätzlich der Bedarf die Daten je nach Statistik und Tabelle zu bearbeiten. Auch die Forschenden bearbeiten die Daten um sie für die jeweilige Analyse aufzubereiten. Daher wird die Datenbearbeitung und anschließende Analyse als zweiter Anwendungsbedarf getestet.

Die Körperschaftsteuerstatistik zeigt über die Jahre eine Zunahme der Steuerpflichtigen mit Verlustvortrag im jeweiligen Berichtsjahr (GENESIS Code 73211-0002). Für den zweiten Anwendungsfall wird das Vorliegen eines Verlustvortrages im jeweiligen Berichtsjahr als versucht anhand verschiedener Einflussfaktoren zu erklären. Anzunehmen ist, dass Personalkosten den Verlustvortrag erhöhen können, daher wird die Zahl der Sozialversicherungspflichtig Beschäftigten sowie die Summe der Löhne und Gehälter als erklärende Variable verwendet. Der jeweilige Gesamtbetrag der Einkünfte und die abgezogenen Spenden können ebenfalls den Verlustvortrag beeinflussen. Um den Internationalisierungsgrad des Unternehmens zu erfassen wird ein Dummy für aufgenommen der Anzeigt, ob das Unternehmen auslandskontrolliert ist.

2.2.1 Deskriptive Eckdaten

1. deskriptive Eckdaten, für BTP als Panel im Quer- und Längsschnitt: Fallzahl pro Statistik und Jahr (s.MDR Produkt S. 9f https://www.forschungsdatenzentrum.de/sites/default/files/btp_2013-2019_on-site_mdr-prod.pdf)

Kennzahlen um inhaltlose Testdaten zu generieren werden folgende Eckdaten benötigt und im nächsten BTP berücksichtigt:

- › Befüllung
- › Statistische Eckdaten univariate (Quantile),
- › ggf. multivariate (gemeinsame Verteilung)

Exemplarisch, neues BTP beinhaltet dies. Regelmäßige Updates beschleunigen.

2.2.2 Regressionen

2. Verlustvorträge¹ (s. Vortrag NeSt) als Indikator für ... und Einflussgrößen auf Verlustvorträge, für Vermutung von Einfluss der Unternehmensgröße (großes Gesamtvolumen, Löhne, Spenden, tätige Personen; Auslandskontrolle oder WZ) auf positive Verlustvorträge.

2.3 Technische Spezifikationen

AK: Habe ich im Bereich Datengrundlage integriert.

Für die vielfältigen Analysewünsche der Forschenden, den Auswertungsbedarf des Fachbereiches bspw. für Sonderauswertungen und der Erstellung des Metadatenreports des Forschungsdaten-zentrums ist der Forschungsdatensatz konzipiert. Für die Abdeckung aller Anforderungen ist der Datensatz möglichst wenig beschränkt worden und dadurch ressourcenintensive. Der damit einhergehende hohe Bedarf an Speicherkapazität, Arbeitsspeicher und Prozessorleistung stellt sowohl im Fachbereich als auch im Forschungsdaten-zentrum eine Herausforderung dar.

Für die vielfältigen Analysewünsche der Forschenden, den Auswertungsbedarf des Fachbereiches bspw. für Sonderauswertungen und der Erstellung des Metadatenreports des Forschungsdaten-zentrums ist der Forschungsdatensatz konzipiert. Für die Abdeckung aller Anforderungen ist der Datensatz möglichst wenig beschränkt worden und dadurch ressourcenintensive. Der damit einhergehende hohe Bedarf an Speicherkapazität, Arbeitsspeicher und Prozessorleistung stellt sowohl im Fachbereich als auch im Forschungsdaten-zentrum eine Herausforderung dar.

- › Technische Herausforderung:

¹Vortrag Annette 2024 JK

- › effiziente und verständliche Speicherung
- › Herausfiltern großer Datenmengen irrelevanter Merkmale
- › Umfang über verfügbaren Arbeitsspeicher
- › Besonders breit mit 3000 Merkmalen, 69 Mio. Beobachtung, sodass zeilenbasierte Formate problematisch sind.
- › Technische Herausforderung:
 - › effiziente und verständliche Speicherung
 - › Herausfiltern großer Datenmengen irrelevanter Merkmale

3

Technische Infrastruktur

Womit wir arbeiten können.

3.1 Allgemein

- › abgeschottete, innerhalb der eigenen Infrastruktur

3.2 SAS Server

3.3 StBA R-Server

Intern ist R in größeren Kapazitäten nutzbar und Stata nur lokal.

- › 10 Server á
 - › 1 TB RAM
 - › 96 Kerne
 - › 2 GPUs mit insg. 96 GB VRAM

Bereitstellung von Paketen und organisatorische Einordnung. Veränderung der Infrastruktur langwierig, Beschaffung via Beschaffungsamt etc. -> wir müssen für die Zukunft planen und umsetzen.

3.4 FDZ OnSite-Server

StBA R-Server mit noch größeren Kapazitäten und grafischen Rechenbeschleunigern.

Neu seit November 2025 steht der sog. OnSite-Server im FDZ Bund allen OnSite Nutzungen bereit – jeweils in Stata und R via KDFV und an den GWAP. Zugriff zu Analyseservern in umfangreichen Kapazitäten.

In FDZ Bund Für Stata (3 Server) oder R (6 Server) in KDFV oder GWAP stehen jeder Nutzung zur Verfügung:

```

::: | Komponente | Umfang | |-----| |-----|
| Arbeitsspeicher | bis zu 512 GB | | Kernanzahl | 16 | |
CPU-Geschwindigkeit | 3.1 GHz | :::
  
```

- › schnelle Direktverbindung zu Netzwerkspeicher
- › Fußnote RAM in R 128 GB kann erweitert werden.

4

Datenverarbeitungsmethoden

Wir betrachten in diesem Artikel die Performanz sog. Datenverarbeitungsmethoden, d.h. Softwarelösungen, die Daten einlesen, modifizieren, aggregieren, auswerten oder analysieren. Das Schreiben von Daten wird in unserer Untersuchung ausgeklammert, da es sich bei den Veröffentlichungen des Statistischen Bundesamtes oder den Outputs der Wissenschaft im FDZ um kleine Tabellen handelt, die i.d.R. keine große Performanz erfordern. Wir vernachlässigen Spark, Datenbanken und weitere Technologien, die zusätzliche Einrichtung erfordern und nicht direkt als R-Package genutzt werden können.

4.1 Anforderungen an Datenverarbeitungsmethoden

- › Performanz und Nutzererfahrung auf dem aktuellen Stand der Technik
- › leicht einzurichten auch in den abgeschotteten System der amtlichen Statistik (tlw. langwierig und schwierig), d.h. wenig Abhängigkeiten und unabhängig von Internet bzw. Cloud betreibbar.
- › langfristig stabil und gut unterstützt
- › leicht nutzbar, gut dokumentiert, gutes Schulungsangebot

Die Analyse großer Datensätze wie des in der FDZ-Umgebung stellt besondere Anforderungen an die verwendeten Werkzeuge. Traditionelle Ansätze (CSV-Dateien, Base R) stoßen bei dieser Datengröße an ihre Grenzen. Moderne spaltenorientierte Technologien lösen dieses Problem indem sie erlauben, nur relevante Variablen bei Bedarf zu einzulesen.

4.2 Sachstand

4.2.1 SAS und Stata

- › Hauptanalysewerkzeuge sind bisher:
 - › im StBA SAS 9.4 M8, EG

- › im FDZ zsl. Stata
- › Stata
 - › bisher: V.15 MP-12 (KDFV) und Stata 19 SE lokal (GWAP).
 - › neu im OSS in KDFV/GWAP V. 19 gleichermaßen in großen Systemkapazitäten.

4.2.2 Empfehlung des FDSZ der deutschen Bundesbank

- (1) hat den Spezialfall von in-memory Auswertung betrachtet mit den folgenden Ergebnissen:
 - › R zeigt große Performanzvorteile gegenüber Stata für FDZ Aufgaben: “Note that using parquet and R reduces the computing time compared to the optimised Stata approach by 65.1% from 77.6 to 27.1 seconds”
 - › zu betrachten ist die Gesamtzeit (d.h. Rechenzeit + Entwicklungszeit)
 - › vorhandene Erfahrung und Knowhow (bspw. in Stata) relativiert die Performanzgewinne in R. Zu beachten sind hohe Debugging Aufwände an den GWAPs der FDZ (kein Internetzugriff)
 - › I.d.R. muss in der Entwicklung Code mehrfach ausgeführt werden, sodass sich die Laufzeit multipliziert (Wickham&Grolemund 2016).
 - › Die u.g. Parquet-Dateien werden bereits standardmäßig im FDSZ angeboten.
 - › Variablenselektion hervorgehoben. Bot Beschleunigung von 39.9% in R und 33.9% in Stata

4.3 Analysewerkzeug R

Der Einsatz von R wächst stetig mit aktuell über 200 aktiven Nutzenden im StBA und FDZ.

- › R ist die native Programmiersprache von Statistiker/-innen und Daten-affinen Programmierer/-innen. Frei verfügbar und leicht einzurichten. Somit weit verbreitet, insb. an Universitäten.
- › R ist Open Source und wird ständig weiterentwickelt (aktuell in Version 4.5 verwendet, jährliche Major Releases).
- › Eine weltweit aktive Community löst Probleme zeitnah und ergänzt stetig Funktionalitäten in Form von sog. R-Packages.
- › Bietet nativ bereits viele Datenverarbeitungsmethoden, die jedoch durch diese R-Packages ganz neue Level an Nutzerfreundlichkeit, Funktionsumfang und Performanz erreichen.

4.4 Klassische Methoden in R

4.4.1 Base R

- › Standardmäßige Basisfunktionen in R.
- › Grundlage/einstieg, weder sonderlich anschaulich noch sonderlich performant -> Packages überlassen
- › Vorteile: Einfach, weit verbreitet, keine zusätzlichen Abhängigkeiten
- › Nachteile: Langsam bei großen Daten, hoher Speicherverbrauch, alle Daten müssen in RAM passen
- › Empfehlung: Zweckdienlich für Einsteiger oder Gelegenheitsnutzer für ganz kleine Anwendungen oder falls gar keine Abhängigkeiten in Form von Pkg erlaubt sind. Ansonsten...

4.4.2 Data.table

- › {data.table} in den meisten Fällen die performanteste klassische DVM. An die Syntax an base-r angesiedelt und nur hier verwendet, spezielles Wissen notwendig.
- › Vorteile: Sehr schnell für In-Memory-Operationen, ausgereift, kompakte Syntax In teilen der Community sehr beliebt
- › Nachteile: Alle Daten müssen in RAM passen, steile Lernkurve, keine Out-of-Core-Unterstützung.
- › Empfehlung: Gute Alternative wenn Datensatz in RAM passt und keine Parquet-Integration benötigt wird

4.4.3 Tidyverse

Tidyverse ist ein Ökosystem von Packages zur Datenverarbeitung, das für besonders hohe Lesbarkeit des Codes bekannt ist. Dazu dient eine eigenen Programmiersyntax, sog. {dplyr}-Syntax, die den Anspruch hat menschlicher Sprache abzubilden. Das R-Package {dplyr} ist die Datenverarbeitungsgrammatik innerhalb Tidyverse, die anhand eines Beispiels in der folgenden Tabelle veranschaulicht wird

[Tabelle Beispiel Dplyr]

Diese Syntax ist bei einem Teil der R-Community so beliebt, dass sie vielen anderen Packages ergänzt wurde. Bspw. für {data.table} setzen dies die Packages {dtplyr} oder {tidytable} um Wie im Falle von {dtplyr} kann die Übersetzung zu {dplyr} jedoch die Performanz verschlechtern.¹²

4.5 Best Practices in R

Ab mittleren Datenmengen (relativ zu CPU und RAM) sind ausgewählte Best Practices in R:

¹²S. <https://www.r-bloggers.com/2024/04/the-truth-about-tidy-wrappers-3/>

- › Variablenselektion: Beim Einlesen von DatenAuswahl der benötigten Variablen in der Einlesefunktion ist wesentliche Best-Practices (besonders für klassische Methoden, da dies das Risiko für RAM-Abbrüche und Wartezeiten deutlich reduziert). Das Einlesen zunächst aller Daten (ggf. mit Variablenselektion zu einem späteren Zeitpunkt) verursacht unnötige Wartezeiten, Ressourcenbelegung und kann zu Abbrüchen führen.
- › Datenaufteilung: Wenn der Arbeitsspeicher nicht ausreicht, um die benötigten Daten einzulesen, bietet eine Aufteilung auf mehrere RAM-Gerechte Datenpakete helfen. Für klassische Methoden kombiniert mit der mehrfachen Variablenselektion. Die folgenden hoch-performanten Techniken, kommen auch direkt mehreren Dateien nutzen, ohne manuell die Datensätze zusammenzuführen.

4.6 Hoch-performante Methoden in R

Wir sprechen in diesem Artikel vereinfacht von einer hoch-performanten Methode, sobald die betrachtete Datenverarbeitungsmethode in der Lage ist, Datenmengen überhalb des verfügbaren Arbeitsspeichers flexibel und effizient zu nutzen. SAS erfüllt den Großteil dieser Definition – lediglich die Effizienz lässt sich deutlich steigern.

Um Datenauswertung auf höhere Datenmengen skalieren zu können ist ein Paradigmenwechsel von der “vollständigen Verarbeitung im RAM” zu der Auslagerung aus dem RAM notwendig. Vollständig im RAM sind Daten zwar sehr schnell und einfach zu nutzen, jedoch beansprucht der Transport in den RAM (Einlesen) einen Hauptteil der Laufzeit und der verfügbare RAM reicht i.d.R. nicht für größere Datenmengen. Die nachfolgenden Technologien sind auch in der Lage Daten überhalb des RAMs zu verarbeiten. Durch moderne Hardware und Software kann dies sogar sehr schnell erfolgen.

4.6.1 Apache Parquet

- › Datenformat, spaltenbasiert, komprimiert, ...
- › tba - s. Vortrag

4.6.2 Apache Arrow

- › R-package, C++ basiert, erlaubt Parallelisierung, Datenaufteilung, Lazy-Computations, Datenformat im RAM passend zu Parquet
- › tba - s. Vortrag

4.6.3 DuckDB

- › R-Package, in-memory DB, ...
- › tba - s. Vortrag

4.6.4 Polars

- › an Python-angelehnte Syntax
- › tba
- › Benchmark des Polars Entwicklerteams^{|3}

4.7 Package-Versionen

Die auf den Servern des StBA und FDZ verfügbaren Packageversionen lassen sich aus organisatorischen Gründen nicht flexibel ändern, da die Genehmigung und Einrichtung neuer Packages nur auf Antrag durch unser R-Betriebsteam erfolgt (i.d.R. innerhalb von 1-2 Tagen). Die Package-Versionen, die zum Zeitpunkt des in ?@sec-benchmark dargestellten Performanz-Vergleiches verfügbar waren, können Tabelle Tabelle 1 entnommen werden.

5

Performanzvergleich

5.1 Versuchsaufbau

Um zwischen den in Abschnitt Kapitel 4 vorgestellten Datenverarbeitungsmethoden abzuwägen, haben wir deren Performanz in einem systematischen Vergleich der Performance auf dem SAS-Server des Statistischen Bundesamtes und den neuen OnSite R- und Stata-Servern des FDZ gemessen. Weiterführende Performanzmessung sowie der vollständig reproduzierbare Code sind auf Opencode verfügbar^{|4}.

Für die Untersuchung wurden simulierte Einzeldaten in verschiedenen Größen (0,1%/1%/10% von den insgesamt 80 Mio. Beobachtungen des BTP) betrachtet. Sie wurden aus öffentlich verfügbaren Informationen generiert, um die wesentlichen Strukturen des BTP für unsere Analyse künstlich nachzubilden. Abgrenzend zu den im FDZ bereitgestellten Datenstrukturfiles wurden die Testdaten nicht aus echten Mikrodaten abgeleitet. Der simulierte Datensatz ist ausschließlich für technische Testzwecke der nachfolgenden Anwendungsfälle bestimmt:

1. Fallzahlen (pro Statistik und Jahr),
2. Regression (Einflussfaktoren auf Verlustvorträge).

Um eine zuverlässige Performanz-Messung zu erhalten, wurde jede Datenverarbeitungsmethode dreifach ange-

^{|3} <https://ddotta.github.io/cookbook-rpolars/benchmarking.html>

^{|4} www.opencode.de/URL-To-Be-Announced.

Tabelle 1

Versionen verfügbarer R-Packages

Paket	Version
{data.table}	1.17.8
{tidyverse}	tba
{vroom}	tba
{arrow}	20.0.0.2
{duckdb}	1.3.2
{polars}	1.0.1

wandt. Der Vergleich erfolgt anhand der mittleren Messung der folgenden Zielgrößen:

1. Arbeitsspeicher der Auswertung,
2. Laufzeit der Auswertung (real verstrichene Zeit),
3. Festplattenspeicher der verwendeten Daten.

Die Zielgrößen sind in dieser Reihenfolge zu priorisieren, da ein übermäßiger Arbeitsspeicherverbrauch zu schwerwiegenden Abbrüchen führen kann, während hohe Laufzeiten dennoch zu einem erfolgreichen Ergebnis führen können. Festplattenspeicher ist ausreichend vorhanden, aber unnötige Belegung sollte vermieden werden.

Feine Abstufungen der Zielgrößen sind für unsere Aufgaben nicht gleichermaßen relevant. Eine Methode, die die betrachteten Auswertungen in unter 10 Sekunden mit weniger als 4 GB Arbeitsspeicher durchführen kann, wird bereits als optimal bewertet. Weitere Optimierungen sind in diesem Fall nicht erforderlich. Falls bereits die gewünschte Performanz erreicht wurde, rückt die Reduktion des Entwicklungsaufwand in den Vordergrund. Entsprechend sind Aspekte wie einfache Anwendbarkeit und Nachvollziehbarkeit – selbst für unerfahrene Nutzende – ausschlaggebend.

5.2 Vergleichswert in SAS und Stata

Klassisch werden die betrachteten Auswertungsaufgaben im Statistischen Bundesamt hauptsächlich mit SAS und im FDZ mit Stata gelöst. Um die nachfolgenden Ergebnisse einzuordnen, haben wir die Performanzmessungen für 1% der simulierten BTP-Daten (etwa. 800.000 Beobachtungen) in SAS und Stata durchgeführt.

Die Ergebnisse in Tabelle 2 zeigen, dass der umfangreiche Arbeitsspeicher des FDZ OnSite-Servers nicht ausreicht, um das ganze BTP in Stata einzulesen, sodass zwingend mit Variablenselektion gearbeitet werden muss. SAS zeigt seine Stärke anhand der geringen Beanspruchung des Arbeitsspeichers, benötigt aber mit etwa 2,3 Minuten pro Auswertung die doppelte Laufzeit gegenüber Stata.

5.3 Kleiner Vergleich zwischen R, SAS und Stata

Für 1% der simulierten BTP Daten, reduzieren die R-Datenverarbeitungsmethode alle Zielgrößen gegenüber SAS und Stata erheblich (siehe Tabelle 3 und Tabelle 4). Selbst klassische R-Methoden sind um den Faktor 7 schneller und benötigen nur 33 % des Festplattenspeichers. {polars}, {duckdb} und {arrow} lösen die betrachteten Auswertungen sogar

- › in unter 2 Sekunden (27-fach schneller),
- › mit unter 300 MB Arbeitsspeicher – {duckdb} und {polars}[⁵polars-ram] sogar mit unter 5 MB (10-fach weniger)⁵ –
- › und nur mit 5 GB Festplattenspeicher (6-fach weniger gegenüber SAS und Stata).

Unter den klassischen R-Methoden bietet {data.table} die beste Performanz. Dabei ist wesentlich zu beachten, dass die Einlesefunktion `fread` direkt die relevanten Variablen auswählt. Dadurch lassen sich unsere Auswertungen um einen Faktor 3 beschleunigen und vor allem der Arbeitsspeicher um einen Faktor 1.000 reduzieren.

Alle hoch-performanten Methoden sind dermaßen effizient, dass die Datenmenge von 800.000 Beobachtungen nicht mehr ausreicht, um zwischen den besten Methoden zu differenzieren. Daher erhöhen wir im nächsten Experiment die Datenmenge auf 8.000.000 Beobachtungen (10% BTP).

⁵Lediglich in der Arbeitsspeicherbeanspruchung, ist SAS deutlich besser als klassische R-Methoden. Gegenüber hoch-performanten R-Methoden benötigt SAS jedoch den 10-fachen Arbeitsspeicher.

⁶{arrow} benötigt mit 274 MB deutlich mehr Arbeitsspeicher als {polars} und {duckdb}, aber kommt dennoch mit minimalen Entwicklungsumgebungen aus, bspw. einem standardmäßigen Laptop.

Tabelle 2

Baselines in SAS und Stata (anhand 1% des simuliertes BTP)

Software	Anwendung	Arbeitsspeicher	Laufzeit	Festplattenspeicher
SAS	Fallzahl	65 MB	2.4 Min.	33 GB
	Regression	7 MB	2.8 Min.	33 GB
Stata	Fallzahl	33 GB	55,2 Sek.	32 GB
	Regression	33 GB	55,8 Sek.	32 GB

Tabelle 3

Performanz Messungen für die Fallzahlberechnung anhand 1% des BTP

Package	Dateiformat	Optimierung	Arbeitsspeicher	Laufzeit	Festplattenspeicher
{polars}	Parquet	-	3,3 MB	1,0 Sek	4,9 GB
{duckdb}	Parquet	-	4,8 MB	1,5 Sek	4,9 GB
{arrow}	Parquet	Variablenauswahl	273,7 MB	1,7 Sek	4,9 GB
{data.table}	CSV	Variablenauswahl	42,9 MB	2,5 Sek	13,0 GB
{arrow}	Parquet	Datenaufteilung (gleichmäßig)	229,7 MB	2,8 Sek	4,9 GB
{arrow}	Parquet	-	272,8 MB	2,8 Sek	4,9 GB
{arrow}	Parquet	-	230,4 MB	3,8 Sek	4,9 GB
{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	229,9 MB	3,9 Sek	4,8 GB
{data.table}	CSV	-	33,7 GB	7,4 Sek	13,0 GB
{data.table}	CSV	Datenaufteilung (Berichtsjahr)	50,4 GB	13,6 Sek	10,5 GB

Tabelle 4

Performanz Messungen für die Regressionsberechnung anhand 1% des BTP

Package	Dateiformat	Optimierung	Arbeitsspeicher	Laufzeit	Festplattenspeicher
{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	529,7 MB	3,8 Sek	4,8 GB
{dplyr}	CSV	Variablenauswahl	154,8 MB	13,2 Sek	13,0 GB

5.4 Größere Datenmengen in R

Auch für 10 % der simulierten BTP-Daten, kann R die beiden betrachteten Auswertungen in Echtzeit mit minimalem Arbeitsspeicher beantworten (siehe Tabelle 5 und Tabelle 6). Die Auswertungsmethoden mit der höchsten Performanz nutzen alle das {parquet} und erreichen:

1. {arrow} benötigt nur 4,7 Sekunden und 230 MB Arbeitsspeicher,
2. {duckdb} benötigt nur 5,1 Sekunden und 4,7 MB Arbeitsspeicher.

[tba: Plot der Performanz unterschiede]

Unerwarteterweise ist die Laufzeit von {polars} für diese Datenmenge mit 1,2 Minuten weit abgeschlagen, obwohl das gleiche Auswertungsskript für kleinere Datenmengen immer die geringste Laufzeit aufwies. Da {polars} das jüngste der betrachteten R-Packages ist, vermuten wir Performanzprobleme in der vorliegenden Version 1.0.1⁷. Zudem hat es noch größere Entwicklungsaufwände beansprucht, da der an Python angelehnte Syntaxstil deutlich von üblicher Programmierung in R abweicht. Öffentliche Hilfestellung bezieht sich hauptsächlich auf Python (oder Rust), was sich in den Antworten der KI-Chatassistenten widerspiegelt.

Klassische Methoden kommen bei der betrachteten Datenmenge bereits an ihre Grenzen. Falls in {data.table} unbeachtet der vollständige Datensatz eingelesen wird, werden in unserem Anwendungsfall die verfügbaren 512 GB Arbeitsspeicher vollständig beansprucht. Schon wenn klassische Methoden auf Datenmengen von ca. 25-33% des verfügbaren Arbeitsspeichers angewandt werden, ist somit deutlich mehr Erfahrung der Nutzenden notwendig, um die relevanten Variablen manuell geschickt zu selektieren unter Beobachtung des Arbeitsspeicherverbrauchs.

Somit kommen wir insgesamt zu dem Ergebnis, dass {arrow} kombiniert mit {parquet} für die Bewältigung unserer Aufgaben die beste Datenverarbeitungsmethode ist, da die Methodik hervorragende Performanz und zugleich hohe Nutzerfreundlichkeit bietet. Im Detail haben uns der folgenden Mehrwerte überzeugt:

1. Für die relevanteste Datenmenge von 8 Mio. Beobachtungen zeigte {arrow} die geringsten Laufzeiten unter 5 Sekunden, was der Fachstatistik Antworten auf Sonderanfragen in Echtzeit ermöglicht und der Wissenschaft alle denkbaren explorativen Analysen auszuweiten.

⁷Das R-Package {polars} Version 1.0.1 war nur der erste Minor Release nach einer kompletten Überarbeitung. Inzwischen sind 5 neuere Major Releases mit diversen Performanz-Verbesserungen verfügbar.

2. auch die Nutzererfahrung gefiel uns mit {arrow} am besten und somit waren die einhergehenden Entwicklungsaufwände gegenüber den Anderen Methoden am geringsten.
3. {arrow} verwendet die anschauliche {tidyverse} Syntax nativ. Vorhandener Code lässt sich zum Großteil änderungsfrei und ohne Performanzverluste auf {arrow} übertragen. {duckdb} kann bei Kenntnissen in SQL zu bevorzugen sein und {polars} mit Erfahrungen in Python.
4. Beide Anwendungen ließen sich in unter 20 nachvollziehbaren Zeilen in {arrow} programmieren.⁸
5. Obwohl nicht alle Features aus {tidyverse} für {arrow} verfügbar sind, ließ sich bisher immer eine Lösung finden, um die gewünschte Auswertung umzusetzen, bspw. durch Kombination mit {duckdb} oder andere Funktionsaufrufe.
6. {arrow} spart ausreichend Arbeitsspeicher (mit Verbrauch unter 1 GB) (tba: Fußnote zu duckdb/polars). Der Arbeitsspeicherverbrauch von {arrow} ist in unserer Auswertung nahezu konstant abhängig von der Datenmenge, sodass {arrow} leicht auf noch größere Datenmengen skalieren kann
7. Dadurch das {arrow} die Nutzung auch von mehreren {parquet} Dateien unterstützt spart gegenüber CSV mind. 50% der Festplatte (für das reale BTP sogar 80%+) und ermöglicht schnelle Nutzung auch von Datenmengen überhalb des verfügbaren Arbeitsspeichers.

[tba: Plot RAM-Bedarf abhängig von der Datenmenge]

6

Ergebnis für das vollständige BTP

Anwendung der besten Methode auf die echten Daten des vollständige BTP ergibt:

- > Performanz von {arrow} Fallzahlen (ein paar Sekunden) und Regression (Sekunden)
- > leicht lesbar in {arrow}

6.1 Ergebnis

[Ergebnistabelle Fallzahl, ggf. als Heatmap]

-> Zukünftige Nutzung für MDR wird umgesetzt.

[Model Summary?]

⁸www.opencode.de/URL-To-Be-Announced.

Tabelle 5

Performanz Messungen für die Fallzahlberechnung anhand 10% des BTP

Package	Dateiformat	Optimierung	Arbeitsspeicher	Laufzeit	Festplattenspeicher
{arrow}	Parquet	Datenaufteilung (gleichmäßig)	229,9 MB	4,7 Sek	48,8 GB
{duckdb}	Parquet	-	4,7 MB	5,1 Sek	49,4 GB
{arrow}	Parquet	Variablenauswahl	702,1 MB	7,5 Sek	49,4 GB
{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	4,7 MB	11,7 Sek	48,1 GB
{arrow}	Parquet	-	230,4 MB	17,0 Sek	49,4 GB
{arrow}	Parquet	-	701,2 MB	20,6 Sek	49,4 GB
{data.table}	CSV	Variablenauswahl	427,5 MB	23,6 Sek	130,2 GB
{polars}	Parquet	-	3,3 MB	1,2 Min	49,4 GB
{data.table}	CSV	-	336,0 GB	2,2 Min	130,2 GB
{data.table}	CSV	Datenaufteilung (Berichtsjahr)	506,4 GB	5,0 Min	104,6 GB

Tabelle 6

Performanz Messungen für die Regressionsberechnung anhand 10% des BTP

Package	Dateiformat	Optimierung	Arbeitsspeicher	Laufzeit	Festplattenspeicher
{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	782,1 MB	5,2 Sek	48,1 GB
{dplyr}	CSV	Variablenauswahl	1,5 GB	1,9 Min	130,2 GB

6.2 Vergleich zu SAS, (Stata), Datatable

- › Ergebnis in SAS
- › (optional) Datatable ohne selektives Einlesen führt zu RAM Crash (RAM-Fehler?)
- › (optional) Datatable Sel.

Real world application unserer Ergebnisse auf das Echte BTP

Ergebnis für gesamten Datensatz

-> Größere Speicherreduktion, da das echte BTP mehr fehlende Werte enthält, als anhand der externen Daten angenommen.

7

Fazit

7.1 Kernaussage des Artikels

Wir empfehlen eine Datenhaltung im Parquet-Format und R incl. {arrow} + {parquet} (bei Bedarf {duckdb}, {polars}) zu erproben und zu etablieren! Denn unsere Untersuchung demonstriert ganz neue Möglichkeiten, analytische Fragestellungen anhand großer Datenmengen in Echtzeit zu beantworten.

7.2 Auswirkung auf IT-Infrastruktur und Beratung

- › Fokus auf Hardware und Software mit größtem Mehrwert (weniger RAM und R anstatt Spark, GPUs, Datenbanken, Cloud, ...)
- › Fokus auf Maintainance und Patching von R, Parquet und hier genannte Packages {arrow}, {duckdb}, {polars}
- › Etablierung dieser Softwarelösungen kann langfristig...
 - › die Hardwareanforderungen reduzieren
 - › die Analysesoftwarevielfalt verschlanken, somit Beschaffungen einsparen (besserer Ausdruck?)
- › Schulungsangebot benötigt für “hoch-performante Auswertungen in R”
- › eigener Beitrag zu Open Source entscheidend, um die Etablierung zu fördern.

7.3 Auswirkungen auf die Statistikproduktion

- › Steigerung der Effizienz und Reaktionsgeschwindigkeit
- › (Vorsichtig!/? Annette, lieber weg oder rein?) Vereinfachung der Statistikproduktion, durch leicht nachvollziehbaren Code und Fokus auf Wissensaufbau in R
- › Aufbau eines Datenbestands in Parquet
- › Anwendung auf weitere Produkte
 - › Überarbeitung des BTP
 - › Mindeststeuer (oder?)
 - › DRG
 - › TPP 2

7.4 Auswirkungen auf die FDZ

- › Berücksichtigung in Mustersyntaxen und Nutzendenberatung im FDZ Bund. Teilen von Code-Snippets und Templates fördern.
- › mögliche Vereinfachung der Betreuung (Fokus auf R, Reduktion von Performanz- und Programmierproblemen)
- › Bereitstellung von Parquet in geeigneter Aufteilung empfohlen
- › Erprobung im FDZ Bund Vorbild für andere FDZ
- › Optimierung von Hardware und Software Angebot

7.5 Auswirkung auf die Wissenschaft

- › Verwendung von R bietet am FDZ Bund einen deutlichen Wettbewerbsvorteil in der emp. Forschung. Lediglich R ist (am GWAP und via KDFV) am FDZ Bund in der Lage große Datenmengen innerhalb von Sekunden zu analysieren und Datenmengen überhalb des verfügbaren Arbeitsspeicher, wie das BTP, ohne vorherige Variablenselektion auszuwerten.
 - › Vollmaterial kann statt Stichproben angeboten werden. Erleichtert die FDZ Betreuung und GWAP/KDFV-Verfügbarkeit
 - › mehr explorative oder komplexe Analysen sind in kürzerer Zeit möglich.
- › Dazu ist R als frei verfügbare Open-Source Software leicht zu lernen und {arrow} bietet hoch-performante Analysen selbst für R-Basiskenntnisse. Empfehlung an die emp. Wissenschaft, sich verstärkt mit R zu befassen.
- › Für analoge über-RAM-Verarbeitungen bietet Stata aktuell keine Lösung. SAS bietet bei weitem nicht hier gemessene Performanz von R. R hervorragende Möglichkeiten bietet Performanz und Anwenderfreundlichkeit zu übertreffen.
- › Weiteres Vorgehen: NeSt-Pilotprojekt. Aus dem realen Use Case Optimierung der Systemkonfiguration und Beratungsbedarfe identifizieren.

7.6 Schlussbemerkung

Die Analyse großer Datensätze in der amtlichen Statistik und den Forschungsdatenzen können von einem signifikanten Performanz-Boost profitieren, wenn die vorgestellten Werkzeuge adaptiert werden. Arrow, DuckDB, Polars und Parquet – bieten das Potenzial, die Effizienz erheblich zu steigern und neue Analysemöglichkeiten zu eröffnen.

Der Übergang erfordert jedoch eine koordinierte Anstrengung von Infrastrukturbetreibern, amtlicher Statistik, Forschungsdatenzentren und Forschenden. Die systema-

tische Wissensaufbau, Dokumentation und Verbreitung von Best Practices wird entscheidend für den Erfolg sein.

Die amtliche Statistik kann von diesen Entwicklungen in mehrfacher Hinsicht profitieren: schnellere Erkenntnisgewinnung, umfassendere Analysen und effizientere Ressourcennutzung. Dies trägt letztlich zur Stärkung der evidenzbasierten Politik- und Gesellschaftsberatung bei.

Anhang

Inhalte für die Veröffentlichung in Open Code.

Weitere Performancemessungen für kleinere Datenmengen.

Tabelle 7

Benchmarkergebnisse für Fallzahlen (kleine Stichproben des BTP)

Beob.	Package	Dateiformat	Optimierung	Arbeitsspeicher	Laufzeit	Festplattenspeicher
10.000	{polars}	Parquet	-	3,3 MB	0,4 Sek	492,6 MB
10.000	{data.table}	CSV	Variablenauswahl	4,4 MB	0,7 Sek	1,3 GB
10.000	{arrow}	Parquet	Variablenauswahl	230,7 MB	1,1 Sek	492,6 MB
10.000	{readr}	CSV	Variablenauswahl	9,3 MB	1,2 Sek	1,3 GB
10.000	{arrow}	Parquet	-	229,8 MB	1,6 Sek	492,6 MB
10.000	{duckdb}	Parquet	-	4,7 MB	2,9 Sek	492,6 MB
10.000	{data.table}	CSV	-	3,4 GB	3,6 Sek	1,3 GB
10.000	{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	229,9 MB	4,2 Sek	486,9 MB
10.000	{arrow}	Parquet	-	230,4 MB	4,6 Sek	492,6 MB
10.000	{data.table}	CSV	Datenaufteilung (Berichtsjahr)	5,1 GB	4,8 Sek	1,0 GB
10.000	{arrow}	Parquet	Datenaufteilung (gleichmäßig)	229,9 MB	7,1 Sek	483,5 MB
10.000	{readr}	CSV	-	1,7 GB	8,6 Sek	1,3 GB
10.000	{arrow}	CSV	-	27,4 MB	15,7 Sek	1,3 GB
10.000	{data.table}	CSV.GZ	-	4,7 GB	21,2 Sek	421,9 MB
10.000	{base}	CSV	-	9,7 GB	4,9 Min	1,3 GB
1.000	{data.table}	CSV	Variablenauswahl	0,6 MB	0,1 Sek	129,8 MB
1.000	{readr}	CSV	Variablenauswahl	2,7 MB	0,2 Sek	129,8 MB
1.000	{polars}	Parquet	-	3,3 MB	0,4 Sek	48,1 MB
1.000	{data.table}	CSV	-	341,8 MB	0,9 Sek	129,8 MB
1.000	{duckdb}	Parquet	-	4,7 MB	1,1 Sek	48,1 MB
1.000	{arrow}	Parquet	Variablenauswahl	226,2 MB	1,2 Sek	48,1 MB
1.000	{arrow}	Parquet	-	225,3 MB	1,4 Sek	48,1 MB
1.000	{arrow}	CSV	-	3,5 MB	1,5 Sek	129,8 MB
1.000	{data.table}	CSV.GZ	-	491,7 MB	2,7 Sek	42,1 MB
1.000	{data.table}	CSV	Datenaufteilung (Berichtsjahr)	510,9 MB	2,8 Sek	104,5 MB
1.000	{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	229,9 MB	2,9 Sek	53,5 MB
1.000	{arrow}	Parquet	-	230,4 MB	3,7 Sek	48,1 MB
1.000	{arrow}	Parquet	Datenaufteilung (gleichmäßig)	229,7 MB	4,0 Sek	50,5 MB
1.000	{readr}	CSV	-	197,4 MB	4,9 Sek	129,8 MB
1.000	{base}	CSV	-	713,4 MB	23,3 Sek	129,8 MB

Tabelle 8

Benchmarkergebnisse für Regression (kleine Stichproben des BTP)

Beob.	Package	Dateiformat	Optimierung	Arbeitsspeicher	Laufzeit	Festplattenspeicher
10.000	{dplyr}	CSV	Variablenauswahl	17,6 MB	1,3 Sek	1,3 GB
10.000	{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	459,3 MB	5,0 Sek	486,9 MB
10.000	{dplyr}	CSV	-	1,8 GB	10,8 Sek	1,3 GB
1.000	{dplyr}	CSV	Variablenauswahl	4,2 MB	0,3 Sek	129,8 MB
1.000	{dplyr}	CSV	-	206,9 MB	6,4 Sek	129,8 MB
1.000	{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	452,5 MB	6,8 Sek	53,5 MB

Literatur

Statistisches Bundesamt (2023). Qualitätshandbuch der amtlichen Statistik. Version 7.0. Wiesbaden. URL: <https://www.destatis.de>.