
Oliver Hauke

ist Mathematiker und IT-Referent im Kompetenzzentrum „Analyse und Auswertung“ des Statistischen Bundesamtes. Er verantwortet die Weiterentwicklung der technischen Infrastruktur des Forschungsdatenzentrums des Statistischen Bundesamts und berät das Netzwerk empirische Steuerforschung in effizienter Datenanalyse.

Annette Kristiansen

ist Ökonomin und Referentin im Referat „Unternehmenssteuern“ des Statistischen Bundesamtes. Sie beschäftigt sich mit der Zusammenführung der Unternehmenssteuerstatistiken und betreut Arbeiten für das Netzwerk empirische Steuerforschung.

EFFIZIENTE AUSWERTUNG DES BUSINESS-TAX-PANELS MITHILFE VON R

Oliver Hauke, Annette Kristiansen

🔑 **Schlüsselwörter:** Effiziente Analysen, R-Programmierung, Forschungsdaten, Unternehmenssteuerstatistik, Business-Tax-Panel, Netzwerk empirische Steuerforschung

ZUSAMMENFASSUNG

Das Forschungsdatenzentrum des Statistischen Bundesamtes baut seine technische Infrastruktur gezielt aus, um der Wissenschaft erweiterte Analysemöglichkeiten amtlicher Daten bereitzustellen. Seit November 2025 steht Forschenden exklusiver Zugang zu diesen erweiterten Systemressourcen in R und Stata zur Verfügung. R-basierte Tools – insbesondere Apache Arrow, Parquet und DuckDB – ermöglichen es, gängige Analysen großer Forschungsdatensätze in Echtzeit auszuführen. Am Beispiel des Business-Tax-Panel (2013 bis 2019) werden die erzielbaren Effizienzgewinne bei der Auswertung umfangreicher steuerstatistischer Daten im Rahmen des Netzwerks empirische Steuerforschung demonstriert.

🔑 **Keywords:** Efficient analysis – R programming – research data – corporate tax statistics – Business Tax Panel – empirical tax research network

ABSTRACT

The Research Data Centre at the Federal Statistical Office is strategically expanding its technical infrastructure to provide researchers with enhanced analytical capabilities for official data. Since November 2025, researchers have had exclusive access to these extended system resources in R and Stata. R-based tools – particularly Apache Arrow, Parquet, and DuckDB – enable real-time analysis of large research datasets. Using the Business Tax Panel (2013–2019), this paper demonstrates the achievable efficiency gains in analysing large-scale tax statistics within the empirical tax research network.

Inhaltsverzeichnis

1	Datenverarbeitungsmethoden	5
1.1	Anforderungen an Datenverarbeitungsmethoden	5
1.2	Sachstand	5
1.2.1	SAS und Stata	5
1.2.2	Empfehlung des FDSZ der deutschen Bundesbank	5
1.3	Analysewerkzeug R	6
1.4	Klassische Methoden in R	6
1.4.1	Base R	6
1.4.2	Data.table	6
1.4.3	Tidyverse	6
1.5	Best Practices in R	6
1.6	Hoch-performante Methoden in R	7
1.6.1	Apache Parquet	7
1.6.2	Apache Arrow	7
1.6.3	DuckDB	7
1.6.4	Polars	7
1.7	Package-Versionen	7

Dokument-Metadaten

Titel: EFFIZIENTE AUSWERTUNG DES BUSINESS-TAX-PANELS MITHILFE VON R
Autoren: Oliver Hauke, Annette Kristiansen
Veröffentlichung: WISTA 01/2026
Erstellungsdatum: 6. Dezember 2025 um 16:02 Uhr

Dokumentstatistik

Abschnitt	Wörter	Zeichen	Fußn.	Quellen	Vorgabe
Insgesamt	1 092	8 589	2	10	30 000 Z.
Zusammenfassung	0	0	—	—	800 Z.
Abstract	0	0	—	—	700 Z.
Autor 1 (O. Hauke)	—	0	—	—	350 Z.
Autor 2 (A. Kristiansen)	—	0	—	—	350 Z.
Einleitung	1 231	2 781	1	3	—
Anwendungsfall Business-Tax-Panel	125	282	0	0	—
Technische Infrastruktur	145	327	0	0	—
Datenverarbeitungsmethoden	810	1 830	0	2	—
Performanzvergleich	999	2 257	1	3	—
Ergebnis für das vollständige BTP	84	189	0	0	—
Fazit	407	919	0	1	—

Schlüsselwörter

Keywords

Tabellen

Nr.	Beschreibung
-----	--------------

Tabelle 1	Versionen verfügbarer R-Packages
---------------------------	----------------------------------

Tabelle 2	Baselines in SAS und Stata (anhand 1% des simuliertes BTP)
-----------	--

Tabelle 3	Performanz Messungen für die Fallzahlberechnung anhand 1% des BTP
-----------	---

Tabelle 4	Performanz Messungen für die Regressionsberechnung anhand 1% des BTP
-----------	--

Tabelle 5	Performanz Messungen für die Fallzahlberechnung anhand 10% des BTP
-----------	--

Tabelle 6	Performanz Messungen für die Regressionsberechnung anhand 10% des BTP
-----------	---

Tabelle 7	Benchmarkergebnisse für Fallzahlen (kleine Stichproben des BTP)
-----------	---

Tabelle 8	Benchmarkergebnisse für Regression (kleine Stichproben des BTP)
-----------	---

Abbildungen

Nr.	Beschreibung
-----	--------------

Abbildung 1	Strategien zur Performanz-Optimierung im FDZ-Bund
-------------	---

1

Datenverarbeitungsmethoden

Wir betrachten in diesem Artikel die Performanz sog. Datenverarbeitungsmethoden, d.h. Softwarelösungen, die Daten einlesen, modifizieren, aggregieren, auswerten oder analysieren. Das Schreiben von Daten wird in unserer Untersuchung ausgeklammert, da es sich bei den Veröffentlichungen des Statistischen Bundesamtes oder den Outputs der Wissenschaft im FDZ um kleine Tabellen handelt, die i.d.R. keine große Performanz erfordern.^{^writedata} Wir vernachlässigen Spark, Datenbanken und weitere Technologien, die zusätzliche Einrichtung erfordern und nicht direkt als R-Package genutzt werden können.

1.1 Anforderungen an Datenverarbeitungsmethoden

- › Performanz und Nutzererfahrung auf dem aktuellen Stand der Technik
- › leicht einzurichten auch in den abgeschotteten System der amtl. Statistik (tlw. langwierig und schwierig), d.h. wenig Abhängigkeiten und unabhängig von Internet bzw. Cloud betreibbar.
- › langfristig stabil und gut unterstützt
- › leicht nutzbar, gut dokumentiert, gutes Schulungsangebot

Die Analyse großer Datensätze wie des in der FDZ-Umgebung stellt besondere Anforderungen an die verwendeten Werkzeuge. Traditionelle Ansätze (CSV-Dateien, Base R) stoßen bei dieser Datengröße an ihre Grenzen. Moderne spaltenorientierte Technologien lösen dieses Problem indem sie erlauben, nur relevante Variablen bei Bedarf zu einzulesen.

1.2 Sachstand

1.2.1 SAS und Stata

- › Hauptanalysewerkzeuge sind bisher:
 - › im StBA SAS 9.4 M8, EG
 - › im FDZ zsl. Stata
- › Stata
 - › bisher: V.15 MP-12 (KDFV) und Stata 19 SE lokal (GWAP).
 - › neu im OSS in KDFV/GWAP V. 19 gleichermaßen in großen Systemkapazitäten.

1.2.2 Empfehlung des FDSZ der deutschen Bundesbank

- (1) hat den Spezialfall von in-memory Auswertung betrachtet mit den folgenden Ergebnissen:
- › R zeigt große Performanzvorteile gegenüber Stata für FDZ Aufgaben: “Note that using parquet and R reduces the computing time compared to the optimised Stata approach by 65.1% from 77.6 to 27.1 seconds”
 - › zu betrachten ist die Gesamtzeit (d.h. Rechenzeit + Entwicklungszeit)
 - › vorhandene Erfahrung und Knowhow (bspw. in Stata) relativiert die Performanzgewinne in R. Zu beachten sind hohe Debugging Aufwände an den GWAPs der FDZ (kein Internetzugriff)
 - › I.d.R. muss in der Entwicklung Code mehrfach ausgeführt werden, sodass sich die Laufzeit multipliziert (Wickham&Grolemund 2016).
 - › Die u.g. Parquet-Dateien werden bereits standardmäßig im FDSZ angeboten.
 - › Variablenselektion hervorgehoben. Bot Beschleunigung von 39.9% in R und 33.9% in Stata

1.3 Analysewerkzeug R

Der Einsatz von R wächst stetig mit aktuell über 200 aktiven Nutzenden im StBA und FDZ.

- › R ist die native Programmiersprache von Statistiker/-innen und Daten-affinen Programmierer/-innen. Frei verfügbar und leicht einzurichten. Somit weit verbreitet, insb. an Universitäten.
- › R ist Open Source und wird ständig weiterentwickelt (aktuell in Version 4.5 verwendet, jährliche Major Releases).
- › Eine weltweit aktive Community löst Probleme zeitnah und ergänzt stetig Funktionalitäten in Form von sog. R-Packages.
- › Bietet nativ bereits viele Datenverarbeitungsmethoden, die jedoch durch diese R-Packages ganz neue Level an Nutzerfreundlichkeit, Funktionsumfang und Performanz erreichen.

1.4 Klassische Methoden in R

1.4.1 Base R

- › Standardmäßige Basisfunktionen in R.
- › Grundlage/einstieg, weder sonderlich anschaulich noch sonderlich performant -> Packages überlassen
- › Vorteile: Einfach, weit verbreitet, keine zusätzlichen Abhängigkeiten
- › Nachteile: Langsam bei großen Daten, hoher Speicherverbrauch, alle Daten müssen in RAM passen
- › Empfehlung: Zweckdienlich für Einsteiger oder gelegheitsnutzer für ganz kleine Anwendungen oder falls gar keine Abhängigkeiten in Form von Pkg erlaubt sind. Ansonsten...

1.4.2 Data.table

- › {data.table} (Dowle und Srinivasan 2024) in den meisten Fällen die performanteste klassische DVM. An die Syntax an base-r angesiedelt und nur hier verwendet, spezielles Wissen notwendig.
- › Vorteile: Sehr schnell für In-Memory-Operationen, ausgereift, kompakte Syntax. In teilen der Community sehr beliebt
- › Nachteile: Alle Daten müssen in RAM passen, steile Lernkurve, keine Out-of-Core-Unterstützung.
- › Empfehlung: Gute Alternative wenn Datensatz in RAM passt und keine Parquet-Integration benötigt wird

1.4.3 Tidyverse

Tidyverse (Wickham 2023) ist ein Ökosystem von Packages zur Datenverarbeitung, das für besonders hohe Lesbarkeit des Codes bekannt ist. Dazu dient eine eigenen Programmiersyntax, sog. {dplyr}-Syntax (Wickham u. a. 2023a), die den Anspruch hat menschlicher Sprache abzubilden. Das R-Package {dplyr} ist die Datenverarbeitungsgrammatik innerhalb Tidyverse, die anhand eines Beispiels in der folgenden Tabelle veranschaulicht wird

[Tabelle Beispiel Dplyr]

Diese Syntax ist bei einem Teil der R-Community so beliebt, dass sie vielen anderen Packages ergänzt wurde. Bspw. für {data.table} setzen dies die Packages {dtplyr} (Wickham u. a. 2023b) oder {tidytable} (Fairbanks 2024) um. Wie im Falle von {dtplyr} kann die Übersetzung zu {dplyr} jedoch die Performanz verschlechtern.¹

1.5 Best Practices in R

Ab mittleren Datenmengen (relativ zu CPU und RAM) sind ausgewählte Best Practices in R:

- › Variablenselektion: Beim Einlesen von Daten Auswahl der benötigten Variablen in der Einlesefunktion ist wesentliche Best-Practices (besonders für klassische Methoden, da dies das Risiko für RAM-Abbrüche und Wartezeiten deutlich reduziert). Das Einlesen zunächst aller Daten (ggf. mit Variablenselektion zu einem späteren Zeitpunkt) verursacht unnötige Wartezeiten, Ressourcenbelegung und kann zu Abbrüchen führen.
- › Datenaufteilung: Wenn der Arbeitsspeicher nicht ausreicht, um die benötigten Daten einzulesen, bietet eine Aufteilung auf mehrere RAM-Gerechte Datenpakete helfen. Für klassische Methoden kombiniert mit der mehrfachen Variablenselektion. Die folgenden hoch-performanten Techniken, kommen auch direkt mehreren Dateien nutzen, ohne manuell die Datensätze zusammenzuführen.

¹ S. <https://www.r-bloggers.com/2024/04/the-truth-about-tidy-wrappers-3/>

1.6 Hoch-performante Methoden in R

Wir sprechen in diesem Artikel vereinfacht von einer hoch-performanten Methode, sobald die betrachtete Datenverarbeitungsmethode in der Lage ist, Datenmengen überhalb des verfügbaren Arbeitsspeichers flexibel und effizient zu nutzen. SAS erfüllt den Großteil dieser Definition – lediglich die Effizienz lässt sich deutlich steigern.

Um Datenauswertung auf höhere Datenmengen skalieren zu können ist ein Paradigmenwechsel von der “vollständigen Verarbeitung im RAM” zu der Auslagerung aus dem RAM notwendig. Vollständig im RAM sind Daten zwar sehr schnell und einfach zu nutzen, jedoch beansprucht der Transport in den RAM (Einlesen) einen Hauptteil der Laufzeit und der verfügbare RAM reicht i.d.R. nicht für größere Datenmengen. Die nachfolgenden Technologien sind auch in der Lage Daten überhalb des RAMs zu verarbeiten. Durch moderne Hardware und Software kann dies sogar sehr schnell erfolgen.

1.6.1 Apache Parquet

- › Datenformat, spaltenbasiert, komprimiert, ...
- › tba - s. Vortrag

1.6.2 Apache Arrow

- › R-package (Richardson u. a. [2024](#)), C++ basiert, erlaubt Parallelisierung, Datenaufteilung, Lazy-Computations, Datenformat im RAM passend zu Parquet
- › tba - s. Vortrag

1.6.3 DuckDB

- › R-Package (Mühleisen, Raasveldt und DuckDB Contributors [2024](#)), in-memory DB, ...
- › tba - s. Vortrag

1.6.4 Polars

- › an Python-angelehnte Syntax (Vink und Welling [2024](#))
- › tba
- › Benchmark des Polars Entwicklerteams ¹²

1.7 Package-Versionen

Die auf den Servern des StBA und FDZ verfügbaren Packageversionen lassen sich aus organisatorischen Gründen nicht flexibel ändern, da die Genehmigung und Einrichtung neuer Packages nur auf Antrag durch unser R-Betriebsteam erfolgt (i.d.R. innerhalb von 1-2 Tagen). Die Package-Versionen, die zum Zeitpunkt des in ?@sec-benchmark dargestellten Performanz-Vergleiches verfügbare waren, können Tabelle [Tabelle 1](#) entnommen werden.

¹²<https://ddotta.github.io/cookbook-rpolars/benchmarking.html>

Tabelle 1

Versionen verfügbarer R-Packages

```

\begin{table*}
\caption{Versionen verfügbarer R-Packages}\label{tbl-pkg-versions}
\centering\begin{group}\fontsize{10}{12}\selectfont

\begin{tabular}{|>{}1|||>{}1|}
\hline
\cellcolor[HTML]{dce6f0}{\textcolor[HTML]{404040}{\textbf{Paket}}}&\cellcolor[HTML]{dce6f0}{\textcolor[H
\hline
\cellcolor{white}{\textcolor{black}{\{data.table\}}}&\cellcolor[HTML]{f0f8ff}{1.17.8}\\
\cellcolor{white}{\textcolor{black}{\{tidyverse\}}}&\cellcolor[HTML]{f0f8ff}{tba}\\
\cellcolor{white}{\textcolor{black}{\{vroom\}}}&\cellcolor[HTML]{f0f8ff}{tba}\\
\cellcolor{white}{\textcolor{black}{\{arrow\}}}&\cellcolor[HTML]{f0f8ff}{20.0.0.2}\\
\cellcolor{white}{\textcolor{black}{\{duckdb\}}}&\cellcolor[HTML]{f0f8ff}{1.3.2}\\
\cellcolor{white}{\textcolor{black}{\{polars\}}}&\cellcolor[HTML]{f0f8ff}{1.0.1}\\
\hline
\end{tabular}
\end{group}
\end{table*}

```


Literatur

- Dowle, Matt und Arun Srinivasan (2024). data.table: Extension of ‘data.frame’. R package version 1.17.8. URL: <https://CRAN.R-project.org/package=data.table>.
- Fairbanks, Mark (2024). tidytable: Tidy Interface to data.table. R package version 0.11.1. URL: <https://CRAN.R-project.org/package=tidytable>.
- Mühleisen, Hannes, Mark Raasveldt und DuckDB Contributors (2024). duckdb: DBI Package for the DuckDB Database Management System. R package version 1.3.2. URL: <https://CRAN.R-project.org/package=duckdb>.
- Richardson, Neal u. a. (2024). arrow: Integration to Apache Arrow. R package version 20.0.0.2. URL: <https://CRAN.R-project.org/package=arrow>.
- Vink, Ritchie und Søren Havelund Welling (2024). polars: Lightning-Fast DataFrame Library. R package version 1.0.1. URL: <https://CRAN.R-project.org/package=polars>.
- Wickham, Hadley (2023). tidyverse: Easily Install and Load the Tidyverse. R package version 2.0.0. URL: <https://CRAN.R-project.org/package=tidyverse>.
- Wickham, Hadley u. a. (2023a). dplyr: A Grammar of Data Manipulation. R package version 1.1.4. URL: <https://CRAN.R-project.org/package=dplyr>.
- Wickham, Hadley u. a. (2023b). dtplyr: Data Table Back-End for dplyr. R package version 1.3.1. URL: <https://CRAN.R-project.org/package=dtplyr>.