

---

Oliver Hauke

ist Mathematiker und IT-Referent im Kompetenzzentrum „Analyse und Auswertung“ des Statistischen Bundesamtes. Er verantwortet die Weiterentwicklung der technischen Infrastruktur des Forschungsdatenzentrums und berät das Netzwerk empirische Steuerforschung in der effizienten Nutzung der Systeme.

Annette Kristiansen

ist Ökonomin und Referentin im Referat „Unternehmenssteuern“ des Statistischen Bundesamtes. Sie beschäftigt sich mit der Zusammenführung der Unternehmenssteuerstatistiken und betreut das Netzwerk empirische Steuerforschung. Für ihre externe Promotion an der Universität Bremen untersucht sie die technologische Vielfalt multinationaler Unternehmen.

# EFFIZIENTE AUSWERTUNG DES BUSINESS-TAX-PANELS MITHILFE VON R

Oliver Hauke, Annette Kristiansen

🔑 **Schlüsselwörter:** Effiziente Analysen, R-Programmierung, Forschungsdaten, Unternehmenssteuerstatistik, Business-Tax-Panel, Netzwerk empirische Steuerforschung

## ZUSAMMENFASSUNG

Das Forschungsdatenzentrum des Statistischen Bundesamtes baut seine technische Infrastruktur gezielt aus, um der Wissenschaft erweiterte Analysemöglichkeiten amtlicher Daten bereitzustellen. Seit November 2025 steht Forschenden exklusiver Zugang zu diesen erweiterten Systemressourcen in R und Stata zur Verfügung. R-basierte Tools – insbesondere Apache Arrow, Parquet und DuckDB – ermöglichen es, gängige Analysen großer Forschungsdatensätze in Echtzeit auszuführen. Am Beispiel des Business-Tax-Panel (2013 bis 2019) werden die erzielbaren Effizienzgewinne bei der Auswertung umfangreicher steuerstatistischer Daten im Rahmen des Netzwerks empirische Steuerforschung demonstriert.

🔑 **Keywords:** Efficient analysis – R programming – research data – corporate tax statistics – Business Tax Panel – empirical tax research network

## ABSTRACT

The Research Data Centre at the Federal Statistical Office is strategically expanding its technical infrastructure to provide researchers with enhanced analytical capabilities for official data. Since November 2025, researchers have had exclusive access to these extended system resources in R and Stata. R-based tools – particularly Apache Arrow, Parquet, and DuckDB – enable real-time analysis of large research datasets. Using the Business Tax Panel (2013–2019), this paper demonstrates the achievable efficiency gains in analysing large-scale tax statistics within the empirical tax research network.

Inhaltsverzeichnis

---

|       |                                                        |   |
|-------|--------------------------------------------------------|---|
| 1     | Datenverarbeitungsmethoden                             | 5 |
| 1.1   | Anforderungen an Datenverarbeitungsmethoden . . . . .  | 5 |
| 1.2   | Sachstand . . . . .                                    | 5 |
| 1.2.1 | SAS und Stata . . . . .                                | 5 |
| 1.2.2 | Empfehlung des FDSZ der deutschen Bundesbank . . . . . | 5 |
| 1.3   | Analysewerkzeug R . . . . .                            | 6 |
| 1.4   | Klassische Methoden in R . . . . .                     | 6 |
| 1.4.1 | Base R . . . . .                                       | 6 |
| 1.4.2 | Data.table . . . . .                                   | 6 |
| 1.4.3 | Tidyverse . . . . .                                    | 6 |
| 1.5   | Best Practices in R . . . . .                          | 6 |
| 1.6   | Hoch-performante Methoden in R . . . . .               | 7 |
| 1.6.1 | Apache Parquet . . . . .                               | 7 |
| 1.6.2 | Apache Arrow . . . . .                                 | 7 |
| 1.6.3 | DuckDB . . . . .                                       | 7 |
| 1.6.4 | Polars . . . . .                                       | 7 |
| 1.7   | Package-Versionen . . . . .                            | 7 |

# Dokument-Metadaten

|                   |                                                              |
|-------------------|--------------------------------------------------------------|
| Titel:            | EFFIZIENTE AUSWERTUNG DES BUSINESS-TAX-PANELS MITHILFE VON R |
| Autoren:          | Oliver Hauke, Annette Kristiansen                            |
| Veröffentlichung: | WISTA 01/2026                                                |
| Erstellungsdatum: | 5. Dezember 2025 um 21:33 Uhr                                |

---

## Dokumentstatistik

| Abschnitt                         | Wörter | Zeichen | Fußn. | Quellen | Vorgabe   |
|-----------------------------------|--------|---------|-------|---------|-----------|
| Insgesamt                         | 1 079  | 8 452   | 2     | 2       | 30 000 Z. |
| Zusammenfassung                   | 0      | 0       | —     | —       | 800 Z.    |
| Abstract                          | 0      | 0       | —     | —       | 700 Z.    |
| Einleitung                        | 1 231  | 2 737   | 1     | 1       | —         |
| Anwendungsfall Business-Tax-Panel | 125    | 277     | 0     | 0       | —         |
| Technische Infrastruktur          | 145    | 322     | 0     | 0       | —         |
| Datenverarbeitungsmethoden        | 810    | 1 801   | 0     | 0       | —         |
| Performanzvergleich               | 999    | 2 221   | 1     | 1       | —         |
| Ergebnis für das vollständige BTP | 84     | 186     | 0     | 0       | —         |
| Fazit                             | 407    | 905     | 0     | 0       | —         |

## Schlüsselwörter

## Keywords

## Tabellen

| Nr. | Beschreibung |
|-----|--------------|
|-----|--------------|

|                           |                                  |
|---------------------------|----------------------------------|
| <a href="#">Tabelle 1</a> | Versionen verfügbarer R-Packages |
|---------------------------|----------------------------------|

|           |                                                            |
|-----------|------------------------------------------------------------|
| Tabelle 2 | Baselines in SAS und Stata (anhand 1% des simuliertes BTP) |
|-----------|------------------------------------------------------------|

|           |                                                                   |
|-----------|-------------------------------------------------------------------|
| Tabelle 3 | Performanz Messungen für die Fallzahlberechnung anhand 1% des BTP |
|-----------|-------------------------------------------------------------------|

|           |                                                                      |
|-----------|----------------------------------------------------------------------|
| Tabelle 4 | Performanz Messungen für die Regressionsberechnung anhand 1% des BTP |
|-----------|----------------------------------------------------------------------|

|           |                                                                    |
|-----------|--------------------------------------------------------------------|
| Tabelle 5 | Performanz Messungen für die Fallzahlberechnung anhand 10% des BTP |
|-----------|--------------------------------------------------------------------|

|           |                                                                       |
|-----------|-----------------------------------------------------------------------|
| Tabelle 6 | Performanz Messungen für die Regressionsberechnung anhand 10% des BTP |
|-----------|-----------------------------------------------------------------------|

|           |                                                                 |
|-----------|-----------------------------------------------------------------|
| Tabelle 7 | Benchmarkergebnisse für Fallzahlen (kleine Stichproben des BTP) |
|-----------|-----------------------------------------------------------------|

|           |                                                                 |
|-----------|-----------------------------------------------------------------|
| Tabelle 8 | Benchmarkergebnisse für Regression (kleine Stichproben des BTP) |
|-----------|-----------------------------------------------------------------|

## Abbildungen

| Nr. | Beschreibung |
|-----|--------------|
|-----|--------------|

|             |                                                   |
|-------------|---------------------------------------------------|
| Abbildung 1 | Strategien zur Performanz-Optimierung im FDZ-Bund |
|-------------|---------------------------------------------------|

---

# 1

---

## Datenverarbeitungsmethoden

---

Wir betrachten in diesem Artikel die Performanz sog. Datenverarbeitungsmethoden, d.h. Softwarelösungen, die Daten einlesen, modifizieren, aggregieren, auswerten oder analysieren. Das Schreiben von Daten wird in unserer Untersuchung ausgeklammert, da es sich bei den Veröffentlichungen des Statistischen Bundesamtes oder den Outputs der Wissenschaft im FDZ um kleine Tabellen handelt, die i.d.R. keine große Performanz erfordern.<sup>^writedata</sup> Wir vernachlässigen Spark, Datenbanken und weitere Technologien, die zusätzliche Einrichtung erfordern und nicht direkt als R-Package genutzt werden können.

### 1.1 Anforderungen an Datenverarbeitungsmethoden

---

- › Performanz und Nutzererfahrung auf dem aktuellen Stand der Technik
- › leicht einzurichten auch in den abgeschotteten System der amtlichen Statistik (tlw. langwierig und schwierig), d.h. wenig Abhängigkeiten und unabhängig von Internet bzw. Cloud betreibbar.
- › langfristig stabil und gut unterstützt
- › leicht nutzbar, gut dokumentiert, gutes Schulungsangebot

Die Analyse großer Datensätze wie dies in der FDZ-Umgebung stellt besondere Anforderungen an die verwendeten Werkzeuge. Traditionelle Ansätze (CSV-Dateien, Base R) stoßen bei dieser Datengröße an ihre Grenzen. Moderne spaltenorientierte Technologien lösen dieses Problem indem sie erlauben, nur relevante Variablen bei Bedarf zu einzulesen.

### 1.2 Sachstand

---

#### 1.2.1 SAS und Stata

- › Hauptanalysewerkzeuge sind bisher:
  - › im StBA SAS 9.4 M8, EG
  - › im FDZ zsl. Stata
- › Stata
  - › bisher: V.15 MP-12 (KDFV) und Stata 19 SE lokal (GWAP).
  - › neu im OSS in KDFV/GWAP V. 19 gleichermaßen in großen Systemkapazitäten.

#### 1.2.2 Empfehlung des FDSZ der deutschen Bundesbank

- (1) hat den Spezialfall von in-memory Auswertung betrachtet mit den folgenden Ergebnissen:
- › R zeigt große Performanzvorteile gegenüber Stata für FDZ Aufgaben: “Note that using parquet and R reduces the computing time compared to the optimised Stata approach by 65.1% from 77.6 to 27.1 seconds”
  - › zu betrachten ist die Gesamtzeit (d.h. Rechenzeit + Entwicklungszeit)
    - › vorhandene Erfahrung und Knowhow (bspw. in Stata) relativiert die Performanzgewinne in R. Zu beachten sind hohe Debugging Aufwände an den GWAPs der FDZ (kein Internetzugriff)
    - › I.d.R. muss in der Entwicklung Code mehrfach ausgeführt werden, sodass sich die Laufzeit multipliziert (Wickham&Grolemund 2016).
  - › Die u.g. Parquet-Dateien werden bereits standardmäßig im FDSZ angeboten.
  - › Variablenselektion hervorgehoben. Bot Beschleunigung von 39.9% in R und 33.9% in Stata

### 1.3 Analysewerkzeug R

---

Der Einsatz von R wächst stetig mit aktuell über 200 aktiven Nutzenden im StBA und FDZ.

- › R ist die native Programmiersprache von Statistiker/-innen und Daten-affinen Programmierer/-innen. Frei verfügbar und leicht einzurichten. Somit weit verbreitet, insb. an Universitäten.
- › R ist Open Source und wird ständig weiterentwickelt (aktuell in Version 4.5 verwendet, jährliche Major Releases).
- › Eine weltweit aktive Community löst Probleme zeitnah und ergänzt stetig Funktionalitäten in Form von sog. R-Packages.
- › Bietet nativ bereits viele Datenverarbeitungsmethoden, die jedoch durch diese R-Packages ganz neue Level an Nutzerfreundlichkeit, Funktionsumfang und Performanz erreichen.

#### 1.4 Klassische Methoden in R

##### 1.4.1 Base R

- › Standardmäßige Basisfunktionen in R.
- › Grundlage/einstieg, weder sonderlich anschaulich noch sonderlich performant -> Packages überlassen
- › Vorteile: Einfach, weit verbreitet, keine zusätzlichen Abhängigkeiten
- › Nachteile: Langsam bei großen Daten, hoher Speicherverbrauch, alle Daten müssen in RAM passen
- › Empfehlung: Zweckdienlich für Einsteiger oder gelegheitsnutzer für ganz kleine Anwendungen oder falls gar keine Abhängigkeiten in Form von Pkg erlaubt sind. Ansonsten...

##### 1.4.2 Data.table

- › `{data.table}` in den meisten Fällen die performanteste klassische DVM. An die Syntax an base-r angesiedelt und nur hier verwendet, spezielles Wissen notwendig.
- › Vorteile: Sehr schnell für In-Memory-Operationen, ausgereift, kompakte Syntax. In teilen der Community sehr beliebt
- › Nachteile: Alle Daten müssen in RAM passen, steile Lernkurve, keine Out-of-Core-Unterstützung.
- › Empfehlung: Gute Alternative wenn Datensatz in RAM passt und keine Parquet-Integration benötigt wird

##### 1.4.3 Tidyverse

Tidyverse ist ein Ökosystem von Packages zur Datenverarbeitung, das für besonders hohe Lesbarkeit des Codes bekannt ist. Dazu dient eine eigenen Programmiersyntax, sog. `{dplyr}`-Syntax, die den Anspruch hat menschlicher Sprache abzubilden. Das R-Package `{dplyr}` ist die Datenverarbeitungsgrammatik innerhalb Tidyverse, die anhand eines Beispiels in der folgenden Tabelle veranschaulicht wird

[ Tabelle Beispiel Dplyr ]

Diese Syntax ist bei einem Teil der R-Community so beliebt, dass sie vielen anderen Packages ergänzt wurde. Bspw. für `{data.table}` setzen dies die Packages `{dtplyr}` oder `{tidytable}` um. Wie im Falle von `{dtplyr}` kann die Übersetzung zu `{dplyr}` jedoch die Performanz verschlechtern.<sup>1</sup>

#### 1.5 Best Practices in R

Ab mittleren Datenmengen (relativ zu CPU und RAM) sind ausgewählte Best Practices in R:

- › Variablenselektion: Beim Einlesen von Daten Auswahl der benötigten Variablen in der Einlesefunktion ist wesentliche Best-Practices (besonders für klassische Methoden, da dies das Risiko für RAM-Abbrüche und Wartezeiten deutlich reduziert). Das Einlesen zunächst aller Daten (ggf. mit Variablenselektion zu einem späteren Zeitpunkt) verursacht unnötige Wartezeiten, Ressourcenbelegung und kann zu Abbrüchen führen.
- › Datenaufteilung: Wenn der Arbeitsspeicher nicht ausreicht, um die benötigten Daten einzulesen, bietet eine Aufteilung auf mehrere RAM-Gerechte Datenpakete helfen. Für klassische Methoden kombiniert mit der mehrfachen Variablenselektion. Die folgenden hoch-performanten Techniken, kommen auch direkt mehreren Dateien nutzen, ohne manuell die Datensätze zusammenzuführen.

<sup>1</sup> S. <https://www.r-bloggers.com/2024/04/the-truth-about-tidy-wrappers-3/>

Tabelle 1

Versionen verfügbarer R-Packages

| Paket        | Version  |
|--------------|----------|
| {data.table} | 1.17.8   |
| {tidyverse}  | tba      |
| {vroom}      | tba      |
| {arrow}      | 20.0.0.2 |
| {duckdb}     | 1.3.2    |
| {polars}     | 1.0.1    |

## 1.6 Hoch-performante Methoden in R

Wir sprechen in diesem Artikel vereinfacht von einer hoch-performanten Methode, sobald die betrachtete Datenverarbeitungsmethode in der Lage ist, Datenmengen überhalb des verfügbaren Arbeitsspeichers flexibel und effizient zu nutzen. SAS erfüllt den Großteil dieser Definition – lediglich die Effizienz lässt sich deutlich steigern.

Um Datenauswertung auf höhere Datenmengen skalieren zu können ist ein Paradigmenwechsel von der “vollständigen Verarbeitung im RAM” zu der Auslagerung aus dem RAM notwendig. Vollständig im RAM sind Daten zwar sehr schnell und einfach zu nutzen, jedoch beansprucht der Transport in den RAM (Einlesen) einen Hauptteil der Laufzeit und der verfügbare RAM reicht i.d.R. nicht für größere Datenmengen. Die nachfolgenden Technologien sind auch in der Lage Daten überhalb des RAMs zu verarbeiten. Durch moderne Hardware und Software kann dies sogar sehr schnell erfolgen.

### 1.6.1 Apache Parquet

- › Datenformat, spaltenbasiert, komprimiert, ...
- › tba - s. Vortrag

### 1.6.2 Apache Arrow

- › R-package, C++ basiert, erlaubt Parallelisierung, Datenaufteilung, Lazy-Computations, Datenformat im RAM passend zu Parquet
- › tba - s. Vortrag

### 1.6.3 DuckDB

- › R-Package, in-memory DB, ...
- › tba - s. Vortrag

### 1.6.4 Polars

- › an Python-angelehnte Syntax
- › tba
- › Benchmark des Polars Entwicklerteams <sup>|2</sup>

## 1.7 Package-Versionen

Die auf den Servern des StBA und FDZ verfügbaren Packageversionen lassen sich aus organisatorischen Gründen nicht flexibel ändern, da die Genehmigung und Einrichtung neuer Packages nur auf Antrag durch unser R-Betriebsteam erfolgt (i.d.R. innerhalb von 1-2 Tagen ). Die Package-Versionen, die zum Zeitpunkt des in ?@sec-benchmark dargestellten Performanz-Vergleiches verfügbar waren, können Tabelle Tabelle 1 entnommen werden.

<sup>|2</sup><https://ddotta.github.io/cookbook-rpolars/benchmarking.html>