
Oliver Hauke

ist Mathematiker und IT-Referent im Kompetenzzentrum „Analyse und Auswertung“ des Statistischen Bundesamtes. Er verantwortet die Weiterentwicklung der technischen Infrastruktur des Forschungsdatenzentrums des Statistischen Bundesamts und berät das Netzwerk empirische Steuerforschung in effizienter Datenanalyse.

Annette Kristiansen

ist Ökonomin und Referentin im Referat „Unternehmenssteuern“ des Statistischen Bundesamtes. Sie beschäftigt sich mit der Zusammenführung der Unternehmenssteuerstatistiken und betreut Arbeiten für das Netzwerk empirische Steuerforschung.

EFFIZIENTE AUSWERTUNG DES BUSINESS-TAX-PANELS MITHILFE VON R

Oliver Hauke, Annette Kristiansen

🔑 **Schlüsselwörter:** Effiziente Analysen, R-Programmierung, Forschungsdaten, Unternehmenssteuerstatistik, Business-Tax-Panel, Netzwerk empirische Steuerforschung

ZUSAMMENFASSUNG

Das Forschungsdatenzentrum des Statistischen Bundesamtes baut seine technische Infrastruktur gezielt aus, um der Wissenschaft erweiterte Analysemöglichkeiten amtlicher Daten bereitzustellen. Seit November 2025 steht Forschenden exklusiver Zugang zu diesen erweiterten Systemressourcen in R und Stata zur Verfügung. R-basierte Tools – insbesondere Apache Arrow, Parquet und DuckDB – ermöglichen es, gängige Analysen großer Forschungsdatensätze in Echtzeit auszuführen. Am Beispiel des Business-Tax-Panel (2013 bis 2019) werden die erzielbaren Effizienzgewinne bei der Auswertung umfangreicher steuerstatistischer Daten im Rahmen des Netzwerks empirische Steuerforschung demonstriert.

🔑 **Keywords:** Efficient analysis – R programming – research data – corporate tax statistics – Business Tax Panel – empirical tax research network

ABSTRACT

The Research Data Centre at the Federal Statistical Office is strategically expanding its technical infrastructure to provide researchers with enhanced analytical capabilities for official data. Since November 2025, researchers have had exclusive access to these extended system resources in R and Stata. R-based tools – particularly Apache Arrow, Parquet, and DuckDB – enable real-time analysis of large research datasets. Using the Business Tax Panel (2013–2019), this paper demonstrates the achievable efficiency gains in analysing large-scale tax statistics within the empirical tax research network.

Inhaltsverzeichnis

1	Ausbau der Analyseinfrastruktur	5
1.1	Ausgangslage	5
1.2	R-Server des Statistischen Bundesamts	5
1.3	OnSite-Server des FDZ	6

Dokument-Metadaten

Titel:	EFFIZIENTE AUSWERTUNG DES BUSINESS-TAX-PANELS MITHILFE VON R
Autoren:	Oliver Hauke, Annette Kristiansen
Veröffentlichung:	WISTA 01/2026
Erstellungsdatum:	7. Dezember 2025 um 01:51 Uhr

Dokumentstatistik

Abschnitt	Wörter	Zeichen	Fußn.	Quellen	Vorgabe	Status
Insgesamt	697	5 828	1	3	30 000 Z.	
Zusammenfassung	0	0	—	—	800 Z.	✗
Abstract	0	0	—	—	700 Z.	✗
Autor 1 (O. Hauke)	—	0	—	—	350 Z.	✗
Autor 2 (A. Kristiansen)	—	0	—	—	350 Z.	✗
Einleitung	1 231	1 887	0	1	—	
Anwendungsfall Business-Tax-Panel	125	191	0	0	—	
Technische Infrastruktur	145	222	0	0	—	
Datenverarbeitungsmethoden	810	1 241	0	1	—	
Performanzvergleich	999	1 531	0	1	—	
Ergebnis für das vollständige BTP	84	128	0	0	—	
Fazit	407	624	0	0	—	

Schlüsselwörter (≤ 5)

Keywords (≤ 5)

Tabellen (2)

Nr.	Beschreibung
Tabelle 1	StBA R-Server Ausbau (Anfang 2025)
Tabelle 2	FDZ OnSite-Server Spezifikationen
Tabelle 3	Versionen verfügbarer R-Packages
Tabelle 4	Baselines in SAS und Stata (anhand 1% des simuliertes BTP)
Tabelle 5	Performanz Messungen für die Fallzahlberechnung anhand 1% des BTP
Tabelle 6	Performanz Messungen für die Regressionsberechnung anhand 1% des BTP
Tabelle 7	Performanz Messungen für die Fallzahlberechnung anhand 10% des BTP
Tabelle 8	Performanz Messungen für die Regressionsberechnung anhand 10% des BTP
Tabelle 9	Benchmarkergebnisse für Fallzahlen (kleine Stichproben des BTP)
Tabelle 10	Benchmarkergebnisse für Regression (kleine Stichproben des BTP)

Abbildungen (0)

Nr.	Beschreibung
Abbildung 1	Strategien zur Performanz-Optimierung im FDZ-Bund

1

Ausbau der Analyseinfrastruktur

Im Jahr 2025 konnten mit der Bereitstellung neuer Analyseserver wesentliche Fortschritte beim Ausbau der analytischen Infrastruktur des Statistischen Bundesamts und des FDZ erzielt werden.

Die Einführung der neuen Systeme stellt einen bedeutenden Schritt dar, da der Ausbau der Infrastruktur in den formalen Strukturen der Bundesverwaltung ein mehrjähriges Unterfangen ist. Auch Änderungen von Softwareversionen in der abgeschotteten Infrastruktur können organisatorisch aufwändig sein, sodass für die folgenden Darstellungen nicht immer die neuesten Versionen der betrachteten Software zur Verfügung stehen — ein Umstand, der die realistischen Rahmenbedingungen der laufenden Statistikproduktion widerspiegelt. Um dennoch langfristig leistungsstark zu bleiben, wurde die neue Infrastruktur von Beginn an zukunftsorientiert konzipiert und bietet moderne Software auf einer deutlich erweiterten Hardwarebasis.

1.1 Ausgangslage

Das Hauptwerkzeug für die Statistikproduktion ist die kommerzielle Analysesoftware [SAS 9.4](#), für das dedizierte Server bereitgestellt werden.¹ SAS 9.4 verarbeitet Daten überwiegend zeilenorientiert und belastet den Arbeitsspeicher daher nur gering — ein entscheidender Vorteil in der amtlichen Statistik, da auch große Datenmengen auf mit geringeren Hardwareanforderungen verarbeitet werden können. Für viele Anwendungsfälle ist jedoch die spaltenbasierte Datenverarbeitung effizienter. In R sind neuere Verfahren verfügbar, die moderne Prozessor- und Arbeitsspeicher gezielt ausnutzen, können die Laufzeiten gegenüber SAS erheblich verkürzen (siehe [?@sec-methoden](#) und [?@sec-benchmark](#)).

Im FDZ ist – neben SAS – die kommerzielle Software [Stata](#) das am stärksten nachgefragte Auswertungswerkzeug. [Stata](#) wird in vielen wissenschaftlichen Fachrichtungen genutzt, da sie ohne tiefgreifende Programmierkenntnisse eingesetzt werden kann, gleichzeitig aber spezialisierte Verfahren, insbesondere für ökonometrische Analysen, bereitstellt. Bei großen Datenmengen stößt Stata jedoch an seine Grenzen, da Daten vollständig in den Arbeitsspeicher geladen werden müssen, und nur ausgewählte Operationen erlauben die parallelisierte Datenverarbeitung. Durch die manuelle Variablenauswahl lassen sich größere Datensätze bearbeiten, der Speicherbedarf bleibt aber begrenzend. Bisher waren die GWAP-Arbeitsplätze auf die Single-Core-Version mit begrenztem RAM beschränkt und damit für viele Produkte des FDZ unzureichend, während leistungsfähigere Server vor der Bereitstellung des OnSite-Server nur in der KDFV verfügbar waren.

1.2 R-Server des Statistischen Bundesamts

Seit Jahren steht im Statistischen Bundesamt ein Server für die Open-Source [Statistiksoftware R](#) und [Python](#) zur Verfügung, der für die Datenverarbeitung in der Statistikproduktion sowie im KDFV des FDZ genutzt wird. R wird aufgrund seiner großen internationalen Community, der Vielzahl spezialisierter Pakete für Datenanalyse, spaltenbasierte Verarbeitung und Visualisierung sowie der schnellen Weiterentwicklung zunehmend in der amtlichen Statistik eingesetzt.

Seit Anfang 2025 konnte der R- und Python-Server signifikant erweitert werden. Verwendet wird die kommerziell unterstützte [Posit Workbench](#), um die Funktionen Projekt-Sharing, Git-Integration, Positron-Features bereitstellen zu können. Zusätzlich wurden die Systemressourcen deutlich ausgebaut, wie die folgende Tabelle zeigt:

Die neue Oberfläche und IDE erhöhen die Nutzerfreundlichkeit, die neuesten R-Versionen stehen bereit, und Pakete

¹Da SAS bereits langjährig eingesetzt wird, ist für die kommenden Performanzvergleiche zu beachten, dass die SAS-Server nicht über die neuste Hardware verfügen. SAS wurde in 2025 auf Version 9.4M8 aktualisiert. Die neuste Version ist SAS 9.4M9. S. https://documentation.sas.com/doc/en/pgmsascdc/9.4_3.5/whatsdiff/upgradeswhatsnew94.html

Tabelle 1

StBA R-Server Ausbau (Anfang 2025)

[!htb]		
Komponente	Vorher	Nachher
Anzahl Server	1	10
Arbeitsspeicher (jeweils)	700 GB	1 TB
Kernanzahl (jeweils)	72	96
Core Speed (jeweils)	TBA	TBA
GPUs (jeweils)	keine	2× A6000 (je 48 GB)

Tabelle 2

FDZ OnSite-Server Spezifikationen

[!htb]	
Komponente	Umfang
Stata-Server	3
R-Server	6
Arbeitsspeicher (jeweils)	512 GB
Kernanzahl (jeweils)	16
CPU-Geschwindigkeit (jeweils)	3.1 GHz

können schnell installiert werden. So können moderne Analyse- und Visualisierungsmethoden effizient genutzt werden – sodass aktuell über 200 aktive Nutzende das System nutzen.

1.3 OnSite-Server des FDZ

Seit November 2025 steht der sogenannte OnSite-Server exklusiv im FDZ für alle OnSite-Nutzungen bereit. Er bietet jeweils dedizierte Stata- und R-Server an den GWAP-Arbeitsplätzen sowie via KDFV mit gleichermaßen umfangreichen Analysekapazitäten, wie in Tabelle 2 aufgeführt. Alle Analyseserver sind über schnelle Direktverbindungen an den Netzwerkspeicher angebunden, sodass R und Stata nahtlos kombiniert werden können.

Stata/MP ist nun einheitlich auf leistungsstarken Multi-Core-Servern verfügbar. Zudem steht erstmals R für OnSite-Nutzungen bereit: Aufbau und Softwarebasis orientieren sich am zentralen R-Server des Statistischen Bundesamts, sind jedoch dediziert für FDZ-Anwendungen.

Die R-Server unterstützen moderne, speichereffiziente Verfahren, mit denen auch Datenmengen oberhalb des Arbeitsspeichers flexibel, stabil und schneller verarbeitet werden können – Details dazu siehe [?@sec-methoden](#).