
Oliver Hauke

ist Mathematiker und IT-Referent im Kompetenzzentrum „Analyse und Auswertung“ des Statistischen Bundesamtes. Er betreut die technische Infrastruktur des Forschungsdatenzentrums im Statistischen Bundesamt und arbeitet für das Netzwerk empirische Steuerforschung.

Annette Kristiansen

ist Ökonomin und Referentin im Referat „Unternehmenssteuern“ des Statistischen Bundesamtes. Sie beschäftigt sich mit der Zusammenführung der Unternehmenssteuerstatistiken und betreut das Netzwerk empirische Steuerforschung. Für ihre externe Promotion an der Universität Bremen untersucht sie die technologische Vielfalt multinationaler Unternehmen.

EFFIZIENTE ANALYSE GROSSER FORSCHUNGSDATEN MITHILFE VON R

Oliver Hauke, Annette Kristiansen

↘ **Schlüsselwörter:** Effiziente Analysen, R Programmierung, Forschungsdaten, Unternehmenssteuerstatistik, Business-Tax-Panel, Netzwerk empirischer Steuerforschung

ZUSAMMENFASSUNG

Das Forschungsdatenzentrum des Statistischen Bundesamtes baut seine technische Infrastruktur gezielt aus, um moderne Analysetools mit deutlich höheren Rechenkapazitäten bereitzustellen. Der neue FDZ OnSite-Server bietet Forschenden ab November 2025 exklusiven Zugang zu diesen erweiterten Systemressourcen in R und Stata. Dieser Beitrag zeigt, wie mit R-basierten Tools – insbesondere Apache Arrow, Parquet und DuckDB – gängige Analysen großer Forschungsdatensätze in Echtzeit ausgeführt werden können. Am Beispiel des Business-Tax-Panel (2013 bis 2019) werden die erzielbaren Effizienzgewinne bei der Auswertung umfangreicher steuerstatistischer Daten im Rahmen des Netzwerks empirischer Steuerforschung demonstriert.

↘ **Keywords:** *Efficient analysis – R programming – research data – corporate tax statistics – Business Tax Panel – empirical tax research network*

ABSTRACT

The Research Data Centre at the Federal Statistical Office is expanding its technical infrastructure to provide modern analysis tools with significantly higher computing capacities. From November 2025, the new FDZ OnSite server will offer researchers exclusive access to these extended system resources in R and Stata. This paper demonstrates how R-based tools – particularly Apache Arrow, Parquet, and DuckDB – enable real-time analysis of large research datasets. Using the Business Tax Panel (2013–2019), the achievable efficiency gains in analysing large-scale tax statistics within the empirical tax research network are demonstrated.