
Oliver Hauke

ist Mathematiker und IT-Referent im Kompetenzzentrum „Analyse und Auswertung“ des Statistischen Bundesamtes. Er verantwortet die Weiterentwicklung der technischen Infrastruktur des Forschungsdatenzentrums und berät das Netzwerk empirische Steuerforschung in der effizienten Nutzung der Systeme.

Annette Kristiansen

ist Ökonomin und Referentin im Referat „Unternehmenssteuern“ des Statistischen Bundesamtes. Sie beschäftigt sich mit der Zusammenführung der Unternehmenssteuerstatistiken und betreut das Netzwerk empirische Steuerforschung. Für ihre externe Promotion an der Universität Bremen untersucht sie die technologische Vielfalt multinationaler Unternehmen.

EFFIZIENTE ANALYSE GROSSER FORSCHUNGSDATEN MITHILFE VON R

Oliver Hauke, Annette Kristiansen

✦ **Schlüsselwörter:** Effiziente Analysen, R-Programmierung, Forschungsdaten, Unternehmenssteuerstatistik, Business-Tax-Panel, Netzwerk empirische Steuerforschung

ZUSAMMENFASSUNG

Das Forschungsdatenzentrum des Statistischen Bundesamtes baut seine technische Infrastruktur gezielt aus, um der Wissenschaft erweiterte Analysemöglichkeiten amtlicher Daten bereitzustellen. Seit November 2025 steht Forschenden exklusiver Zugang zu diesen erweiterten Systemressourcen in R und Stata zur Verfügung. R-basierte Tools – insbesondere Apache Arrow, Parquet und DuckDB – ermöglichen es, gängige Analysen großer Forschungsdatensätze in Echtzeit auszuführen. Am Beispiel des Business-Tax-Panel (2013 bis 2019) werden die erzielbaren Effizienzgewinne bei der Auswertung umfangreicher steuerstatistischer Daten im Rahmen des Netzwerks empirische Steuerforschung demonstriert.

✦ **Keywords:** *Efficient analysis – R programming – research data – corporate tax statistics – Business Tax Panel – empirical tax research network*

ABSTRACT

The Research Data Centre at the Federal Statistical Office is strategically expanding its technical infrastructure to provide researchers with enhanced analytical capabilities for official data. Since November 2025, researchers have had exclusive access to these extended system resources in R and Stata. R-based tools – particularly Apache Arrow, Parquet, and DuckDB – enable real-time analysis of large research datasets. Using the Business Tax Panel (2013–2019), this paper demonstrates the achievable efficiency gains in analysing large-scale tax statistics within the empirical tax research network.

Inhaltsverzeichnis

1	Einleitung	3
1	TLDR	3
2	Handlungsbedarf	3
2.1	Steigende Datenmenge der amtlichen Statistik	3
2.2	Steigende Anforderungen der Öffentlichkeit insb. Wissenschaft	4
3	Vorschreitende Innovation der Datenverarbeitungstechnologien	4
3.1	Ausgangslage	4
3.2	Vormarsch von Open Source	4
3.3	Fokus auf R	4
3.4	Hoch-performante R-Pakete	5
4	Umsetzungsideen/-vorschläge im StBA/FDZ	5
5	Fokus der Artikels	6
2	Vergleich der Performanz	6
1	Benchmark-Setup	7
2	Baselines in SAS und Stata	7
3	Kleiner Vergleich zwischen R und den Baselines	7
4	Größere Datenmengen in R	10
5	Erkenntnisse des Experiments	11
3	Anwendung auf das BTP	11
4	Fazit	11
1	Kernaussage des Artikels	12
2	Auswirkung auf IT-Infrastruktur und Beratung	12
3	Auswirkungen auf die Statistikproduktion	13
4	Auswirkungen auf die FDZ	13
5	Auswirkung auf die Wissenschaft	13
6	Schlussbemerkung	13
Anhang		14
	Weitere Performancemessungen für kleinere Datenmengen.	14

1

Einleitung

1

TLDR

...

Spannungsfeld, Weiterentwicklung und Technologie-Empfehlung...

Forschungsdatenzentrum des Statistischen Bundesamts, hier kurz FDZ Netzwerk empirischer Steuerforschung, hier kurz NeSt

2

Handlungsbedarf

2.1 Steigende Datenmenge der amtlichen Statistik

StBA

- › Qualitätsbericht. Wachsende Datenmenge in der amtlichen Statistik, Verweis auf (Statistisches Bundesamt 2023)
- › Datenverarbeitung im StBA erklären
- › neues NeSt Produkt BTP zeigt Umfang, hoch interessant für Wissenschaft
- › Datenverarbeitungsaufgaben des StBA erklären

- › Nicht mehr durch vorhandene Systemkapazitäten (insb. Arbeitsspeicher) gedeckt

-> wir müssen RAM sparen! Idealerweise auch Laufzeit.

- › Herausforderungen (größere Datenmengen, komplexere Analysen, schnellere Antworten notwendig)
 - › hohe Anforderungen der Öffentlichkeit und besonders Wissenschaft. Verweis auf Gutachten des Stat. Beirats und Gründung "Netzwerk emp. Steuerforschung"
 - › Schnelle Bereitstellung von am besten vollständigen, wenig Anonymisierten Datensätzen an Wissenschaft via FDZ. Erste Analysen seitens StBA und hohe Expertise erwartet (Exploration der Daten nötig)
 - › Bereitstellung von Zusatzdokumentation durch StBA. Metadatenreport
 - › schnelle Bereitstellung,
 - › zeitnahe Nutzung in FDZ
 - › keine Wartezeiten in FDZ
 - › sofortig Antworten auf Analysefragen
 - › Erhöhte Komplexität Analysen mit größeren, Komplexeren Datensätzen
- › Rückstände/Altlasten: weiterentwickelnde Infrastruktur, nicht state of the art (ausgelegt auf Konsistenz und Zuverlässigkeit, nicht Schnelligkeit), gesetzlicher Auftrag
 - › hauptsächlich SAS für große Datenmenge verwendet, funktioniert, aber langsam
 - › FDZ Bund integriert in Standardarbeitsplätze des StBA
 - › Bereitstellungsaufwände und Abhängigkeiten moderner Software

Annette: -> Impuls aus der Wissenschaft, dann Fachbereich - Fachbereich/Verbund im Grunde Hauptnutzende da Tools und Daten zur Verfügung stehen Technische Möglichkeit entwickelt sich weiter usw..

Der Sachverständigenrat zur Begutachtung der gesamtwirtschaftlichen Entwicklung (2023) hat in seinem Gutachten 2023/24 auf eine technisch veraltete Infrastruktur und auf die fehlende Nutzerfreundlichkeit hingewiesen. Seitdem hat sich die Infrastruktur in dem Forschungsdatenzentrum des Bundes verbessert. Seit Januar 2025 besteht ein Remote Access System als neuer Zugangsweg für die Wissenschaft. Im Bereich der Steuerstatistiken wird derzeit geprüft, inwiefern auch Einzeldaten aus diesem Bereich über Remote Access genutzt werden können. Als Übergang und Erleichterung für bestehende Forschungsprojekte wird in diesem Kapitel 2

Die amtliche Statistik steht vor der Herausforderung,

bei stetig wachsenden Datenmengen und sich ändernden Nutzeranforderungen qualitativ hochwertige und zeitnahe statistische Informationen bereitzustellen (Statistisches Bundesamt 2023). Dabei spielt die Effizienz der verwendeten statistischen Verfahren eine zentrale Rolle für die Leistungsfähigkeit des gesamten statistischen Systems.

In den vergangenen Jahren haben sich die Rahmenbedingungen für die Produktion amtlicher Statistiken erheblich verändert. Die Digitalisierung hat nicht nur zu einer Vervielfachung der verfügbaren Datenquellen geführt, sondern auch neue Möglichkeiten für die statistische Analyse eröffnet. Gleichzeitig sind die Erwartungen der Nutzer an Aktualität und Detailliertheit der Statistiken gestiegen.

Diese Entwicklungen erfordern eine kontinuierliche Evaluation und Optimierung der eingesetzten Verfahren. Ziel der vorliegenden Studie ist es daher, die Effizienz verschiedener statistischer Verfahren systematisch zu bewerten und Handlungsempfehlungen für die Praxis abzuleiten.

2.2 Steigende Anforderungen der Öffentlichkeit insb. Wissenschaft

FDZ, NeSt

- › Schnelle Reaktionen erforderlich
- › Komplexere (Forschungsfragen) zu beantworten
- › FDZ erklären
- › Gutachten BMF ansprechen
- › NeSt erklären, Bedarfe durch Produkt BTP beantwortet.. aber wie kann es in angme

The Need for Speed

As we start working with larger and larger datasets, the basic tools of the tidyverse start to look a little slow. In the last few years several packages more suited to large datasets have emerged. Some of these are column, rather than row, oriented. Some use parallel processing. Some are vector optimized. Speedy databases that have made their way into the R ecosystem are data.table, arrow, polars and duckdb. All of these are available for Python as well. Each of these carries with it its own interface and learning curve. duckdb, for example is a dialect of SQL, an entirely different language so our dplyr code above has to look like this in SQL: S. <https://www.r-bloggers.com/2024/04/the-truth-about-tidy-wrappers-3/>

3

Vorschreitende Innovation der Datenverarbeitungstechnologien

3.1 Ausgangslage

SAS für aml. Statistik und SAS/Stata für FDZ

- › SAS, zsl. Stata in den FDZ. Session zu SAS Ablösung
- › Weiterentwicklung der Infrastruktur: neue Server für R im StBA und für FDZ eigene neue Server für R und Stata
- › hohe Lizenzkosten, Trend zu Abonnements und Cloud nachteilig, technologiLOCK und Privacy.
- › Kommen bei unseren Anwendungen Kapazitätär an ihre Grenzen und Performanz in anderen Technologien höher.

Anforderungen an Modernisierung

- › hohe Performanz, schnelle Ergebnisse, idealenfalls in Echtzeit (d.h. wenigen Sekunden)
- › moderne Interfaces, möglichst leichte Nutzung, wenig Schulungsbedarf, Allgemeinwissen von Statistiker u.Ä. Fachrichtungen (Werkzeug, nicht Gegenstand der Untersuchung)
- › leicht einrichtbar, wenig Abhängigkeiten zu vielen Tools, die sich ständig weiterentwickeln, sodass hohe Wartungsaufwände entstehen.

3.2 Vormarsch von Open Source

- › in der internationalen amtlichen Statistik seit Jahren auf dem Vormarsch. Langsam steigt auch Verbreitung von R steigt auch in den dt. Statistikämtern.

3.3 Fokus auf R

R verbreitung steigt, bei uns in Kinderschuhen. Wie fängt man denn am besten an? Was ist von anfang an der richtige Weg daten in R zu verarbeiten?

R ist weltweit bekannt und verbreitet als die Lingua Franca für Statistik, Methodologie und Data Science. Dies macht R zu der natürlichen Wahl für die amtlichen Statistik mit viele attraktive Vorteile.

- › aktive globale Community sorgt für schnelle Innovation und Verbesserung
- › CRAN bietet offiziell aktuell Zusatzfunktionalitäten in Form von X R-Paketen. Darunter sind viele klassische Pakete für Datenverarbeitung und -analyse.
- › R
 - › The reasons why the official statistics community is rapidly embracing R are clear. S. erfolg / Wachstum der Conference uRos <https://r-project.ro/conference2025.html#Presentations>
 - › R lingua franca for statisticians, methodologists and data scientists worldwide -> nativ geeignet für amtl. Statistik
 - › R Open Source bietet vorteile
 - › aktive globale Community
 - › support from the industry
 - › it combines a vast amount of functionalities for data preparation, methodology, visualisation and application building
 - › free = ideal environment for sharing, collaboration and industrialising official statistics
 - › Packages CRAN, github...

Arrow bspw. hatte in 2024 und 2025 jeweils 4 Major Releases mit diversen neuen Funktionalitäten und Performanz-Verbesserung

Neue Entwicklung zu R in der dt. OSS, bei Integration in Statistikproduktion und Datenbereitstellung direkt mit den richtigen Features und Methoden beginnen. Wie die folgenden...

Open Source -> breite Auswahl an Parketen zum Einlesen, Transformieren und Auswerten von Daten.

- › Unterscheidung klassischer/r-nativer Methoden (base-r, readr / vroom und data.table), effiziente/moderne Methoden (arrow, duckdb, polars)
- › Klassische Methoden
 - › base-r zu vermeiden
 - › readr
 - › in tidyverse
 - › nutzerfreundlich, einfach zu lernen / nutzen
 - › data.table
 - › benchmarking: <https://cran.r-project.org/web/packages/data.table/vignettes/datatable-benchmarking.html>
 - › datenformate in R: qs, rds
- › dtplyr?

3.4 Hoch-performante R-Pakete

Als Desktopanwendung konzipiert ist R nicht für hoch-performante Auswertungen von Big Data bekannt. Wie unsere Untersuchung zeigen wird, beansprucht R nativ übermäßige Systemressourcen, um die Nutzerfreundlichkeit zu erhöhen. Dadurch dass R Open Source ist ändern dies jedoch diverse Entwicklerteams weltweit und stellen R Zusatzfunktionen in Form von R-Paketen zur Verfügung die in R hoch-performante Auswertung großer Datenmengen ermöglichen.

- › R darüber hinaus vermehrt hoch-performante Analysetools, die sich ständig verbessern
- › ermöglichen sehr schnelle Verarbeitung von Daten, mit einem sehr hohen Gesamtvolumen, das sogar den verfügbaren RAM übersteigt.
- › sollte möglichst leicht nutzbar sein, nativ in R ohne viele Abhängigkeiten (organisatorische Einschränkungen)

4

Umsetzungsideen/-vorschläge im StBA/FDZ

- › möglichst leicht nutzbar und gewohnt/verbreitet -> R+dpplr
- › wechselnde Nutzende (Forscher) unterschiedlicher Fachbereiche mit unterschiedlichen Analytischen und technischen Kenntnissen
- › stabil
- › schnell, optimale Nutzung vorhandener GWAP Zeit und KDFV Zeitraum
- › ressourcensparend (RAM Problematik)
- › möglichst leicht nutzbar mit den vorhandenen Systemen und organisatorischen Strukturen ergibt Anforderungen
- › hohe-performanz bereits mit R Grundlagenwissen

- › minimale Anforderungen an zsl. Software
- › NeSt Förderung, Datenprodukterstellung, Bereitstellung der FDZ auch technischen Infrastruktur und Knowhow der effizienten Nutzung
- › Bereitstellung des OSS seit Nov. 2025
- › Vorbereitend Exploration und Beratung in geeigneten Äußerst effizienten Methoden -> Ergebnisse in Echtzeit
- › Szenario FDZ GWAP Besuch, statt KDFV, sofort Ergebnisse
- › Diese Arbeit

Technische Lösungsansätze.

- › Modernisierung der amtl. Stat, FDZs -> Zugangswege, Kapazitäten, ...
- › Technische Weiterentwicklung, stärkere Hardware, leichtere Bereitstellung, virtualisierung
- › Schnelle Weiterentwicklung von Open-Source Software, R, div. Packages, e.g. Verweis auf Changelog von Arrow, Polars

Rechenzeit und Speicheranforderungen bei gleichbleibender Ergebnisqualität?

2. **Skalierbarkeit:** Welche Verfahren zeigen die beste Performance bei wachsenden Datenmengen, und wo liegen die kritischen Grenzen?
 3. **Praktische Anwendbarkeit:** Welche Infrastrukturanforderungen stellen moderne Auswertungsmethoden an Forschungsdatenzentren?
- › Bei der Integration von R und umfangreichen Auswahl, welche Technologie sollte Datenaufbereitung, -analyse und -auswertung genutzt werden?
 - › Wir nutzen eine Kontrollierte Benchmark

Die Arbeit gliedert sich wie folgt: Nach dieser Einleitung wird in **?@sec-btp** der Anwendungsfall Business-Tax-Panel vorgestellt, der als empirisches Beispiel für die Analysen dient. **?@sec-infrastruktur** beschreibt die Infrastruktur des Forschungsdatenzentrums des Bundes (FDZ-Bund), in der die Auswertungen durchgeführt werden.

In **?@sec-methoden** werden verschiedene effiziente Auswertungsmethoden vorgestellt und deren theoretische Grundlagen erläutert. Kapitel 2 präsentiert die empirischen Performanzergebnisse der verschiedenen Ansätze. Die Arbeit schließt mit einem Ausblick auf zukünftige Entwicklungen in **?@sec-ausblick**.

Die Analyse basiert auf einer umfangreichen empirischen Studie, die verschiedene statistische Verfahren anhand realer Datensätze aus der amtlichen Statistik vergleicht. Dabei werden sowohl etablierte als auch neuere Ansätze berücksichtigt, um ein vollständiges Bild der verfügbaren Optionen zu zeichnen.

““

2

Vergleich der Performanz

1

5

Fokus der Artikels

Zielgruppe: alle Datenanalytiker mit rudimentären R-Kenntnisse, aber breit, FDZ, amtl. Stat,

Scope, Abgrenzung

- › Identifizierte Kernaufgabe: 90% irrelevante Informationen aus großen Datenmengen rausfiltern, Untersuchung wie dies am effizientesten geht.

Leitet in den weiteren Artikel über zu der Kernfrage

enchmark Experiment

-> Empfehlung Systemressourcen für IT-Betrieb -> Software- und Methodenempfehlung für Wissenschaft

Die Untersuchung fokussiert sich auf folgende zentrale Forschungsfragen:

1. **Methodische Effizienz:** Wie unterscheiden sich verschiedene statistische Verfahren hinsichtlich ihrer

Benchmark-Setup

Um zwischen den in Abschnitt 2 vorgestellten Datenverarbeitungsmethoden abzuwägen, haben wir deren Performanz in einem systematischen Benchmark-Experiment auf dem SAS-Server des Statistischen Bundesamtes und den neuen OnSite R- und Stata-Servern des FDZ gemessen. Weiterführende Benchmarks sowie der vollständig reproduzierbare Code sind auf Opencode verfügbar¹.

Für die Untersuchung wurden simulierte Einzeldaten in verschiedenen Größen (0,1%/1%/10% von den insgesamt 80 Mio. Beobachtungen des BTP) betrachtet. Sie wurden aus öffentlich verfügbaren Informationen generiert, um die wesentlichen Strukturen des BTP für unsere Analyse künstlich nachzubilden. Abgrenzend zu den im FDZ bereitgestellten *Datenstrukturfiles* wurden die Testdaten nicht aus echten Mikrodaten abgeleitet. Der simulierte Datensatz ist ausschließlich für technische Testzwecke der nachfolgenden Anwendungsfälle bestimmt:

1. **Fallzahlen** (pro Statistik und Jahr),
2. **Regression** (Einflussfaktoren auf Verlustvorträge).

Um eine zuverlässige Performanz-Messung zu erhalten, wurde jede Datenverarbeitungsmethode dreifach angewandt. Der Vergleich erfolgt anhand der mittleren Messung der folgenden Zielgrößen:

1. **Arbeitsspeicher** der Auswertung,
2. **Laufzeit** der Auswertung (real verstrichene Zeit),
3. **Festplattenspeicher** der verwendeten Daten.

Die Zielgrößen sind in dieser Reihenfolge zu priorisieren, da ein übermäßiger Arbeitsspeicherverbrauch zu schwerwiegenden Abbrüchen führen kann, während hohe Laufzeiten dennoch zu einem erfolgreichen Ergebnis führen können. Festplattenspeicher ist ausreichend vorhanden, aber unnötige Belegung sollte vermieden werden.

Feine Abstufungen der Zielgrößen sind für unsere Aufgaben nicht gleichermaßen relevant. Eine Methode, die die betrachteten Auswertungen in unter 10 Sekunden mit weniger als 4 GB Arbeitsspeicher durchführen kann, wird bereits als optimal bewertet. Weitere Optimierungen sind in diesem Fall nicht erforderlich. Falls bereits die gewünschte Performanz erreicht wurde, rückt die Reduktion des Entwicklungsaufwand in den Vordergrund. Entsprechend sind Aspekte wie einfache Anwendbarkeit

und Nachvollziehbarkeit – selbst für unerfahrene Nutzende – ausschlaggebend.

2

Baselines in SAS und Stata

Klassisch werden die betrachteten Auswertungsaufgaben im Statistischen Bundesamt hauptsächlich mit SAS und im FDZ mit Stata gelöst. Um die nachfolgenden Ergebnisse einzuordnen, haben wir die Performanzmessungen für 1% des simulierten BTP-Daten (etwa. 800.000 Beobachtungen) in SAS und Stata durchgeführt.

Die Ergebnisse in Tabelle 1 zeigen, dass der umfangreiche Arbeitsspeicher des FDZ OnSite-Servers nicht ausreicht, um das ganze BTP in Stata einzulesen, sodass zwingend mit Variablenselektion gearbeitet werden muss. SAS zeigt seine Stärke anhand der geringen Beanspruchung des Arbeitsspeichers, benötigt aber mit etwa 2,3 Minuten pro Auswertung die doppelte Laufzeit gegenüber Stata.

3

Kleiner Vergleich zwischen R und den Baselines

Für 1% der simulierten BTP Daten, reduzieren die R-Datenverarbeitungsmethode alle Zielgrößen gegenüber SAS und Stata erheblich (siehe Tabelle 2 und Tabelle 3). Selbst klassische R-Methoden sind um den Faktor 7 schneller und benötigen nur 33 % des Festplattenspeichers.

¹ www.opencode.de/URL-To-Be-Announced.

Tabelle 1

Baselines in SAS und Stata (anhand 1% des simuliertes BTP)

		[t]		
SAS	Fallzahl	65 MB	2.4 Min.	33 GB
SAS	Regression	7 MB	2.8 Min.	33 GB
Stata	Fallzahl	33 GB	55,2 Sek.	32 GB
	Regression	33 GB	55,8 Sek.	32 GB

{polars}, {duckdb} und {arrow} lösen die betrachteten Auswertungen sogar

- › in **unter 2 Sekunden** (27-fach schneller),
- › mit unter **300 MB Arbeitsspeicher** – {duckdb} und {polars} sogar mit unter **5 MB** (10-fach weniger)^{|2|3}
-
- › und nur mit **5 GB Festplattenspeicher** (6-fach weniger gegenüber SAS und Stata).

Unter den klassischen R-Methoden bietet {data.table} die beste Performanz. Dabei ist wesentlich zu beachten, dass die Einlesefunktion `fread` direkt die relevanten Variablen auswählt. Dadurch lassen sich unsere Auswertungen um einen Faktor 3 beschleunigen und vor allem der Arbeitsspeicher um einen Faktor 1.000 reduzieren.

Alle hoch-performanten Methoden sind dermaßen effizient, dass die Datenmenge von 800.000 Beobachtungen nicht mehr ausreicht, um zwischen den besten Methoden zu differenzieren. Daher erhöhen wir im nächsten Experiment die Datenmenge auf 8.000.000 Beobachtungen (10% BTP).

^{|2} Lediglich in der Arbeitsspeicherbeanspruchung, ist SAS deutlich besser als klassische R-Methoden. Gegenüber hoch-performanten R-Methoden benötigt SAS jedoch den 10-fachen Arbeitsspeicher.

^{|3} {arrow} benötigt mit 274 MB deutlich mehr Arbeitsspeicher als {polars} und {duckdb}, aber kommt dennoch mit minimalen Entwicklungsumgebungen aus, bspw. einem standardmäßigen Laptop.

Tabelle 2

Performanz Messungen für die Fallzahlberechnung anhand 1% des BTP

		[t]			
{polars}	Parquet	-	3,3 MB	1,0 Sek	4,9 GB
{duckdb}	Parquet	-	4,8 MB	1,5 Sek	4,9 GB
{arrow}	Parquet	Variablenauswahl	273,7 MB	1,7 Sek	4,9 GB
{data.table}	CSV	Variablenauswahl	42,9 MB	2,5 Sek	13,0 GB
{arrow}	Parquet	Datenaufteilung (gleichmäßig)	229,7 MB	2,8 Sek	4,9 GB
{arrow}	Parquet	-	272,8 MB	2,8 Sek	4,9 GB
{arrow}	Parquet	-	230,4 MB	3,8 Sek	4,9 GB
{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	229,9 MB	3,9 Sek	4,8 GB
{data.table}	CSV	-	33,7 GB	7,4 Sek	13,0 GB
{data.table}	CSV	Datenaufteilung (Berichtsjahr)	50,4 GB	13,6 Sek	10,5 GB

Tabelle 3

Performanz Messungen für die Regressionsberechnung anhand 1% des BTP

		[t]			
{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	529,7 MB	3,8 Sek	4,8 GB
{dplyr}	CSV	Variablenauswahl	154,8 MB	13,2 Sek	13,0 GB

4

Größere Datenmengen in R

Auch für 10 % der simulierten BTP-Daten, kann R die beiden betrachteten Auswertungen in Echtzeit mit minimalem Arbeitsspeicher beantworten (siehe Tabelle 4 und Tabelle 5). Die Auswertungsmethoden mit der höchsten Performanz nutzen alle das {parquet} und erreichen:

1. {arrow} benötigt nur **4,7 Sekunden** und 230 MB Arbeitsspeicher,
2. {duckdb} benötigt nur 5,1 Sekunden und **4,7 MB Arbeitsspeicher**.

Unerwarteterweise ist die Laufzeit von {polars} für diese Datenmenge mit 1,2 Minuten weit abgeschlagen, obwohl das gleiche Auswertungsskript für kleinere Datenmengen immer die geringste Laufzeit aufwies. Da {polars} das jüngste der betrachteten R-Packages ist, vermuten wir Performanzprobleme in der vorliegenden Version 1.0.1¹⁴. Zudem hat es noch größere Entwicklungsaufwände beansprucht, da der an Python angelehnte Syntaxstil deutlich von üblicher Programmierung in R abweicht. Öffentliche Hilfestellung bezieht sich hauptsächlich auf Python (oder Rust), was sich in den Antworten der KI-Chatassistenten widerspiegelt.

Klassische Methoden kommen bei der betrachteten Datenmenge bereits an ihre Grenzen. Falls in {data.table} unbedacht der vollständige Datensatz eingelesen wird, werden in unserem Anwendungsfall die verfügbaren 512 GB Arbeitsspeicher vollständig beansprucht. Wir klassische Methoden ist somit deutlich mehr Erfahrung der Nutzenden notwendig, um die relevanten Variablen manuell geschickt zu selektieren unter Beobachtung des Arbeitsspeicherverbrauchs.

Insgesamt kommen wir zu dem Ergebnis, dass {arrow} kombiniert mit {parquet} im Gesamtpaket die beste Datenverarbeitungsmethode für die Bewältigung unserer Aufgaben aus den folgenden Gründen ist:

1. Für die relevanteste Datenmenge zeigte {arrow} die geringsten Laufzeiten unter 5 Sekunden, was der Fachstatistik Antworten auf Sonderanfragen in Echtzeit ermöglicht und der Wissenschaft alle denkbaren explorativen Analysen.
 2. auch die Nutzererfahrung war mit {arrow} am besten und die damit einhergehenden Entwicklungsaufwände waren dadurch am geringsten.
 3. die anschauliche {tidyverse} Syntax lässt sich zum Großteil änderungsfrei und ohne Performanzverluste auf {arrow} übertragen. {duckdb} kann bei Kenntnissen in SQL zu bevorzugen sein und {polars} mit Erfahrungen in Python.
 4. Beide Anwendungen ließen sich in unter 20 nachvollziehbaren Zeilen in {arrow} programmieren.
 5. Obwohl nicht alle Features aus {tidyverse} für {arrow} verfügbar sind, haben wir bisher immer eine Lösung gefunden, um die gewünschte Auswertung umzusetzen, bspw. durch Kombination mit {duckdb}.
 6. {arrow} spart ausreichend Arbeitsspeicher (mit Verbrauch unter 1 GB) (tba: Fußnote zu duckdb/polars). Der Arbeitsspeicherverbrauch von {arrow} ist in unserer Auswertung nahezu konstant abhängig von der Datenmenge, sodass {arrow} leicht auf noch größere Datenmengen skalieren kann
 7. Dadurch das {arrow} die Nutzung auch von mehreren {parquet} Dateien unterstützt spart gegenüber CSV mind. 50% der Festplatte (für das reale BTP sogar 80%+) und ermöglicht schnelle Nutzung auch von Datenmengen überhalb des verfügbaren Arbeitsspeichers.
- › {arrow} zeigte im Experiment die beste Nutzenderfahrung.
- › Beide Anwendungen lassen sich in unter 20 Z. mit Arrow programmieren (verständlich lesbar) s. Opencode Repo.
 - › Leicht und verständlich - adaptiert nativ schöne {tidyverse} Syntax. Dagegen sind {duckdb} und {polars} auf Zusatzpakete angewiesen, die tlw. die Performanz reduzieren können.
 - › Flexibel, selektives Einlesen ist zwingend erforderlich
 - › hohe Stabilität, fehlende Features können durch leicht in duckdb oder in den Arbeitsspeicher überführt und dennoch ausgeführt werden
- › kleiner Nachteile: Erfahrung notwendig, da...
- › erst Datenaufteilung/selektives Einlesen die maximale Performanz erreicht
 - › aktuell nicht der volle Funktionsumfang von {tidyverse} in {arrow} abgebildet wird, sodass auf fehlende Features mit {duckdb} etc. reagiert werden muss.

¹⁴Das R-Package {polars} Version 1.0.1 war nur der erste Minor Release nach einer kompletten Überarbeitung. Inzwischen sind 5 neuere Major Releases mit diversen Performanz-Verbesserungen verfügbar.

5

Erkenntnisse des Experiments

- › Auswahl der optimalen hoch-performanten Methode erfordert eine Untersuchung in der eigenen Infrastruktur anhand eigener Daten. Jedoch bieten alle HP-Methoden für die meisten Anwendungsfälle starke Performanzgewinne und sollten eingesetzt werden (nach den vorhandenen Erfahrungen und Strukturen: tidy vs Python vs SQL). Falls die Daten in CSV unter 25% des Arbeitsspeichers sind, sind auch klassische Methoden sehr gut nutzbar (bevorzugt {data.table}).
 - › **Package für optimale Laufzeit ist nicht eindeutig.** Je nach Datenmenge hat sich die Top 3 stark unterschieden.
 - › 1e6: arrow > duckdb > DT+SEL > polars
 - › 1e5: polars > duckdb > arrow > DT+SEL
 - › 1e4: polars > data.table > arrow > readr
 - › Unerwarteterweise ist {polars} bis 1% BTP am schnellsten aber für das 10% BTP abgeschlagen (unter den schlechtesten Methoden).
- › Dagegen ist **das effizienteste betrachtete Datenformat über 1000 Beobachtungen eindeutig Parquet** – sowohl in Speicherbedarf als auch in Lese- und Schreibzeiten.
- › HP-Methoden und Optimierungen können erst ab einer Mindestdatenmenge vorteilhaft sein. Insb. Datenaufteilung bietet nur HP Methoden ab einer gewissen Datenmenge Vorteile. Für kleine Mengen überwiegt der Overhead durch das Lesen mehrerer kleiner Dateien. Klassische Methoden werden durch eine Datenaufteilung nur negativ beeinflusst.
- › **Variablenauswahl beim Einlesen ist immer vorteilhaft.** High-Performance Methoden können aber bei einer **Datenaufteilung** darauf verzichten.
- › (tba: mit obigem zusammenführen) Unter den klassischen Methoden ist {data.table} mit Variablenauswahl am effizientesten und schneller als eine schlechte Anwendung von {arrow}. D.h. ein {data.table} Profi, ist besser als ein schlechter Arrow Programmierer, der aber größeres Potenzial für Verbesserungen hat. Anfängern ist eher {arrow} zu empfehlen, da in {da-

ta.table} die Variablenauswahl abhängig von dem verfügbaren Arbeitsspeicher manuell gesteuert werden muss und daher nicht so flexibel ist.

- › 5x langsamer als {arrow}
- › Variablenauswahl ab einer gewissen Datenmenge erforderlich, da ohne 3x größer als die Eingangsdaten, dauert 2.2 min anstatt 23 Sec. -> schwierige Anwendung (Entscheidung relevanter Variablen muss vorab getroffen werden unter Beachtung der Arbeitsspeicher Restriktionen)
- › Datenaufteilung verschlechtert DT im Gegensatz zu arrow
- › {arrow} verzeiht Fehler leicht(er als DT). Denn schlecht programmiert, ist es immernoch ganz gut). Alleine durch die Datenaufteilung (vorgegeben durch die Datenbereitstellung, vorbereitet durch das FDZ), erreichen wir die Fallzahl-Berechnung in 11.73s, nur 5s über dem absoluten Optimum.
- › R-base oder readr sind immer weit abgeschlagen und zu vermeiden.
- › Wenn der RAM extrem begrenzt ist, können {poars} oder {duckdb} dennoch eingesetzt werden.

3

Anwendung auf das BTP

Anwendung der besten Methoden auf das vollständige BTP

- › Repräsentant high perf: Arrow ->
- › (optional) Datatable ohne selektives Einlesen führt zu RAM Crash (RAM-Fehler?)
- › (optional) Datatable Sel.

Real world application unserer Ergebnisse auf das Echte BTP

Ergebnis für gesamten Datensatz

-> Größere Speicherreduktion, da das echte BTP mehr fehlende Werte enthält, als anhand der externen Daten angenommen.

4

Fazit

Tabelle 4

Performanz Messungen für die Fallzahlberechnung anhand 10% des BTP

		[t]			
{arrow}	Parquet	Datenaufteilung (gleichmäßig)	229,9 MB	4,7 Sek	48,8 GB
{duckdb}	Parquet	-	4,7 MB	5,1 Sek	49,4 GB
{arrow}	Parquet	Variablenauswahl	702,1 MB	7,5 Sek	49,4 GB
{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	4,7 MB	11,7 Sek	48,1 GB
{arrow}	Parquet	-	230,4 MB	17,0 Sek	49,4 GB
{arrow}	Parquet	-	701,2 MB	20,6 Sek	49,4 GB
{data.table}	CSV	Variablenauswahl	427,5 MB	23,6 Sek	130,2 GB
{polars}	Parquet	-	3,3 MB	1,2 Min	49,4 GB
{data.table}	CSV	-	336,0 GB	2,2 Min	130,2 GB
{data.table}	CSV	Datenaufteilung (Berichtsjahr)	506,4 GB	5,0 Min	104,6 GB

Tabelle 5

Performanz Messungen für die Regressionsberechnung anhand 10% des BTP

		[t]			
{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	782,1 MB	5,2 Sek	48,1 GB
{dplyr}	CSV	Variablenauswahl	1,5 GB	1,9 Min	130,2 GB

1

Auswirkung auf IT-Infrastruktur und Beratung

Kernaussage des Artikels

Wir empfehlen eine Datenhaltung im Parquet-Format und **R** incl. {arrow} + {parquet} (bei Bedarf {duckdb}, {polars}) zu erproben und zu etablieren! Denn unsere Untersuchung demonstriert ganz neue Möglichkeiten, analytische Fragestellungen anhand großer Datenmengen in Echtzeit zu beantworten.

- › Fokus auf Hardware und Software mit größtem Mehrwert (weniger RAM und R anstatt Spark, GPUs, Datenbanken, Cloud, ...)
- › Fokus auf Maintainance und Patching von R, Parquet und hier genannte Packages {arrow}, {duckdb}, {polars}
- › Etablierung dieser Softwarelösungen kann langfristig...
 - › die Hardwareanforderungen reduzieren
 - › die Analysesoftwarevielfalt verschlanken, somit Beschaffungen einsparen (besserer Ausdruck?)
- › Schulungsangebot benötigt für *“hoch-performante Auswertungen in R”*
- › eigener Beitrag zu Open Source entscheidend, um die Etablierung zu fördern.

2

3

Auswirkungen auf die Statistikproduktion Auswirkung auf die Wissenschaft

- › Steigerung der Effizienz und Reaktionsgeschwindigkeit
- › (Vorsichtig!? Annette, lieber weg oder rein?) Vereinfachung der Statistikproduktion, durch leicht nachvollziehbaren Code und Fokus auf Wissensaufbau in R
- › Aufbau eines Datenbestands in Parquet
- › Anwendung auf weitere Produkte
 - › Überarbeitung des BTP
 - › Mindeststeuer (oder?)
 - › DRG
 - › TPP 2

4

Auswirkungen auf die FDZ

- › Berücksichtigung in Mustersyntaxen und Nutzendenberatung im FDZ Bund. Teilen von Code-Snippets und Templates fördern.
- › mögliche Vereinfachung der Betreuung (Fokus auf R, Reduktion von Performanz- und Programmierproblemen)
- › Bereitstellung von Parquet in geeigneter Aufteilung empfohlen
- › Erprobung im FDZ Bund Vorbild für andere FDZ
- › Optimierung von Hardware und Software Angebot

5

- › Verwendung von R bietet am FDZ Bund einen deutlichen **Wettbewerbsvorteil in der emp. Forschung**. Lediglich R ist (am GWAP und via KDFV) am FDZ Bund in der Lage große Datenmengen innerhalb von Sekunden zu analysieren und Datenmengen überhalb des verfügbaren Arbeitsspeicher, wie das BTP, ohne vorherige Variablenselektion auszuwerten.
 - › Vollmaterial kann statt Stichproben angeboten werden. Erleichtert die FDZ Betreuung und GWAP/KDFV-Verfügbarkeit
 - › mehr explorative oder komplexe Analysen sind in kürzerer Zeit möglich.
- › Dazu ist R als frei verfügbare Open-Source Software leicht zu lernen und {arrow} bietet hoch-performante Analysen selbst für R-Basiskenntnisse. Empfehlung an die emp. Wissenschaft, sich verstärkt mit R zu befassen.
- › Für analoge über-RAM-Verarbeitungen bietet Stata aktuell keine Lösung. SAS bietet bei weitem nicht hier gemessene Performanz von R. R hervorragende Möglichkeiten bietet Performanz und Anwenderfreundlichkeit zu übertreffen.
- › Weiteres Vorgehen: **NeSt-Pilotprojekt**. Aus dem realen Use Case Optimierung der Systemkonfiguration und Beratungsbedarfe identifizieren.

6

Schlussbemerkung

Die Analyse großer Datensätze in der amtlichen Statistik und den Forschungsdatenzen können von einem signifikanten Performanz-Boost profitieren, wenn die vorgestellten Werkzeuge adaptiert werden. **Arrow, DuckDB, Polars und Parquet** – bieten das Potenzial, die Effizienz erheblich zu steigern und neue Analysemöglichkeiten zu

eröffnen.

Der Übergang erfordert jedoch eine **koordinierte Anstrengung** von Infrastrukturbetreibern, amtlicher Statistik, Forschungsdatenzentren und Forschenden. Die systematische Wissensaufbau, Dokumentation und Verbreitung von Best Practices wird entscheidend für den Erfolg sein.

Die amtliche Statistik kann von diesen Entwicklungen in mehrfacher Hinsicht profitieren: **schnellere Erkenntnisgewinnung, umfassendere Analysen** und **effizientere Ressourcennutzung**. Dies trägt letztlich zur Stärkung der evidenzbasierten Politik- und Gesellschaftsberatung bei.

Anhang

Inhalte von Opencode.

Weitere Performancemessungen für kleinere Datenmengen.

Tabelle 6

Benchmarkergebnisse für Fallzahlen (kleine Stichproben des BTP)

			[t]			
10.000	{polars}	Parquet	-	3,3 MB	0,4 Sek	492,6 MB
10.000	{data.table}	CSV	Variablenauswahl	4,4 MB	0,7 Sek	1,3 GB
10.000	{arrow}	Parquet	Variablenauswahl	230,7 MB	1,1 Sek	492,6 MB
10.000	{readr}	CSV	Variablenauswahl	9,3 MB	1,2 Sek	1,3 GB
10.000	{arrow}	Parquet	-	229,8 MB	1,6 Sek	492,6 MB
10.000	{duckdb}	Parquet	-	4,7 MB	2,9 Sek	492,6 MB
10.000	{data.table}	CSV	-	3,4 GB	3,6 Sek	1,3 GB
10.000	{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	229,9 MB	4,2 Sek	486,9 MB
10.000	{arrow}	Parquet	-	230,4 MB	4,6 Sek	492,6 MB
10.000	{data.table}	CSV	Datenaufteilung (Berichtsjahr)	5,1 GB	4,8 Sek	1,0 GB
10.000	{arrow}	Parquet	Datenaufteilung (gleichmäßig)	229,9 MB	7,1 Sek	483,5 MB
10.000	{readr}	CSV	-	1,7 GB	8,6 Sek	1,3 GB
10.000	{arrow}	CSV	-	27,4 MB	15,7 Sek	1,3 GB
10.000	{data.table}	CSV.GZ	-	4,7 GB	21,2 Sek	421,9 MB
10.000	{base}	CSV	-	9,7 GB	4,9 Min	1,3 GB
1.000	{data.table}	CSV	Variablenauswahl	0,6 MB	0,1 Sek	129,8 MB
1.000	{readr}	CSV	Variablenauswahl	2,7 MB	0,2 Sek	129,8 MB
1.000	{polars}	Parquet	-	3,3 MB	0,4 Sek	48,1 MB
1.000	{data.table}	CSV	-	341,8 MB	0,9 Sek	129,8 MB
1.000	{duckdb}	Parquet	-	4,7 MB	1,1 Sek	48,1 MB
1.000	{arrow}	Parquet	Variablenauswahl	226,2 MB	1,2 Sek	48,1 MB
1.000	{arrow}	Parquet	-	225,3 MB	1,4 Sek	48,1 MB
1.000	{arrow}	CSV	-	3,5 MB	1,5 Sek	129,8 MB
1.000	{data.table}	CSV.GZ	-	491,7 MB	2,7 Sek	42,1 MB
1.000	{data.table}	CSV	Datenaufteilung (Berichtsjahr)	510,9 MB	2,8 Sek	104,5 MB
1.000	{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	229,9 MB	2,9 Sek	53,5 MB
1.000	{arrow}	Parquet	-	230,4 MB	3,7 Sek	48,1 MB
1.000	{arrow}	Parquet	Datenaufteilung (gleichmäßig)	229,7 MB	4,0 Sek	50,5 MB
1.000	{readr}	CSV	-	197,4 MB	4,9 Sek	129,8 MB
1.000	{base}	CSV	-	713,4 MB	23,3 Sek	129,8 MB

Tabelle 7

Benchmarkergebnisse für Regression (kleine Stichproben des BTP)

			[t]			
10.000	{dplyr}	CSV	Variablenauswahl	17,6 MB	1,3 Sek	1,3 GB
10.000	{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	459,3 MB	5,0 Sek	486,9 MB
10.000	{dplyr}	CSV	-	1,8 GB	10,8 Sek	1,3 GB
1.000	{dplyr}	CSV	Variablenauswahl	4,2 MB	0,3 Sek	129,8 MB
1.000	{dplyr}	CSV	-	206,9 MB	6,4 Sek	129,8 MB
1.000	{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	452,5 MB	6,8 Sek	53,5 MB

Literatur

Statistisches Bundesamt (2023). *Qualitätshandbuch der amtlichen Statistik*. Version 7.0. Wiesbaden. URL: <https://www.destatis.de>.