

---

**Oliver Hauke**

ist Mathematiker und IT-Referent im Kompetenzzentrum „Analyse und Auswertung“ des Statistischen Bundesamtes. Er betreut die technische Infrastruktur des Forschungsdatenzentrums im Statistischen Bundesamt und arbeitet für das Netzwerk empirische Steuerforschung.

**Annette Kristiansen**

ist Ökonomin und Referentin im Referat „Unternehmenssteuern“ des Statistischen Bundesamtes. Sie beschäftigt sich mit der Zusammenführung der Unternehmenssteuerstatistiken und betreut das Netzwerk empirische Steuerforschung. Für ihre externe Promotion an der Universität Bremen untersucht sie die technologische Vielfalt multinationaler Unternehmen.

# EFFIZIENTE ANALYSE GROSSER FORSCHUNGSDATEN MITHILFE VON R

---

Oliver Hauke, Annette Kristiansen

---

↘ **Schlüsselwörter:** Effiziente Analysen, R Programmierung, Forschungsdaten, Unternehmenssteuerstatistik, Business-Tax-Panel, Netzwerk empirischer Steuerforschung

## ZUSAMMENFASSUNG

Die technische Infrastruktur des Forschungsdatenzentrums des Statistischen Bundesamtes wird derzeit ausgebaut, um moderne Analysetools in erweiterten Kapazitäten bereitzustellen. Der neue FDZ OnSite-Server bietet Forschenden ab November 2025 exklusiven Zugang zu diesen erweiterten Systemressourcen. Dieser Beitrag zeigt, wie mit R-basierten Tools – insbesondere Apache Arrow, Parquet und DuckDB – das volle Potenzial der neuen Infrastruktur ausgeschöpft werden kann. Am Beispiel des Business-Tax-Panel 2013 bis 2019 werden die deutlichen Effizienzgewinne bei der Auswertung umfangreicher steuerstatistischer Daten im Rahmen des Netzwerks empirischer Steuerforschung demonstriert.

↘ **Keywords:** Efficient analysis – R programming – research data – corporate tax statistics – Business Tax Panel – empirical tax research network

## ABSTRACT

*The technical infrastructure of the Research Data Centre at the Federal Statistical Office is currently being expanded to provide modern analysis tools with enhanced capacities. From November 2025, the new FDZ OnSite server will offer researchers exclusive access to these extended system resources. This paper demonstrates how R-based tools – particularly Apache Arrow, Parquet, and DuckDB – can fully leverage the new infrastructure's potential. Using the Business Tax Panel 2013–2019 as a case study, the substantial efficiency gains in analysing large-scale tax statistics within the empirical tax research network are demonstrated.*