

---

## Oliver Hauke

ist Mathematiker und IT-Referent im Kompetenzzentrum „Analyse und Auswertung“ des Statistischen Bundesamtes. Er betreut die technische Infrastruktur des Forschungsdatenzentrums im Statistischen Bundesamt und arbeitet für das Netzwerk empirische Steuerforschung.

## Annette Kristiansen

ist Ökonomin und Referentin im Referat „Unternehmenssteuern“ des Statistischen Bundesamtes. Sie beschäftigt sich mit der Zusammenführung der Unternehmenssteuerstatistiken und betreut das Netzwerk empirische Steuerforschung. Für ihre externe Promotion an der Universität Bremen untersucht sie die technologische Vielfalt multinationaler Unternehmen.

# EFFIZIENTE ANALYSE GROSSER FORSCHUNGSDATEN MITHILFE VON R

---

Oliver Hauke, Annette Kristiansen

---

🔑 **Schlüsselwörter:** Effiziente Analysen, R-Programmierung, Forschungsdaten, Unternehmenssteuerstatistik, Business-Tax-Panel, Netzwerk empirische Steuerforschung

## ZUSAMMENFASSUNG

Das Forschungsdatenzentrum des Statistischen Bundesamtes baut seine technische Infrastruktur gezielt aus, um der Wissenschaft erweiterte Analysemöglichkeiten amtlicher Daten bereitzustellen. Ab November 2025 steht Forschenden exklusiver Zugang zu diesen erweiterten Systemressourcen in R und Stata zur Verfügung. R-basierte Tools – insbesondere Apache Arrow, Parquet und DuckDB – ermöglichen es, gängige Analysen großer Forschungsdatensätze in Echtzeit auszuführen. Am Beispiel des Business-Tax-Panel (2013 bis 2019) werden die erzielbaren Effizienzgewinne bei der Auswertung umfangreicher steuerstatistischer Daten im Rahmen des Netzwerks empirische Steuerforschung demonstriert.

🔑 **Keywords:** Efficient analysis – R programming – research data – corporate tax statistics – Business Tax Panel – empirical tax research network

## ABSTRACT

*The Research Data Centre at the Federal Statistical Office is expanding its technical infrastructure to provide researchers with enhanced analytical capabilities for official data. From November 2025, researchers will have exclusive access to these extended system resources in R and Stata. R-based tools – particularly Apache Arrow, Parquet, and DuckDB – enable real-time analysis of large research datasets. Using the Business Tax Panel (2013–2019), the achievable efficiency gains in analysing large-scale tax statistics within the empirical tax research network are demonstrated.*

## 1

## Einleitung

### 1.1 Motivation und Zielsetzung

Die amtliche Statistik steht vor der Herausforderung, bei stetig wachsenden Datenmengen und sich ändernden Nutzeranforderungen qualitativ hochwertige und zeitnahe statistische Informationen bereitzustellen (Statistisches Bundesamt 2023). Dabei spielt die Effizienz der verwendeten statistischen Verfahren eine zentrale Rolle für die Leistungsfähigkeit des gesamten statistischen Systems.

In den vergangenen Jahren haben sich die Rahmenbedingungen für die Produktion amtlicher Statistiken erheblich verändert. Die Digitalisierung hat nicht nur zu einer Vervielfachung der verfügbaren Datenquellen geführt, sondern auch neue Möglichkeiten für die statistische Analyse eröffnet. Gleichzeitig sind die Erwartungen der Nutzer an Aktualität und Detailliertheit der Statistiken gestiegen.

Diese Entwicklungen erfordern eine kontinuierliche Evaluation und Optimierung der eingesetzten Verfahren. Ziel der vorliegenden Studie ist es daher, die Effizienz verschiedener statistischer Verfahren systematisch zu bewerten und Handlungsempfehlungen für die Praxis abzuleiten.

### 1.2 Forschungsfragen

Die Untersuchung fokussiert sich auf folgende zentrale Forschungsfragen:

1. **Methodische Effizienz:** Wie unterscheiden sich verschiedene statistische Verfahren hinsichtlich ihrer Rechenzeit und Speicheranforderungen bei gleichbleibender Ergebnisqualität?
2. **Skalierbarkeit:** Welche Verfahren zeigen die beste Performance bei wachsenden Datenmengen, und wo liegen die kritischen Grenzen?
3. **Praktische Anwendbarkeit:** Welche Infrastrukturanforderungen stellen moderne Auswertungsmethoden an Forschungsdatenzentren?

### 1.3 Aufbau der Arbeit

Die Arbeit gliedert sich wie folgt: Nach dieser Einleitung wird in Kapitel 2 der Anwendungsfall Business-Tax-Panel vorgestellt, der als empirisches Beispiel für die Analysen dient. Kapitel 3 beschreibt die Infrastruktur des

Forschungsdatenzentrums des Bundes (FDZ-Bund), in der die Auswertungen durchgeführt werden.

In Kapitel 4 werden verschiedene effiziente Auswertungsmethoden vorgestellt und deren theoretische Grundlagen erläutert. Kapitel 5 präsentiert die empirischen Performanzergebnisse der verschiedenen Ansätze. Die Arbeit schließt mit einem Ausblick auf zukünftige Entwicklungen in Kapitel 6.

Die Analyse basiert auf einer umfangreichen empirischen Studie, die verschiedene statistische Verfahren anhand realer Datensätze aus der amtlichen Statistik vergleicht. Dabei werden sowohl etablierte als auch neuere Ansätze berücksichtigt, um ein vollständiges Bild der verfügbaren Optionen zu zeichnen.

## 2

## Anwendungsfall Business-Tax-Panel

### 2.1 Überblick zum Business-Tax-Panel

Das Business-Tax-Panel (BTP) ist ein zentraler Forschungsdatensatz des Statistischen Bundesamtes, der umfassende Informationen zur Unternehmensbesteuerung in Deutschland bereitstellt. Das Panel kombiniert Daten aus verschiedenen Steuerstatistiken miteinander und ermöglicht somit eine umfassende Analyse der Besteuerung von Unternehmen über Zeit.

Im BTP werden folgende Datensätze zusammengeführt:

- **Gewerbesteuerstatistik** (EVAS-Nr. 73511)
- **Körperschaftsteuerstatistik** (EVAS-Nr. 73211)
- **Umsatzsteuerstatistik - Voranmeldungen** (EVAS-Nr. 73311)
- **Statistik über Personengesellschaften und Gemeinschaften** (EVAS-Nr. 73121)
- **Umsatzsteuerstatistik - Veranlagungen** (EVAS-Nr. 73321)
- **Einnahmenüberschussrechnung** aus der Lohn- und Einkommensteuerstatistik (EVAS-Nr. 73111)
- Merkmale aus dem **Statistischen Unternehmensregister** (EVAS-Nr. 52111)

### 2.2 Datenstruktur und Umfang

#### Dimensionen des Datensatzes.

Das BTP umfasst einen außergewöhnlich umfangreichen Datensatz mit beeindruckenden Dimensionen:

#### Hauptmerkmale des Datensatzes.

Tabelle 1: Übersicht über die Dimensionen des Business-Tax-Panel

| Merkmal                      | Wert                                |
|------------------------------|-------------------------------------|
| Beobachtungszeitraum         | 2013-2019 (jährliche Erweiterung)   |
| Anzahl Einheiten (2013-2019) | >66 Millionen                       |
| Anzahl Merkmale              | >2.700                              |
| Erhebungsart                 | Vollerhebung                        |
| Datenquelle                  | Sekundärerhebung (Finanzverwaltung) |

Aus den verschiedenen Steuervordrucken und darin verwendeten Kennzahlen werden über 2.700 Merkmale erfasst, die verschiedene Aspekte der Unternehmensbesteuerung abbilden:

- **Steuerliche Kennzahlen:** Bemessungsgrundlagen, Steuerbeträge, Vorsteuern aus verschiedenen Steuerarten
- **Wirtschaftliche Kennzahlen:** Umsätze, Gewinne, Betriebsausgaben
- **Strukturmerkmale:** Rechtsform, Wirtschaftszweig, Größenklassen
- **Geografische Informationen:** Bundesland, Gemeindekennziffer
- **Panelstruktur:** Längsschnittinformationen ermöglichen Zeitreihenanalysen

### Datenerhebung und Rechtsgrundlage.

Die im BTP enthaltenen Steuerstatistiken sind Bundesstatistiken, die als **Vollerhebung** durchgeführt werden. Es handelt sich um **Sekundärerhebungen**: Die Erhebungsmerkmale werden aus den Voranmeldungs- und Veranlagungsbescheiden von der Finanzverwaltung entnommen und über deren Rechenzentren an die Statistischen Ämter der Länder übermittelt.

Rechtsgrundlage ist das [Gesetz über Steuerstatistiken \(StStatG\)](#) vom 11. Oktober 1995.

### 2.3 Forschungspotenzial und Nutzung

#### Typische Forschungsfragen.

Das BTP wird für eine Vielzahl von Forschungsfragen genutzt:

1. **Steuerliche Analysen:** Effekte von Steuerreformen auf Unternehmensentscheidungen
2. **Unternehmensdynamik:** Gründungen, Wachstum und Marktaustritte

3. **Wirtschaftsstruktur:** Branchenentwicklung und regionale Unterschiede
4. **Krisenanalysen:** Auswirkungen von wirtschaftlichen Schocks auf Unternehmen

#### Herausforderungen bei der Datenauswertung.

Die Größe und Komplexität des BTP stellt besondere Anforderungen an die Auswertungsinfrastruktur:

- **Rechenleistung:** Analysen über den gesamten Datensatz erfordern erhebliche Rechenkapazitäten
- **Speicherbedarf:** Das Vorhalten des Datensatzes im Arbeitsspeicher ist oft nicht möglich
- **Komplexe Verknüpfungen:** Die Zusammenführung verschiedener Datenquellen erfordert effiziente Join-Operationen
- **Datenschutz:** Strenge Anforderungen an den Umgang mit sensiblen Unternehmensdaten

### 2.4 Zugangsformen im FDZ

Das BTP ist über verschiedene Zugangsformen verfügbar:

- **Gastwissenschaftsarbeitsplatz (GWAP):** On-Site-Zugang mit vollständigen Daten, auswertbar mit SAS oder Stata. Bedingt durch die Speicherplatzgröße kann die Nutzung einer Stichprobe erforderlich sein.
- **Kontrollierte Datenfernverarbeitung (KDFV):** Remote-Zugang mit Ergebnisfreigabe über KDFV
- Die Gemeindekennziffer für Bayern steht am GWAP lediglich pseudonymisiert zur Verfügung

### 2.5 BTP als Benchmark-Datensatz

Aufgrund seiner Größe (>66 Millionen Einheiten), Komplexität (>2.700 Variablen) und realen Datenstruktur eignet sich das BTP hervorragend als Benchmark für die Evaluation verschiedener Auswertungsmethoden. Die Herausforderungen des BTP sind repräsentativ für viele Forschungsprojekte im FDZ:

- **Datengröße:** Der Datensatz übersteigt oft die verfügbare RAM-Kapazität
- **Komplexe Joins:** Verknüpfung verschiedener Steuerstatistiken erforderlich
- **Aggregationen:** Über verschiedene Dimensionen (Zeit, Region, Wirtschaftszweig)
- **Filteroperationen:** Selektion relevanter Unternehmensgruppen
- **Zeitreihenanalysen:** Panel-Struktur über mehrere Jahre

Diese realitätsnahen Szenarien ermöglichen es, die Praxistauglichkeit verschiedener Auswertungsmethoden unter

den tatsächlichen Bedingungen eines Forschungsdatenzentrums zu bewerten.

### 3

## Infrastruktur des FDZ-Bund

### 3.1 Die Forschungsdatenzentren der amtlichen Statistik

Die Forschungsdatenzentren (FDZ) der amtlichen Statistik bestehen aus zwei organisatorisch voneinander getrennten Einrichtungen: dem **Forschungsdatenzentrum des Statistischen Bundesamts** und dem **Forschungsdatenzentrum der Statistischen Ämter der Länder**. Beide FDZ arbeiten eng zusammen und bieten ein abgestimmtes Daten- und Dienstleistungsangebot für die wissenschaftliche Nutzung von Mikrodaten der amtlichen Statistiken.

#### Entstehung und Entwicklung.

Die Gründung der FDZ geht auf ein Gutachten der „Kommission zur Verbesserung der informationellen Infrastruktur zwischen Wissenschaft und Statistik“ (KVI) von 1999 zurück. Mit finanzieller Förderung des Bundesministeriums für Bildung und Forschung (BMBF) wurde im Herbst 2001 zunächst das FDZ des Statistischen Bundesamts gegründet. Das FDZ der Statistischen Ämter der Länder folgte im April 2002.

#### Aufgaben und Ziele.

Die FDZ verfolgen das Ziel, den Zugang zu Mikrodaten der amtlichen Statistik für die Wissenschaft nicht nur zu ermöglichen, sondern fortlaufend zu verbessern und an die sich ändernden Bedarfe anzupassen:

- **Datenzugang:** Bereitstellung hochwertiger Mikrodaten für die wissenschaftliche Forschung
- **Datenschutz:** Gewährleistung des Schutzes personenbezogener und unternehmensbezogener Daten nach § 16 BStatG
- **Beratung:** Unterstützung der Forschenden bei der Datennutzung und methodischen Fragen
- **Infrastruktur:** Bereitstellung einer sicheren und leistungsfähigen Auswertungsumgebung
- **Regionalisierung:** Flächendeckende Standorte in ganz Deutschland für kurze Anfahrtswege

### 3.2 Technische Infrastruktur

#### Hardware-Ausstattung.

Die technische Infrastruktur des FDZ-Bund umfasst verschiedene Systemkomponenten:

#### Software-Umgebung.

Den Forschenden stehen verschiedene Software-Tools zur Verfügung:

- **Statistische Software:** R, Python, Stata, SAS, SPSS
- **Datenbanksysteme:** PostgreSQL, DuckDB
- **Entwicklungsumgebungen:** RStudio Server, JupyterLab
- **Versionskontrolle:** Git (lokal, ohne externe Verbindung)

### 3.3 Infrastrukturkonzept

#### Fachlich zentralisierte Datenhaltung.

In Deutschland wird der überwiegende Teil der amtlichen Statistikproduktion dezentral in den Statistischen Ämtern der Länder durchgeführt (über 90% aller amtlichen Statistiken). Da sich wissenschaftliche Analysen in der Regel jedoch auf mehrere Bundesländer oder das gesamte Bundesgebiet beziehen, haben die FDZ eine **fachlich zentralisierte Datenhaltung** eingerichtet. Diese ermöglicht es, die Daten des gesamten Bundesgebiets länderübergreifend an jedem Standort bereitzustellen.

#### Regionalisierte Infrastruktur.

Die FDZ verfolgen das Ziel, immer in der Nähe der Wissenschaft zu sein. Dies wird durch über ganz Deutschland verteilte Standorte erreicht. Standorte befinden sich u.a. in:

- Berlin, Bonn, Wiesbaden (Bund)
- Bad Ems, Bremen, Dresden, Düsseldorf, Erfurt, Frankfurt, Hamburg, Hannover, Kiel, München, Stuttgart u.v.m. (Länder)

### 3.4 Zugangsformen und Nutzungsmodelle

Die FDZ bieten verschiedene Zugangswege an, über die unterschiedlich anonymisierte Datenprodukte bereitgestellt werden:

#### Off-Site-Zugang.

- **Public Use Files (PUF):** Stark anonymisierte Daten für freie Nutzung
- **Scientific Use Files (SUF):** Faktisch anonymisierte Daten für wissenschaftliche Zwecke
- **Remote Scientific Use Files (Remote-SUF):** Neuer Zugangsweg mit höherer Detailtiefe

#### On-Site-Zugang.

Tabelle 2: Technische Ausstattung des FDZ-Bund (beispielhafte Konfiguration)

| Komponente                 | Spezifikation                                            | Anzahl |
|----------------------------|----------------------------------------------------------|--------|
| Rechenknoten (Standard)    | 2x Intel Xeon Gold 6248R (48 Kerne), 384 GB RAM          | 12     |
| Rechenknoten (High-Memory) | 2x Intel Xeon Platinum 8280 (56 Kerne), 1,5 TB RAM       | 4      |
| Speichersystem             | NAS-System mit 500 TB nutzbarem Speicher                 | 1      |
| Netzwerk                   | 10 Gbit/s Ethernet, InfiniBand für parallele Operationen | -      |
| Backup-System              | Tägliches Backup, räumlich getrennte Archivierung        | -      |

- **Gastwissenschaftsarbeitsplatz (GWAP):** Zugang zu formal anonymisierten Daten vor Ort
  - Vorteile: Höchste Datendetailtiefe, direkte Beratung
  - Anforderungen: Terminvereinbarung, Zutrittskontrolle, Output-Kontrolle
- **Kontrollierte Datenfernverarbeitung (KDFV):** Remote-Ausführung von Analyseskripten
  - Vorteile: Keine Anreise, zeitlich flexibel
  - Einschränkungen: Keine interaktive Arbeit, Ergebnisfreigabe erforderlich

### 3.5 Datenschutz und Sicherheit

#### Mehrstufiges Sicherheitskonzept.

Das FDZ-Bund implementiert ein umfassendes Sicherheitskonzept:

1. **Physische Sicherheit:** Zutrittskontrolle, gesicherte Räumlichkeiten
2. **Netzwerksicherheit:** Isolierte Netzwerke, Firewalls, Intrusion Detection
3. **Zugriffsrechte:** Rollenbasierte Zugriffskontrolle, Authentifizierung
4. **Output-Kontrolle:** Prüfung aller Ergebnisse vor Freigabe
5. **Audit-Logging:** Protokollierung aller Zugriffe und Operationen

#### Output-Kontrolle.

Bevor Forschungsergebnisse das FDZ verlassen dürfen, durchlaufen sie eine mehrstufige Kontrolle:

- **Automatische Prüfung:** Screening auf kritische Werte (z.B. Fallzahlen < 5)
- **Manuelle Prüfung:** Sichtung durch geschulte Mitarbeiter
- **Dokumentation:** Nachvollziehbare Begründung der Freigabeentscheidung

### 3.6 Performanz-Optimierung in der FDZ-Umgebung

#### Herausforderungen.

Die Arbeit in der geschützten FDZ-Umgebung stellt besondere Anforderungen:

- **Begrenzte Ressourcen:** Mehrere Nutzer teilen sich die verfügbare Hardware
- **Keine Cloud-Dienste:** Externe Rechenressourcen können nicht genutzt werden
- **Datengröße:** Große Datensätze müssen effizient verarbeitet werden
- **Reproduzierbarkeit:** Analysen müssen dokumentiert und nachvollziehbar sein

#### Optimierungsstrategien.

Verschiedene Strategien helfen, die Performanz zu optimieren:

\*[htbp]




Abbildung 1: Strategien zur Performanz-Optimierung im FDZ-Bund

\*

### 3.7 Akkreditierung und Qualitätssicherung

Die Forschungsdatenzentren der Statistischen Ämter des Bundes und der Länder sind durch den **Rat für Sozial- und Wirtschaftsdaten (RatSWD)** akkreditiert. Der RatSWD akkreditiert seit 2008 Forschungsdatenzentren, die den Zugang zu qualitativ hochwertigen sensiblen Daten für die Wissenschaft ermöglichen und dabei die erforderlichen Kriterien erfüllen.



### 3.8 Best Practices für FDZ-Nutzende

Aus der Erfahrung mit den FDZ lassen sich folgende Empfehlungen für effizientes Arbeiten ableiten:

1. **Datenreduktion:** Frühzeitige Filterung auf relevante Beobachtungen und Variablen
2. **Inkrementelle Entwicklung:** Erst mit Stichproben arbeiten, dann auf Vollsatz skalieren
3. **Effiziente Datenformate:** Nutzung moderner Formate (Arrow/Parquet) statt CSV
4. **Dokumentation:** Sorgfältige Dokumentation des Analyseprozesses für Output-Kontrolle
5. **Ressourcenplanung:** Bewusste Planung rechenintensiver Operationen bei geteilter Infrastruktur
6. **Beratung nutzen:** Frühzeitige Kontaktaufnahme mit FDZ-Mitarbeitern bei methodischen Fragen

## 4

## Effiziente Auswertungsmethoden

### 4.1 Motivation

Die Analyse großer Datensätze wie des BTP (>66 Millionen Einheiten, >2.700 Variablen) in der FDZ-Umgebung stellt besondere Anforderungen an die verwendeten Werkzeuge. Traditionelle Ansätze (CSV-Dateien, Base R) stoßen bei dieser Datengröße an ihre Grenzen. Moderne spaltenorientierte Technologien bieten hier deutliche Vorteile.

### 4.2 Apache Arrow: Spaltenorientiertes In-Memory-Format

#### Grundprinzip.

Apache Arrow ist ein sprach- und plattformübergreifendes In-Memory-Format für spaltenorientierte Datenverarbeitung. Im Gegensatz zu zeilenorientierten Formaten werden Daten spaltenweise organisiert, was erhebliche Vorteile bietet:

- **Effiziente Kompression:** Ähnliche Werte in einer Spalte lassen sich besser komprimieren
- **Schnellere Aggregationen:** Nur benötigte Spalten müssen gelesen werden (Columnar Scanning)
- **Zero-Copy:** Daten können ohne Kopieren zwischen Prozessen und Sprachen ausgetauscht werden
- **SIMD-Optimierung:** Moderne CPU-Instruktionen können effizient genutzt werden

#### Anwendung in R.

Das **arrow**-Paket in R bietet vollständige Integration:

```
library(arrow)

## Lesen eines Parquet-Datasets mit Filterung
dataset <- open_dataset("btp_data.parquet")

result <- dataset |>
  filter(year >= 2015, sector == "Manufacturing") |>
  select(company_id, year, revenue, employees) |>
  group_by(year) |>
  summarise(
    total_revenue = sum(revenue),
    mean_employees = mean(employees)
  ) |>
  collect() # Erst hier wird die Berechnung ausgeführt
```

#### Vorteile für FDZ-Analysen.

- **Out-of-Core Processing:** Datensätze müssen nicht vollständig in den RAM passen
- **Lazy Evaluation:** Operationen werden optimiert, bevor sie ausgeführt werden
- **Predicate Pushdown:** Filter werden direkt beim Lesen angewendet
- **Partitionierung:** Datensätze können nach Kriterien (z.B. Jahr) partitioniert werden

#### Limitationen.

- **Lernkurve:** Neue Syntax für Nutzer mit Base-R-Erfahrung
- **Noch in Entwicklung:** Nicht alle R-Funktionen werden unterstützt
- **Setup-Aufwand:** Daten müssen einmalig ins Parquet-Format konvertiert werden

### 4.3 Parquet: Persistentes spaltenorientiertes Format

#### Eigenschaften.

Parquet ist ein spaltenorientiertes Speicherformat, das optimal mit Arrow zusammenarbeitet:

- **Kompression:** Typischerweise 5-10x kleinere Dateien als CSV
- **Metadaten:** Enthält Schema-Informationen und Statistiken
- **Partitionierung:** Ermöglicht selektives Lesen nach Partitionskeys
- **Kompatibilität:** Von vielen Tools unterstützt (R, Python, Spark, DuckDB)

#### Vergleich zu Alternativen.

#### Empfehlung für FDZ.

Tabelle 3: Vergleich verschiedener Datenformate für die BTP-Analyse

| Format                  | Größe | Ladezeit                | Kompression  | Partitionierung | Kompatibilität   |
|-------------------------|-------|-------------------------|--------------|-----------------|------------------|
| CSV                     | 100%  | Sehr langsam            | Keine        | Nein            | Universal        |
| RDS (R)                 | 45%   | Mittel                  | Gzip         | Nein            | Nur R            |
| Feather                 | 95%   | Sehr schnell            | LZ4/ZSTD     | Nein            | Arrow-Oekosystem |
| Parquet                 | 15%   | Schnell                 | Snap-py/GZIP | Möglich         | Sehr hoch        |
| Parquet (partitioniert) | 15%   | Sehr schnell (selektiv) | Snap-py/GZIP | Ja              | Sehr hoch        |

**Parquet ist das empfohlene Format für große Datensätze im FDZ** wegen:

1. Drastischer Reduktion der Dateigröße (wichtig bei begrenztem Speicherplatz)
2. Deutlich schnelleren Ladezeiten
3. Möglichkeit der selektiven Filterung ohne vollständiges Laden
4. Kompatibilität mit verschiedenen Analysewerkzeugen

#### 4.4 DuckDB: Analytical Database System

##### Konzept.

DuckDB ist ein einbettbares analytisches Datenbanksystem, speziell für OLAP-Workloads (Online Analytical Processing) entwickelt:

- **In-Process:** Läuft im gleichen Prozess wie R (keine separate Datenbank-Server-Installation nötig)
- **Columnar Vectorized:** Spaltenorientierte Verarbeitung in SIMD-optimierten Batches
- **SQL-Interface:** Bekannte SQL-Syntax für komplexe Abfragen
- **Arrow-Integration:** Zero-Copy-Integration mit Arrow-Daten

##### Warum DuckDB?

DuckDB löst spezifische Probleme bei der Analyse großer Datensätze:

1. **Komplexe Aggregationen:** Window Functions, CTEs, komplexe Joins

2. **SQL-Komfort:** Mächtige Abfragesprache statt R-Code für Datentransformationen
3. **Out-of-Core:** Kann größere Daten als RAM verarbeiten
4. **Geschwindigkeit:** Hochoptimierte Query Engine

##### Anwendungsbeispiel.

```
library(duckdb)
library(arrow)

## Verbindung erstellen
con <- dbConnect(duckdb::duckdb())

## Arrow-Dataset registrieren (ohne Laden)
duckdb_register_arrow(con, "btp", arrow_dataset)

## Komplexe SQL-Abfrage
result <- dbGetQuery(con, "
SELECT
  year,
  sector,
  COUNT(*) as n_companies,
  MEDIAN(revenue) as median_revenue,
  PERCENTILE_CONT(0.9) WITHIN GROUP (ORDER BY revenue) as p90_revenue,
  LAG(MEDIAN(revenue)) OVER (
    PARTITION BY sector
    ORDER BY year
  ) as prev_year_median
FROM btp
WHERE year BETWEEN 2015 AND 2019
AND revenue > 0
GROUP BY year, sector
ORDER BY year, sector
")

dbDisconnect(con, shutdown = TRUE)
```

##### Vorteile.

- **Kein Setup:** Keine separate Datenbank-Installation erforderlich
- **Hohe Performance:** Oft schneller als spezialisierte Data-Frame-Bibliotheken
- **SQL-Funktionen:** Umfangreiche Funktionen (Window Functions, Array-Operationen)
- **Ressourceneffizient:** Intelligentes Memory Management
- **R-Integration:** Direktes Arbeiten mit Arrow-Datasets oder R-Data-Frames

##### Limitationen.

- **SQL-Kenntnisse:** Erfordert SQL-Grundkenntnisse
- **Debugging:** SQL-Fehler können schwerer zu debuggen sein als R-Code

- **Noch jung:** Weniger etabliert als traditionelle Datenbanken (aber sehr aktiv entwickelt)

#### 4.5 Vergleich mit Alternativen

##### Base R.

**Vorteile:** Einfach, weit verbreitet, keine zusätzlichen Abhängigkeiten **Nachteile:** Langsam bei großen Daten, hoher Speicherverbrauch, alle Daten müssen in RAM passen

**Empfehlung:** Nur für kleine Datensätze (<1 GB) oder wenn Kompatibilität wichtiger als Performance ist

##### data.table.

**Vorteile:** Sehr schnell für In-Memory-Operationen, ausgereift, kompakte Syntax **Nachteile:** Alle Daten müssen in RAM passen, steile Lernkurve, keine Out-of-Core-Unterstützung

**Empfehlung:** Gute Alternative wenn Datensatz in RAM passt und keine Parquet-Integration benötigt wird

##### dplyr + dbplyr.

**Vorteile:** Vertraute dplyr-Syntax, gut mit Datenbanken integriert **Nachteile:** Langsamer als Arrow/DuckDB, benötigt Backend-Datenbank, SQL-Translation manchmal limitiert

**Empfehlung:** Wenn bereits PostgreSQL- oder ähnliche Datenbank-Infrastruktur vorhanden ist

#### 4.6 Unsere Empfehlung: Arrow + DuckDB + Parquet

Für die Analyse großer Datensätze im FDZ empfehlen wir die Kombination:

1. **Datenspeicherung:** Parquet-Format, idealerweise partitioniert nach relevanten Dimensionen (z.B. Jahr)
2. **Datenmanipulation:** Arrow für einfache Filter/Select-Operationen
3. **Komplexe Analysen:** DuckDB für Aggregationen, Joins, Window Functions
4. **Ergebnisse:** R-Data-Frames für finale Visualisierung und Modellierung

##### Workflow-Beispiel.

```
library(arrow)
library(duckdb)

## 1. Daten als Parquet-Dataset öffnen
btp <- open_dataset("data/btp.parquet")
```

```
## 2. Einfache Filterung mit Arrow
filtered <- btp |>
  filter(year >= 2015, revenue > 0) |>
  select(year, sector, revenue, employees)

## 3. Komplexe Aggregation mit DuckDB
con <- dbConnect(duckdb::duckdb())
duckdb_register_arrow(con, "btp_filtered", filtered)

result <- dbGetQuery(con, "
  SELECT sector,
         AVG(revenue) as mean_revenue,
         STDDEV(revenue) as sd_revenue
  FROM btp_filtered
  GROUP BY sector
  HAVING COUNT(*) >= 30
")

## 4. Aufräumen
dbDisconnect(con, shutdown = TRUE)

## 5. Weiterverarbeitung in R
result <- result |>
  mutate(cv = sd_revenue / mean_revenue)
```

Dieser Workflow kombiniert die Stärken aller Werkzeuge und ist optimal für FDZ-Bedingungen geeignet.

## 5

### Performanzergebnisse

#### 5.1 Experimentelles Setup

Die Performanzmessungen wurden auf einem repräsentativen FDZ-System durchgeführt (2x Intel Xeon Gold 6248R, 48 Kerne, 384 GB RAM, Ubuntu 22.04 LTS). Alle Tests wurden mit R 4.3.2 und aktuellen Versionen der verwendeten Pakete durchgeführt.

##### Test-Szenarien.

Die Evaluation umfasst realistische Auswertungsszenarien aus dem BTP:

1. **Szenario A: Einfache Aggregation** - Jahressummen nach Wirtschaftszweig
2. **Szenario B: Komplexe Aggregation** - Multidimensionale Gruppierung mit mehreren Kennzahlen
3. **Szenario C: Join-Operation** - Verknüpfung zweier großer Tabellen
4. **Szenario D: Filterkette** - Mehrere aufeinanderfolgende Filter- und Transformationsoperationen



Tabelle 4: Ausführungszeiten für Szenario A: Einfache Aggregation (in Sekunden)

| Ansatz                                     | Laden | Aggregation | Gesamt | Speedup |
|--------------------------------------------|-------|-------------|--------|---------|
| Base R<br>(read.csv<br>+ aggregate)        | 45.2  | 18.7        | 63.9   | 1.0     |
| data.table<br>(fread +<br>group-by)        | 12.1  | 2.3         | 14.4   | 4.4     |
| dplyr +<br>CSV                             | 43.8  | 8.9         | 52.7   | 1.2     |
| Arrow +<br>Parquet                         | 4.8   | 1.2         | 6.0    | 10.7    |
| DuckDB                                     | 0.3   | 0.8         | 1.1    | 58.1    |
| +<br>Parquet                               |       |             |        |         |
| Arrow +<br>Parquet<br>(parti-<br>tioniert) | 0.2   | 0.5         | 0.7    | 91.3    |

5.2 Vergleich der Datenformate

Ladezeiten und Speicherverbrauch.

\*[htbp]




Abbildung 2: Ladezeiten verschiedener Datenformate (BTP-Datensatz, 5 Mio. Zeilen, 50 Variablen)

\*

Aggregations-Performance.

5.3 Skalierungsverhalten

Performance bei wachsender Datenmenge.

\*[htbp]




Abbildung 3: Skalierungsverhalten verschiedener Ansätze (Szenario B: Komplexe Aggregation)

\*

5.4 Join-Performance

Verschiedene Join-Strategien.

Die Verknüpfung großer Datensätze ist eine häufige Operation bei der Arbeit mit dem BTP:

\*[htbp]




Abbildung 4: Join-Performance bei verschiedenen Datensatzgrößen (Inner Join zweier Tabellen)

\*

5.5 Parallelisierungs-Effizienz

Speedup durch Multi-Threading.

5.6 Speichereffizienz

Memory Footprint.

Tabelle 5: Speedup durch Parallelisierung (Szenario D: Filterkette, 10 Mio. Zeilen)

| Kerne | Arrow<br>(s) | DuckDB<br>(s) | Arrow<br>Speedup | DuckDB<br>Speedup |
|-------|--------------|---------------|------------------|-------------------|
| 1     | 25.3         | 9.8           | 1.0              | 1.0               |
| 2     | 13.2         | 5.1           | 1.9              | 1.9               |
| 4     | 7.1          | 2.7           | 3.6              | 3.6               |
| 8     | 3.9          | 1.5           | 6.5              | 6.5               |
| 16    | 2.3          | 0.9           | 11.0             | 10.9              |
| 32    | 1.8          | 0.7           | 14.1             | 14.0              |




Abbildung 5: Peak Memory Usage verschiedener Ansätze (5 Mio. Zeilen)

Ein kritischer Faktor in der FDZ-Umgebung ist der Speicherverbrauch:

\*

5.7 Praktische Implikationen

Empfehlungen nach Anwendungsfall.

Basierend auf den Performanzmessungen lassen sich folgende Empfehlungen ableiten:

5.8 Zusammenfassung der Erkenntnisse

Die empirischen Messungen zeigen deutlich:

- 1. **Moderne Formate dominieren:** Arrow/Parquet und DuckDB bieten um den Faktor 10-90x bessere Performance als traditionelle Ansätze
- 2. **Partitionierung lohnt sich:** Bei großen Datensätzen reduziert Partitionierung die Zugriffszeiten erheblich
- 3. **Query Optimization wichtig:** Lazy Evaluation und Predicate Pushdown ermöglichen dramatische

Tabelle 6: Empfohlene Werkzeuge nach Anwendungsfall

| Anwendungsfall                           | 1. Wahl         | 2. Wahl           | Begründung                                      |
|------------------------------------------|-----------------|-------------------|-------------------------------------------------|
| Kleine Datensätze (<1M Zeilen)           | data.table      | Base R            | Einfachheit, gute Performance                   |
| Explorative Analyse, häufige Iterationen | DuckDB          | Arrow             | SQL-Komfort, schnelle Iteration                 |
| Große Aggregationen (>5M Zeilen)         | DuckDB          | Arrow + Parquet   | Beste Skalierung, niedrigster Speicherverbrauch |
| Komplexe Joins                           | DuckDB          | data.table        | Optimierter Hash-Join, Index-Support            |
| Produktions-Pipelines                    | Arrow + Parquet | DuckDB            | Persistenz, Partitionierung, Reproduzierbarkeit |
| Speicherlimitierte Umgebung              | DuckDB          | Arrow (streaming) | Out-of-core Verarbeitung möglich                |

Speedups

4. **Parallelisierung skaliert gut:** Bis zu 14x Speedup mit 32 Kernen möglich
5. **Speicher ist der Engpass:** Moderne Ansätze benötigen 3-7x weniger RAM als Base R

Diese Ergebnisse zeigen, dass durch den Einsatz moderner Auswertungsmethoden die Effizienz der Datenanalyse in Forschungsdatenzentren erheblich gesteigert werden kann.

## 6

### Ausblick

#### 6.1 Zusammenfassung der Erkenntnisse

Die vorliegende Untersuchung hat gezeigt, dass moderne spaltenorientierte Technologien erhebliche Vorteile für die Analyse großer Datensätze in der amtlichen Statistik bieten. Die Kombination von **Apache Arrow**, **DuckDB** und **Parquet** ermöglicht:

- > **Drastische Reduktion der Speicheranforderungen** (typisch 5-10x Kompression gegenüber CSV)
- > **Signifikante Beschleunigung der Analysen** durch spaltenorientierte Verarbeitung
- > **Out-of-Core-Verarbeitung** für Datensätze, die den verfügbaren RAM übersteigen
- > **Effiziente Query-Optimierung** durch Lazy Evaluation und Predicate Pushdown

#### 6.2 Implikationen für die Forschungsdatenzentren

##### Infrastrukturentwicklung.

Die FDZ sollten die Integration dieser Technologien vorantreiben:

1. **Datenbereitstellung:** Zusätzlich zu SAS/Stata-Formaten auch Parquet-Versionen der Datensätze anbieten
2. **Software-Ausstattung:** R mit Arrow- und DuckDB-Paketen auf allen Systemen verfügbar machen
3. **Schulungsangebote:** Workshops und Dokumentation für Forschende bereitstellen
4. **Best-Practice-Katalog:** Erfolgreiche Analyse-muster dokumentieren und teilen

##### Nutzerunterstützung.

Forschende profitieren von:

- > **Kürzeren Analysezeiten:** Mehr explorative Analyse in kürzerer Zeit möglich

- > **Größere Datensätze handhabbar:** Vollsatz-Analysen statt Stichproben
- > **Geringere Ressourcenkonflikte:** Effizientere Nutzung geteilter Infrastruktur
- > **Reproduzierbare Workflows:** Parquet-basierte Pipelines gut dokumentierbar

#### 6.3 Technologische Entwicklungen

##### Kurz- bis mittelfristig.

Weitere Optimierungen der bestehenden Tools sind zu erwarten:

- > **Arrow-Flight:** Effizienter Datentransfer zwischen Prozessen und Systemen
- > **Substrait:** Standardisierte Query-Repräsentation für Tool-übergreifende Optimierung
- > **DuckDB Extensions:** Spezielle Module für statistische Analysen
- > **GPU-Beschleunigung:** Erste Implementierungen für Arrow-basierte Berechnungen

##### Langfristig.

Neue Paradigmen könnten zusätzliche Verbesserungen bringen:

- > **Föderated Queries:** Analyse über verteilte Datensätze ohne zentrale Zusammenführung
- > **Adaptive Execution:** Automatische Wahl der optimalen Verarbeitungsstrategie
- > **Streaming Analytics:** Echtzeitverarbeitung großer Datenströme
- > **Privacy-Preserving Computation:** Analysen auf verschlüsselten Daten

#### 6.4 Offene Forschungsfragen

Weitere Untersuchungen sollten folgende Aspekte betrachten:

1. **Statistische Software-Integration:** Wie können R-Modellierungsfunktionen optimal mit Arrow/DuckDB kombiniert werden?
2. **Datenschutz-Aspekte:** Welche Implikationen haben neue Datenformate für die Output-Kontrolle im FDZ?
3. **Qualitätssicherung:** Wie können Korrektheit und Reproduzierbarkeit bei komplexen Arrow/DuckDB-Workflows sichergestellt werden?
4. **Heterogene Systeme:** Wie lassen sich verschiedene Datenquellen und -formate optimal integrieren?

## 6.5 Handlungsempfehlungen

---

### Für Forschungsdatenzentren.

**Pilotprojekte** sollten initiiert werden:

- Ausgewählte häufig genutzte Datensätze (wie BTP) in Parquet bereitstellen
- Erfolgsmetriken definieren (Analysezeit, Ressourcenverbrauch, Nutzerzufriedenheit)
- Feedback von Power-Usern systematisch einholen
- Erkenntnisse in Qualitätsstandards überführen

### Für Forschende.

**Schrittweise Einführung** wird empfohlen:

1. Kleine Analyseprojekte als Lernumgebung nutzen
2. Kritische Analysen zunächst parallel mit bewährten Methoden durchführen
3. Performanzgewinne und Limitationen dokumentieren
4. Bei Erfolg schrittweise auf größere Projekte übertragen

## 6.6 Schlussbetrachtung

---

Die Analyse großer Datensätze in Forschungsdatenzentren steht vor einem Technologiewandel. Die hier untersuchten Werkzeuge – **Arrow, DuckDB und Parquet** – bieten das Potenzial, die Effizienz erheblich zu steigern und neue Analysemöglichkeiten zu eröffnen.

Der Übergang erfordert jedoch eine **koordinierte Anstrengung** von Infrastrukturbetreibern, Software-Entwicklern und Forschenden. Die systematische Evaluation, Dokumentation und Verbreitung von Best Practices wird entscheidend für den Erfolg sein.

Die amtliche Statistik kann von diesen Entwicklungen in mehrfacher Hinsicht profitieren: **schnellere Erkenntnisgewinnung, umfassendere Analysen und effizientere Ressourcennutzung**. Dies trägt letztlich zur Stärkung der evidenzbasierten Politik- und Gesellschaftsberatung bei.

## Literatur

---

Statistisches Bundesamt (2023). *Qualitätshandbuch der amtlichen Statistik*. Version 7.0. Wiesbaden. URL: <https://www.destatis.de>.