
Oliver Hauke

ist Mathematiker und IT-Referent im Kompetenzzentrum „Analyse und Auswertung“ des Statistischen Bundesamtes. Er verantwortet die Weiterentwicklung der technischen Infrastruktur des Forschungsdatenzentrums und berät das Netzwerk empirische Steuerforschung in der effizienten Nutzung der Systeme.

Annette Kristiansen

ist Ökonomin und Referentin im Referat „Unternehmenssteuern“ des Statistischen Bundesamtes. Sie beschäftigt sich mit der Zusammenführung der Unternehmenssteuerstatistiken und betreut das Netzwerk empirische Steuerforschung. Für ihre externe Promotion an der Universität Bremen untersucht sie die technologische Vielfalt multinationaler Unternehmen.

EFFIZIENTE ANALYSE GROSSER FORSCHUNGSDATEN MITHILFE VON R

Oliver Hauke, Annette Kristiansen

🔑 **Schlüsselwörter:** Effiziente Analysen, R-Programmierung, Forschungsdaten, Unternehmenssteuerstatistik, Business-Tax-Panel, Netzwerk empirische Steuerforschung

ZUSAMMENFASSUNG

Das Forschungsdatenzentrum des Statistischen Bundesamtes baut seine technische Infrastruktur gezielt aus, um der Wissenschaft erweiterte Analysemöglichkeiten amtlicher Daten bereitzustellen. Seit November 2025 steht Forschenden exklusiver Zugang zu diesen erweiterten Systemressourcen in R und Stata zur Verfügung. R-basierte Tools – insbesondere Apache Arrow, Parquet und DuckDB – ermöglichen es, gängige Analysen großer Forschungsdatensätze in Echtzeit auszuführen. Am Beispiel des Business-Tax-Panel (2013 bis 2019) werden die erzielbaren Effizienzgewinne bei der Auswertung umfangreicher steuerstatistischer Daten im Rahmen des Netzwerks empirische Steuerforschung demonstriert.

🔑 **Keywords:** *Efficient analysis – R programming – research data – corporate tax statistics – Business Tax Panel – empirical tax research network*

ABSTRACT

The Research Data Centre at the Federal Statistical Office is strategically expanding its technical infrastructure to provide researchers with enhanced analytical capabilities for official data. Since November 2025, researchers have had exclusive access to these extended system resources in R and Stata. R-based tools – particularly Apache Arrow, Parquet, and DuckDB – enable real-time analysis of large research datasets. Using the Business Tax Panel (2013–2019), this paper demonstrates the achievable efficiency gains in analysing large-scale tax statistics within the empirical tax research network.

Vergleich der Performanz

5.1 Benchmark-Setup

Um zwischen den in Abschnitt **2@sec-methoden** vorgestellten Datenverarbeitungsmethoden abzuwägen, haben wir deren Performanz in einem systematischen Benchmark-Experiment auf dem SAS-Server des Statistischen Bundesamtes und den neuen OnSite R- und Stata-Servern des FDZ gemessen. Weiterführende Benchmarks sowie der vollständig reproduzierbare Code sind auf [open-code.de](https://www.opencode.de) verfügbar¹.

Herangezogen wurden dafür simulierte Einzeldaten in verschiedenen Größen (0.1%/1%/10% von den insgesamt 80 Mio. Beobachtungen des BTP). Sie wurden aus öffentlich verfügbaren Informationen generiert, um die wesentlichen Strukturen des BTP für unsere Analyse künstlich nachzubilden. Abgrenzend zu den im FDZ bereitgestellten *Datenstrukturfiles* wurden die Testdaten nicht aus echten Mikrodaten abgeleitet. Der simulierte Datensatz ist ausschließlich für technische Testzwecke der nachfolgenden Anwendungsfälle bestimmt:

- 1. **Fallzahlen** (pro Statistik und Jahr)
- 2. **Regression** (Einflussfaktoren auf Verlustvorträge)

Um eine zuverlässige Performanz-Messung zu erhalten, wurde jede Datenverarbeitungsmethode dreifach angewandt. Der Vergleich erfolgt anhand der mittleren Messung der folgenden Zielgrößen:

- 1. **Arbeitsspeicher**-Beanspruchung der Auswertung,
- 2. **Laufzeit** der Auswertung (real verstrichene Zeit),
- 3. **Festplattenspeicher** der verwendeten Daten.

Die Zielgrößen sind in dieser Reihenfolge zu priorisieren, da ein übermäßiger Arbeitsspeicherverbrauch zu schwerwiegenden Abbrüchen führen kann, während längere Laufzeiten dennoch zu einem erfolgreichen Ergebnis führen können. Festplattenspeicher ist ausreichend vorhanden, aber unnötige Belegung sollte vermieden werden.

Für unsere Aufgaben muss nicht zwingend die Abstufungen der Zielgrößen sind für unsere Aufgaben nicht gleichermaßen relevant.

Eine Methode, die die betrachteten Auswertungen in unter 10 Sekunden mit weniger als 4 GB Arbeitsspeicher durchführen kann, wird bereits als optimal bewertet.

¹www.opencode.de/

Weitere Optimierungen sind in diesem Fall nicht erforderlich. Falls bereits die gewünschte Performanz erreicht wurde, rückt die Reduktion des Entwicklungsaufwand in den Vordergrund. Entsprechend sind Aspekte wie die einfache Anwendbarkeit und Nachvollziehbarkeit – selbst für unerfahrene Nutzende – ausschlaggebend.

Wir betrachten in R (Version 4.5.0) die folgenden R-Pakete gemeinsam mit den in Abschnitt **2@sec-methoden** beschriebenen Methoden (Variablenselektion, Datenaufteilung):

Tabelle 1
Versionen betrachteter R-Pakete

Paket	Version
data.table	1.17.8
tidyverse	tba
vroom	tba
arrow	20.0.0.2
duckdb	1.3.2
polars	1.0.1

Wie in Abschnitt **2@sec-infrastruktur** beschrieben war es uns aus organisatorischen Gründen nicht möglich, die neuste Version aller Pakete zu verwenden. Die leichter nutzbaren Variationen {duckplyr} bzw. {tidytable} zu nutzen. Die Package wurden aber wenige Tage nach dem Experiment eingerichtet. Die Syntaxtranslation kann dabei die Performanz verschlechtern, sodass bei {duckdb} bzw. {data.table} zwischen Performanz und Code-Verständlichkeit abgewägt werden muss. {arrow} ist schon länger als {polars} im Statistischen Bundesamt verfügbar, sodass wir darin bereits mehr Erfahrungen einsetzen konnten.

5.2 Baseline

Klassisch werden die betrachteten Auswertungsaufgaben im Statischen Bundesamt hauptsächlich mit SAS und im FDZ mit Stata gelöst. Um die nachfolgenden Ergebnisse einzuordnen, haben wir die Performanzmessungen für 1% des simulierten BTP durchgeführt (800.000 Beobachtungen)in SAS und Stata durchgeführt:

Tabelle 2
Baseline anhand SAS und Stata (1% simuliertes BTP)

Software	Anwendung	Arbeitsspeicher	Laufzeit	Festplattenspeicher
----------	-----------	-----------------	----------	---------------------

Der Arbeitsspeicher des FDZ OnSite-Servers reicht nicht aus, um das ganze BTP in Stata zu verarbeiten, sodass zwingend mit selektivem Einlesen gearbeitet werden muss.

5.3 Hauptergebnis für große Datenmengen

Anhand unserer Untersuchung, bietet `{arrow}`+`{parquet}` (bei Bedarf +`{duckdb}`) im Gesamtpaket die eindeutige besten Datenverarbeitungsmethoden für unsere Zwecke.

- › Das geringe Arbeitsspeicherprofil Bedarf keiner weiteren Optimierung und ist in unserer Auswertung nahezu konstant abhängig von der Datenmenge, sodass die Methoden auf noch größere Datenmengen skalieren können. Ansonsten bietet `{duckdb}` und `{polars}` stärkere Optimierung des Arbeitsspeichers.
- › schnellste Laufzeit für große Datenmengen
- › das Parquet Dateiformat reduziert den benötigten Festplattenspeicher massiv.
- › beste Nutzererfahrung
 - › Leicht und verständlich - adaptiert nativ schöne `{tidyverse}` Syntax
 - › Flexibel, selektives Einlesen ist zwingend erforderlich
 - › hohe Stabilität, fehlende Features können durch leicht in `duckdb` oder in den Arbeitsspeicher überführt und dennoch ausgeführt werden
- › kleiner Nachteil: Erfahrung notwendig, da erst Datenaufteilung/selektives Einlesen die maximale Performance erreichen

Unerwarteterweise ist `{polars}` für das simulierte 10% BTP abgeschlagen (unter den schlechtesten Methoden) und für andere Datenmengen optimal schnell.

5.4 Erkenntnisse für kleine Datenmengen

- › Paket für die optimale Laufzeit nicht eindeutig
 - › 1e6: `arrow` > `duckdb` > `DT+SEL` > `polars`
 - › 1e5: `polars` > `duckdb` > `arrow` > `DT+SEL`
 - › 1e4: `polars` > `data.table` > `arrow` > `readr`
- › Dagegen ist das effizienteste betrachtete Datenformat über 1000 Beobachtungen eindeutig Parquet – sowohl in Speicherbedarf als auch in Laufzeit.
- › Datenaufteilung bietet nur high-performance Methoden ab einer gewissen Datenmenge Vorteile. Für kleine Mengen überwiegt der Overhead durch das Lesen

mehrer kleiner Dateien. Klassische Methoden werden durch eine Datenaufteilung nur negativ beeinflusst.

- › Die Ergänzung von selektivem Einlesen ist immer vorteilhaft. High-Performance Methoden können aber bei einer aufgeteilten Datenhaltung darauf verzichten.
- › Von den klassischen Methoden ist `DT+SEL` am effizientesten, aber für unseren größten Anwendungsfall. Ein geschickter DTler kann mit moderaten Datenmengen auch sehr effizient arbeiten. Anfängern ist eher `{arrow}` zu empfehlen.
 - › 5x langsamer als `{arrow}`
 - › SEL notwendig, da ohne 3x größer als die Eingangsdaten, dauert 2.2 min anstatt 23 Sec. -> schwierige Anwendung (Entscheidung relevanter Variablen muss vorab getroffen werden unter Beachtung der Arbeitsspeicher Restriktionen)
 - › SPLIT verschlechtert DT im Gegensatz zu `arrow`
 - › `{data.table}`+`csv` ist die beste "klassische" R-Methode und erreicht maximal 23.58s, in der größten Ordnung wie die nicht optimierte Arrow Performance. Das die beste gemessene Performance für CSV (aufgeteilte Parquet sind doppelt so schnell). D.h. ein `{data.table}` Profi, ist besser als ein schlechter Arrow Programmierer, der aber größeres Potenzial für Verbesserungen hat.
- › `base+readr` sind immer weit abgeschlagen

5.5 Ergebnisse

- › › Für `{data.table}` ist die geschickte Programmierung noch viel wichtiger. Arrow wird höchstens langsam und beansprucht viel weniger RAM. Wohingegen `data.table` für den gesamten Datensatz (ohne Sel) das 600x an RAM belegt wie Arrow, damit viel schneller abbricht und den schlechten Programmierer Abbrüche beschert.
 - › ohne Vorauswahl bricht DT ab, wenn das gesamte BTP verwendet werden soll. Arrow nur, wenn die Auswertung auch dazu führt, dass wirklich alle Variablen verarbeitet werden.
 - › mit DT lässt sich nicht so flexibel/schön arbeiten
- › Arrow verzeiht Fehler leichter als DT. Alleine durch die Datenaufteilung (vorgegeben durch die Datenbereitstellung, vorbereitet durch das FDZ), erreichen wir Count Ergebnisse in 11.73s, nur 5s über dem absoluten Optimum.
- › Wenn noch weniger RAM einsetzbar ist, benötigt

Tabelle 3

Benchmarkergebnisse für 10% des BTP

Paket	Dateiformat	Optimierung	Festplatte	Arbeitsspeicher	Laufzeit
Fallzahl					
{arrow}	Parquet	Datenaufteilung (gleichmäßig)	45.5G	219.23M	4.65s
{duckdb}	Parquet		46G	4.48M	5.14s
{arrow}	Parquet	Variablenauswahl	46G	669.55M	7.47s
{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	44.8G	4.47M	11.73s
{arrow}	Parquet		46G	219.7M	16.96s
{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	44.9G	4.48M	17.07s
{arrow}	Parquet		46G	668.71M	20.61s
{data.table}	CSV	Variablenauswahl	121.2G	407.68M	23.58s
{polars}	Parquet		46G	3.13M	1.17m
{data.table}	CSV		121.2G	312.92G	2.21m
{data.table}	CSV	Datenaufteilung (Berichtsjahr)	97.5G	471.61G	5m
Regression					
{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	44.8G	745.92M	5.19s
{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	44.9G	745.92M	6.54s
{dplyr}	CSV	Variablenauswahl	121.2G	1.42G	1.92m

Polars den wenigsten RAM, DuckDB nur geringfügig mehr

10 %: arrow + aufgeteilte parquet, duckdb, arrow variante
1 %: polars + ein parquet, duckdb, arrow 0.1 %: polars + ein parquet, DT, arrow 0.01%: DT + csv, readr, polars

-> nicht eindeutig. Für kleinere Datenmengen mehr Auswahl und das vertraute auszuwählen. Für größere Datenmengen klare Empfehlung Arrow, w.g. einfacher Anwendung, Stabilität (ggü. Nutzerfehlern), Skalierbarkeit an die RAM-Grenze und darüber hinaus, höchste Performance für unsere Datenmengen+gute System Ressourcen.

-> für kleine Datenmengen macht chunking keinen Sinn.

Dateitypen:

Beide Anwendungen lassen sich in unter 20 Z. mit Arrow programmieren (verständlich lesbar) s. Opencode Repo.

RAM Wachstum Arrow, Polars, DuckDB, Data.table, readr, baser mit und ohne sel.

512 im FDZ Obergrenze.

Gewinne ggü. Klassischen Methoden 7.X Min DT und sehr viel RAM im Default. Dennoch nicht komplett davon abraten.

5.6 Fazit (nach Hinten)

- > Empfehlung (insb. für unerfahrene Nutzende): Arrow, stabil, flexibel, einfach zu nutzen

- > Profi's in `data.table`, die sehr vertraut sind mit der Syntax, müssen nur in Randfällen wechseln. Falls die wirklich genutzten Variablenauswahl nicht durch den verfügbaren Arbeitsspeicher bedient werden können (dt brauchte ca. 3x RAM ggü. Festplatte).
- > neuste, beste, experimentell, bietet **polars** für moderate Datenmengen die effizienteste Variante
- > wer mit sql vertraut ist oder Features außerhalb des Scopes von Arrow braucht (auf großen Inputs), nutzt auch gerne duckdb

5.7 Anhang

Weitere Benchmarks

->

Tabelle 4

Benchmarkergebnisse für Fallzahlen (kleine Stichproben)

Beobach- tungen	Paket	Datei- format	Optimie- rung	Fest- platte	Arbeits- speicher	Laufzeit
100.000	{polars}	Parquet		4.59G	3.17M	967.38ms
100.000	{duckdb}	Parquet		4.59G	4.56M	1.46s
100.000	{arrow}	Parquet	Variablenauswahl	4.59G	261M	1.69s
100.000	{data.table}	CSV	Variablenauswahl	12.11G	40.94M	2.51s
100.000	{arrow}	Parquet	Datenaufteilung (gleichmäßig)	4.54G	219.08M	2.81s
100.000	{arrow}	Parquet		4.59G	260.2M	2.84s
100.000	{arrow}	Parquet		4.59G	219.7M	3.81s
100.000	{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	4.48G	219.25M	3.85s
100.000	{data.table}	CSV		12.11G	31.41G	7.4s
100.000	{data.table}	CSV	Datenaufteilung (Berichtsjahr)	9.74G	46.98G	13.62s
10.000	{polars}	Parquet		469.79M	3.13M	404.58ms
10.000	{data.table}	CSV	Variablenauswahl	1.21G	4.2M	669.04ms
10.000	{arrow}	Parquet	Variablenauswahl	469.79M	220.03M	1.1s
10.000	{readr}	CSV	Variablenauswahl	1.21G	8.85M	1.25s
10.000	{arrow}	Parquet		469.79M	219.19M	1.59s
10.000	{duckdb}	Parquet		469.79M	4.49M	2.94s
10.000	{data.table}	CSV		1.21G	3.15G	3.65s
10.000	{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	464.38M	219.23M	4.18s
10.000	{arrow}	Parquet		469.79M	219.7M	4.56s
10.000	{data.table}	CSV	Datenaufteilung (Berichtsjahr)	997.06M	4.71G	4.75s
10.000	{arrow}	Parquet	Datenaufteilung (gleichmäßig)	461.09M	219.23M	7.14s
10.000	{readr}	CSV		1.21G	1.62G	8.59s
10.000	{arrow}	CSV		1.21G	26.1M	15.65s
10.000	{data.table}	CSV.GZ		402.31M	4.38G	21.21s
10.000	{base}	CSV		1.21G	9.02G	4.86m
1.000	{data.table}	CSV	Variablenauswahl	123.83M	539.57K	124.89ms
1.000	{readr}	CSV	Variablenauswahl	123.83M	2.54M	208.72ms
1.000	{polars}	Parquet		45.87M	3.13M	436.83ms
1.000	{data.table}	CSV		123.83M	325.99M	900.98ms
1.000	{duckdb}	Parquet		45.87M	4.49M	1.09s
1.000	{arrow}	Parquet	Variablenauswahl	45.87M	215.77M	1.21s
1.000	{arrow}	Parquet		45.87M	214.86M	1.45s
1.000	{arrow}	CSV		123.83M	3.3M	1.51s
1.000	{data.table}	CSV.GZ		40.11M	468.94M	2.71s
1.000	{data.table}	CSV	Datenaufteilung (Berichtsjahr)	99.63M	487.24M	2.78s
1.000	{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	51.03M	219.25M	2.94s
1.000	{arrow}	Parquet		45.87M	219.7M	3.66s
1.000	{arrow}	Parquet	Datenaufteilung (gleichmäßig)	48.12M	219.1M	3.99s
1.000	{readr}	CSV		123.83M	188.25M	4.9s
1.000	{base}	CSV		123.83M	680.31M	23.33s

Tabelle 5
Benchmarkergebnisse für Regression (kleine Stichproben)

Beobachtungen	Paket	Dateiformat	Optimierung	Festplatte	Arbeitsspeicher	Laufzeit
100.000	{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	4.48G	505.21M	3.8s
100.000	{dplyr}	CSV	Variablenauswahl	12.11G	147.61M	13.21s
10.000	{dplyr}	CSV	Variablenauswahl	1.21G	16.79M	1.34s
10.000	{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	464.38M	438.01M	4.96s
10.000	{dplyr}	CSV		1.21G	1.7G	10.82s
1.000	{dplyr}	CSV	Variablenauswahl	123.83M	3.97M	259.24ms
1.000	{dplyr}	CSV		123.83M	197.32M	6.42s
1.000	{arrow}	Parquet	Datenaufteilung (Berichtsjahr)	51.03M	431.53M	6.84s