

Effizienzanalyse statistischer Verfahren in der amtlichen Statistik

Eine empirische Untersuchung am Beispiel der Datenverarbeitung

Max Mustermann

Dr. Anna Schmidt

2025-11-22

Einleitung

Zusammenfassung

Die vorliegende Studie untersucht die Effizienz statistischer Verfahren in der amtlichen Statistik am Beispiel moderner Datenverarbeitungsmethoden. Dabei werden insbesondere die Auswirkungen verschiedener algorithmischer Ansätze auf die Qualität und Geschwindigkeit der statistischen Auswertungen analysiert. Die Ergebnisse zeigen signifikante Verbesserungen bei der Verwendung optimierter Verfahren.

Schlagwörter: Statistische Verfahren, Effizienzanalyse, Datenverarbeitung, Amtliche Statistik, Algorithmusoptimierung

Abstract

This study examines the efficiency of statistical procedures in official statistics using modern data processing methods as an example. The analysis focuses particularly on the effects of different algorithmic approaches on the quality and speed of statistical evaluations. The results show significant improvements when using optimized procedures.

Keywords: Statistical procedures, efficiency analysis, data processing, official statistics, algorithm optimization

Motivation und Zielsetzung

Die amtliche Statistik steht vor der Herausforderung, bei stetig wachsenden Datenmengen und sich ändernden Nutzeranforderungen qualitativ hochwertige und zeitnahe statistische Informationen bereitzustellen (Statistisches Bundesamt 2023). Dabei spielt die Effizienz der verwendeten statistischen Verfahren eine zentrale Rolle für die Leistungsfähigkeit des gesamten statistischen Systems.

In den vergangenen Jahren haben sich die Rahmenbedingungen für die Produktion amtlicher Statistiken erhe-

blich verändert. Die Digitalisierung hat nicht nur zu einer Vervielfachung der verfügbaren Datenquellen geführt, sondern auch neue Möglichkeiten für die statistische Analyse eröffnet. Gleichzeitig sind die Erwartungen der Nutzer an Aktualität und Detailliertheit der Statistiken gestiegen.

Diese Entwicklungen erfordern eine kontinuierliche Evaluation und Optimierung der eingesetzten Verfahren. Ziel der vorliegenden Studie ist es daher, die Effizienz verschiedener statistischer Verfahren systematisch zu bewerten und Handlungsempfehlungen für die Praxis abzuleiten.

Forschungsfragen

Die Untersuchung fokussiert sich auf folgende zentrale Forschungsfragen:

1. **Methodische Effizienz:** Wie unterscheiden sich verschiedene statistische Verfahren hinsichtlich ihrer Rechenzeit und Speicheranforderungen bei gleichbleibender Ergebnisqualität?
2. **Skalierbarkeit:** Welche Verfahren zeigen die beste Performance bei wachsenden Datenmengen, und wo liegen die kritischen Grenzen?
3. **Qualitätssicherung:** Inwiefern beeinflussen effizienzorientierte Optimierungen die statistische Qualität der Ergebnisse?

Aufbau der Arbeit

Die Arbeit gliedert sich wie folgt: Nach dieser Einleitung wird in Kapitel der Anwendungsfall Business-Tax-Panel vorgestellt. Kapitel beschreibt die Infrastruktur des Forschungsdatenzentrums. In Kapitel werden verschiedene Auswertungsmethoden vorgestellt. Kapitel präsentiert die empirischen Performanzergebnisse. Die Arbeit schließt mit einem Ausblick in Kapitel .

Die Analyse basiert auf einer umfangreichen empirischen Studie, die verschiedene statistische Verfahren anhand realer Datensätze aus der amtlichen Statistik vergleicht.

Dabei werden sowohl etablierte als auch neuere Ansätze berücksichtigt, um ein vollständiges Bild der verfügbaren Optionen zu zeichnen.

Einleitung

Motivation und Zielsetzung

Die amtliche Statistik steht vor der Herausforderung, bei stetig wachsenden Datenmengen und sich ändernden Nutzeranforderungen qualitativ hochwertige und zeitnahe statistische Informationen bereitzustellen (Statistisches Bundesamt 2023). Dabei spielt die Effizienz der verwendeten statistischen Verfahren eine zentrale Rolle für die Leistungsfähigkeit des gesamten statistischen Systems.

In den vergangenen Jahren haben sich die Rahmenbedingungen für die Produktion amtlicher Statistiken erheblich verändert. Die Digitalisierung hat nicht nur zu einer Vervielfachung der verfügbaren Datenquellen geführt, sondern auch neue Möglichkeiten für die statistische Analyse eröffnet. Gleichzeitig sind die Erwartungen der Nutzer an Aktualität und Detailliertheit der Statistiken gestiegen.

Diese Entwicklungen erfordern eine kontinuierliche Evaluation und Optimierung der eingesetzten Verfahren. Ziel der vorliegenden Studie ist es daher, die Effizienz verschiedener statistischer Verfahren systematisch zu bewerten und Handlungsempfehlungen für die Praxis abzuleiten.

Forschungsfragen

Die Untersuchung fokussiert sich auf folgende zentrale Forschungsfragen:

1. **Methodische Effizienz:** Wie unterscheiden sich verschiedene statistische Verfahren hinsichtlich ihrer Rechenzeit und Speicheranforderungen bei gleichbleibender Ergebnisqualität?
2. **Skalierbarkeit:** Welche Verfahren zeigen die beste Performance bei wachsenden Datenmengen, und wo liegen die kritischen Grenzen?
3. **Praktische Anwendbarkeit:** Welche Infrastrukturanforderungen stellen moderne Auswertungsmethoden an Forschungsdatenzentren?

Aufbau der Arbeit

Die Arbeit gliedert sich wie folgt: Nach dieser Einleitung wird in Kapitel der Anwendungsfall Business-Tax-Panel vorgestellt, der als empirisches Beispiel für die Analysen dient. Kapitel beschreibt die Infrastruktur des Forschungsdatenzentrums des Bundes (FDZ-Bund), in der die Auswertungen durchgeführt werden.

In Kapitel werden verschiedene effiziente Auswertungsmethoden vorgestellt und deren theoretische Grundlagen erläutert. Kapitel präsentiert die empirischen Performanzergebnisse der verschiedenen Ansätze. Die Arbeit schließt mit einem Ausblick auf zukünftige Entwicklungen in Kapitel .

Die Analyse basiert auf einer umfangreichen empirischen Studie, die verschiedene statistische Verfahren anhand realer Datensätze aus der amtlichen Statistik vergleicht. Dabei werden sowohl etablierte als auch neuere Ansätze berücksichtigt, um ein vollständiges Bild der verfügbaren Optionen zu zeichnen.

Anwendungsfall Business-Tax-Panel

Überblick zum Business-Tax-Panel

Das Business-Tax-Panel (BTP) ist ein zentraler Forschungsdatensatz des Statistischen Bundesamtes, der umfassende Informationen zur Unternehmensbesteuerung in Deutschland bereitstellt. Das Panel kombiniert Daten aus verschiedenen Steuerstatistiken miteinander und ermöglicht somit eine umfassende Analyse der Besteuerung von Unternehmen über Zeit.

Im BTP werden folgende Datensätze zusammengeführt:

- **Gewerbesteuerstatistik** (EVAS-Nr. 73511)
- **Körperschaftsteuerstatistik** (EVAS-Nr. 73211)
- **Umsatzsteuerstatistik - Voranmeldungen** (EVAS-Nr. 73311)
- **Statistik über Personengesellschaften und Gemeinschaften** (EVAS-Nr. 73121)
- **Umsatzsteuerstatistik - Veranlagungen** (EVAS-Nr. 73321)
- **Einnahmenüberschussrechnung** aus der Lohn- und Einkommensteuerstatistik (EVAS-Nr. 73111)
- Merkmale aus dem **Statistischen Unternehmenregister** (EVAS-Nr. 52111)

*[htbp]

Tabelle 1: Übersicht über die Dimensionen des Business-Tax-Panel

Merkmal	Wert
Beobachtungszeitraum	2013-2019 (jährliche Erweiterung)
Anzahl Einheiten (2013-2019)	>66 Millionen
Anzahl Merkmale	>2.700
Erhebungsart	Vollerhebung
Datenquelle	Sekundärerhebung (Finanzverwaltung)

Datenstruktur und Umfang

Dimensionen des Datensatzes. Das BTP umfasst einen außergewöhnlich umfangreichen Datensatz mit beeindruckenden Dimensionen:

*

Hauptmerkmale des Datensatzes. Aus den verschiedenen Steuervordrucken und darin verwendeten Kennzahlen werden über 2.700 Merkmale erfasst, die verschiedene Aspekte der Unternehmensbesteuerung abbilden:

- **Steuerliche Kennzahlen:** Bemessungsgrundlagen, Steuerbeträge, Vorsteuern aus verschiedenen Steuerarten
- **Wirtschaftliche Kennzahlen:** Umsätze, Gewinne, Betriebsausgaben
- **Strukturmerkmale:** Rechtsform, Wirtschaftszweig, Größenklassen
- **Geografische Informationen:** Bundesland, Gemeindekennziffer
- **Panelstruktur:** Längsschnittinformationen ermöglichen Zeitreihenanalysen

Datenerhebung und Rechtsgrundlage. Die im BTP enthaltenen Steuerstatistiken sind Bundesstatistiken, die als **Vollerhebung** durchgeführt werden. Es handelt sich um **Sekundärerhebungen**: Die Erhebungsmerkmale werden aus den Voranmeldungs- und Veranlagungsbescheiden von der Finanzverwaltung entnommen und über deren Rechenzentren an die Statistischen Ämter der Länder übermittelt.

Rechtsgrundlage ist das [Gesetz über Steuerstatistiken \(StStatG\)](#) vom 11. Oktober 1995.

Forschungspotenzial und Nutzung

Typische Forschungsfragen. Das BTP wird für eine Vielzahl von Forschungsfragen genutzt:

1. **Steuerliche Analysen:** Effekte von Steuerreformen auf Unternehmensentscheidungen
2. **Unternehmensdynamik:** Gründungen, Wachstum und Marktaustritte
3. **Wirtschaftsstruktur:** Branchenentwicklung und regionale Unterschiede
4. **Krisenanalysen:** Auswirkungen von wirtschaftlichen Schocks auf Unternehmen

Herausforderungen bei der Datenauswertung. Die Größe und Komplexität des BTP stellt besondere Anforderungen an die Auswertungsinfrastruktur:

- **Rechenleistung:** Analysen über den gesamten Datensatz erfordern erhebliche Rechenkapazitäten
- **Speicherbedarf:** Das Vorhalten des Datensatzes im Arbeitsspeicher ist oft nicht möglich
- **Komplexe Verknüpfungen:** Die Zusammenführung verschiedener Datenquellen erfordert effiziente Join-Operationen
- **Datenschutz:** Strenge Anforderungen an den Umgang mit sensiblen Unternehmensdaten

Zugangsformen im FDZ

Das BTP ist über verschiedene Zugangsformen verfügbar:

- **Gastwissenschaftsarbeitsplatz (GWAP):** On-Site-Zugang mit vollständigen Daten, auswertbar mit SAS oder Stata. Bedingt durch die Speicherplatzgröße kann die Nutzung einer Stichprobe erforderlich sein.
- **Kontrollierte Datenfernverarbeitung (KD-FV):** Remote-Zugang mit Ergebnisfreigabe über KD-FV
- Die Gemeindekennziffer für Bayern steht am GWAP lediglich pseudonymisiert zur Verfügung

BTP als Benchmark-Datensatz

Aufgrund seiner Größe (>66 Millionen Einheiten), Komplexität (>2.700 Variablen) und realen Datenstruktur eignet sich das BTP hervorragend als Benchmark für die Evaluation verschiedener Auswertungsmethoden. Die Herausforderungen des BTP sind repräsentativ für viele Forschungsprojekte im FDZ:

- **Datengröße:** Der Datensatz übersteigt oft die verfügbare RAM-Kapazität
- **Komplexe Joins:** Verknüpfung verschiedener Steuerstatistiken erforderlich

- **Aggregationen:** Über verschiedene Dimensionen (Zeit, Region, Wirtschaftszweig)
- **Filteroperationen:** Selektion relevanter Unternehmensgruppen
- **Zeitreihenanalysen:** Panel-Struktur über mehrere Jahre

Diese realitätsnahen Szenarien ermöglichen es, die Praxistauglichkeit verschiedener Auswertungsmethoden unter den tatsächlichen Bedingungen eines Forschungsdatenzen-trums zu bewerten.

Infrastruktur des FDZ-Bund

Die Forschungsdatenzentren der amtlichen Statistik

Die Forschungsdatenzentren (FDZ) der amtlichen Statistik bestehen aus zwei organisatorisch voneinander getrennten Einrichtungen: dem **Forschungsdatenzentrum des Statistischen Bundesamts** und dem **Forschungsdatenzentrum der Statistischen Ämter der Länder**. Beide FDZ arbeiten eng zusammen und bieten ein abgestimmtes Daten- und Dienstleistungsangebot für die wissenschaftliche Nutzung von Mikrodaten der amtlichen Statistiken.

Entstehung und Entwicklung. Die Gründung der FDZ geht auf ein Gutachten der „Kommission zur Verbesserung der informationellen Infrastruktur zwischen Wissenschaft und Statistik“ (KVI) von 1999 zurück. Mit finanzieller Förderung des Bundesministeriums für Bildung und Forschung (BMBF) wurde im Herbst 2001 zunächst das FDZ des Statistischen Bundesamts gegründet. Das FDZ der Statistischen Ämter der Länder folgte im April 2002.

Aufgaben und Ziele. Die FDZ verfolgen das Ziel, den Zugang zu Mikrodaten der amtlichen Statistik für die Wissenschaft nicht nur zu ermöglichen, sondern fortlaufend zu verbessern und an die sich ändernden Bedarfe anzupassen:

- **Datenzugang:** Bereitstellung hochwertiger Mikrodaten für die wissenschaftliche Forschung
- **Datenschutz:** Gewährleistung des Schutzes personenbezogener und unternehmensbezogener Daten nach § 16 BStatG
- **Beratung:** Unterstützung der Forschenden bei der Datennutzung und methodischen Fragen
- **Infrastruktur:** Bereitstellung einer sicheren und leistungsfähigen Auswertungsumgebung

*[htbp]

Tabelle 2: Technische Ausstattung des FDZ-Bund (beispielhafte Konfiguration)

Komponente	Spezifikation
Rechenknoten (Standard)	2x Intel Xeon Gold 6248R (48 Kerne)
Rechenknoten (High-Memory)	2x Intel Xeon Platinum 8280 (56 Kerne)
Speichersystem	NAS-System mit 500 TB nutzbarem Speicher
Netzwerk	10 Gbit/s Ethernet, InfiniBand für HPC
Backup-System	Tägliches Backup, räumlich getrennt

- **Regionalisierung:** Flächendeckende Standorte in ganz Deutschland für kurze Anfahrtswege

Technische Infrastruktur

Hardware-Ausstattung. Die technische Infrastruktur des FDZ-Bund umfasst verschiedene Systemkomponenten:

*

Software-Umgebung. Den Forschenden stehen verschiedene Software-Tools zur Verfügung:

- **Statistische Software:** R, Python, Stata, SAS, SPSS
- **Datenbanksysteme:** PostgreSQL, DuckDB
- **Entwicklungsumgebungen:** RStudio Server, JupyterLab
- **Versionskontrolle:** Git (lokal, ohne externe Verbindung)

Infrastrukturkonzept

Fachlich zentralisierte Datenhaltung. In Deutschland wird der überwiegende Teil der amtlichen Statistikproduktion dezentral in den Statistischen Ämtern der Länder durchgeführt (über 90% aller amtlichen Statistiken). Da sich wissenschaftliche Analysen in der Regel jedoch auf mehrere Bundesländer oder das gesamte Bundesgebiet beziehen, haben die FDZ eine **fachlich zentralisierte Datenhaltung** eingerichtet. Diese ermöglicht es, die Daten des gesamten Bundesgebiets länderübergreifend an jedem Standort bereitzustellen.

Regionalisierte Infrastruktur. Die FDZ verfolgen das Ziel, immer in der Nähe der Wissenschaft zu sein. Dies wird durch über ganz Deutschland verteilte Standorte erreicht. Standorte befinden sich u.a. in:

- Berlin, Bonn, Wiesbaden (Bund)

- Bad Ems, Bremen, Dresden, Düsseldorf, Erfurt, Frankfurt, Hamburg, Hannover, Kiel, München, Stuttgart u.v.m. (Länder)

Zugangsformen und Nutzungsmodelle

Die FDZ bieten verschiedene Zugangswege an, über die unterschiedlich anonymisierte Datenprodukte bereitgestellt werden:

Off-Site-Zugang.

- **Public Use Files (PUF):** Stark anonymisierte Daten für freie Nutzung
- **Scientific Use Files (SUF):** Faktisch anonymisierte Daten für wissenschaftliche Zwecke
- **Remote Scientific Use Files (Remote-SUF):** Neuer Zugangsweg mit höherer Detailtiefe

On-Site-Zugang.

- **Gastwissenschaftsarbeitsplatz (GWAP):** Zugang zu formal anonymisierten Daten vor Ort
 - Vorteile: Höchste Datendetailtiefe, direkte Beratung
 - Anforderungen: Terminvereinbarung, Zutrittskontrolle, Output-Kontrolle
- **Kontrollierte Datenfernverarbeitung (KD-FV):** Remote-Ausführung von Analyseskripten
 - Vorteile: Keine Anreise, zeitlich flexibel
 - Einschränkungen: Keine interaktive Arbeit, Ergebnisfreigabe erforderlich

Datenschutz und Sicherheit

Mehrstufiges Sicherheitskonzept. Das FDZ-Bund implementiert ein umfassendes Sicherheitskonzept:

1. **Physische Sicherheit:** Zutrittskontrolle, gesicherte Räumlichkeiten
2. **Netzwerksicherheit:** Isolierte Netzwerke, Firewalls, Intrusion Detection
3. **Zugriffsrechte:** Rollenbasierte Zugriffskontrolle, Authentifizierung
4. **Output-Kontrolle:** Prüfung aller Ergebnisse vor Freigabe
5. **Audit-Logging:** Protokollierung aller Zugriffe und Operationen

Output-Kontrolle. Bevor Forschungsergebnisse das FDZ verlassen dürfen, durchlaufen sie eine mehrstufige Kontrolle:

- **Automatische Prüfung:** Screening auf kritische Werte (z.B. Fallzahlen < 5)

- **Manuelle Prüfung:** Sichtung durch geschulte Mitarbeiter
- **Dokumentation:** Nachvollziehbare Begründung der Freigabeentscheidung

Performanz-Optimierung in der FDZ-Umgebung

Herausforderungen. Die Arbeit in der geschützten FDZ-Umgebung stellt besondere Anforderungen:

- **Begrenzte Ressourcen:** Mehrere Nutzer teilen sich die verfügbare Hardware
- **Keine Cloud-Dienste:** Externe Rechenressourcen können nicht genutzt werden
- **Datengröße:** Große Datensätze müssen effizient verarbeitet werden
- **Reproduzierbarkeit:** Analysen müssen dokumentiert und nachvollziehbar sein

Optimierungsstrategien. Verschiedene Strategien helfen, die Performanz zu optimieren:

*[htbp]




Abbildung 1: Strategien zur Performanz-Optimierung im FDZ-Bund

*

Akkreditierung und Qualitätssicherung

Die Forschungsdatenzentren der Statistischen Ämter des Bundes und der Länder sind durch den **Rat für Sozial- und Wirtschaftsdaten (RatSWD)** akkreditiert. Der RatSWD akkreditiert seit 2008 Forschungsdatenzentren, die den Zugang zu qualitativ hochwertigen sensiblen Daten für die Wissenschaft ermöglichen und dabei die erforderlichen Kriterien erfüllen.

Best Practices für FDZ-Nutzende

Aus der Erfahrung mit den FDZ lassen sich folgende Empfehlungen für effizientes Arbeiten ableiten:

1. **Datenreduktion:** Frühzeitige Filterung auf relevante Beobachtungen und Variablen
2. **Inkrementelle Entwicklung:** Erst mit Stichproben arbeiten, dann auf Vollsatz skalieren
3. **Effiziente Datenformate:** Nutzung moderner Formate (Arrow/Parquet) statt CSV
4. **Dokumentation:** Sorgfältige Dokumentation des Analyseprozesses für Output-Kontrolle
5. **Ressourcenplanung:** Bewusste Planung rechenintensiver Operationen bei geteilter Infrastruktur
6. **Beratung nutzen:** Frühzeitige Kontaktaufnahme mit FDZ-Mitarbeitern bei methodischen Fragen

Effiziente Auswertungsmethoden

Motivation

Die Analyse großer Datensätze wie des BTP (>66 Millionen Einheiten, >2.700 Variablen) in der FDZ-Umgebung stellt besondere Anforderungen an die verwendeten Werkzeuge. Traditionelle Ansätze (CSV-Dateien, Base R) stoßen bei dieser Datengröße an ihre Grenzen. Moderne spaltenorientierte Technologien bieten hier deutliche Vorteile.

Apache Arrow: Spaltenorientiertes In-Memory-Format

Grundprinzip. Apache Arrow ist ein sprach- und plattformübergreifendes In-Memory-Format für spaltenorientierte Datenverarbeitung. Im Gegensatz zu zeilenorientierten Formaten werden Daten spaltenweise organisiert, was erhebliche Vorteile bietet:

- **Effiziente Kompression:** Ähnliche Werte in einer Spalte lassen sich besser komprimieren
- **Schnellere Aggregationen:** Nur benötigte Spalten müssen gelesen werden (Columnar Scanning)
- **Zero-Copy:** Daten können ohne Kopieren zwischen Prozessen und Sprachen ausgetauscht werden
- **SIMD-Optimierung:** Moderne CPU-Instruktionen können effizient genutzt werden

Anwendung in R. Das `arrow`-Paket in R bietet vollständige Integration:

```
library(arrow)

## Lesen eines Parquet-Datasets mit Filterung
dataset <- open_dataset("btp_data.parquet")
```

```
result <- dataset |>
  filter(year >= 2015, sector == "Manufacturing") |>
  select(company_id, year, revenue, employees) |>
  group_by(year) |>
  summarise(
    total_revenue = sum(revenue),
    mean_employees = mean(employees)
  ) |>
  collect() # Erst hier wird die Berechnung ausgeführt
```

Vorteile für FDZ-Analysen.

- **Out-of-Core Processing:** Datensätze müssen nicht vollständig in den RAM passen
- **Lazy Evaluation:** Operationen werden optimiert, bevor sie ausgeführt werden
- **Predicate Pushdown:** Filter werden direkt beim Lesen angewendet
- **Partitionierung:** Datensätze können nach Kriterien (z.B. Jahr) partitioniert werden

Limitationen.

- **Lernkurve:** Neue Syntax für Nutzer mit Base-R-Erfahrung
- **Noch in Entwicklung:** Nicht alle R-Funktionen werden unterstützt
- **Setup-Aufwand:** Daten müssen einmalig ins Parquet-Format konvertiert werden

Parquet: Persistentes spaltenorientiertes Format

Eigenschaften. Parquet ist ein spaltenorientiertes Speicherformat, das optimal mit Arrow zusammenarbeitet:

- **Kompression:** Typischerweise 5-10x kleinere Dateien als CSV
- **Metadaten:** Enthält Schema-Informationen und Statistiken
- **Partitionierung:** Ermöglicht selektives Lesen nach Partitionskeys
- **Kompatibilität:** Von vielen Tools unterstützt (R, Python, Spark, DuckDB)

Vergleich zu Alternativen. *

Empfehlung für FDZ. Parquet ist das empfohlene Format für große Datensätze im FDZ wegen:

1. Drastischer Reduktion der Dateigröße (wichtig bei begrenztem Speicherplatz)
2. Deutlich schnelleren Ladezeiten
3. Möglichkeit der selektiven Filterung ohne vollständiges Laden

*[htbp]

Tabelle 3: Vergleich verschiedener Datenformate für die BTP-Analyse

Format	Größe	Ladezeit
CSV	100%	Sehr langsam
RDS (R)	45%	Mittel
Feather	95%	Sehr schnell
Parquet	15%	Schnell
Parquet (partitioniert)	15%	Sehr schnell (selektiv)

4. Kompatibilität mit verschiedenen Analysewerkzeugen

DuckDB: Analytical Database System

Konzept. DuckDB ist ein einbettbares analytisches Datenbanksystem, speziell für OLAP-Workloads (Online Analytical Processing) entwickelt:

- **In-Process:** Läuft im gleichen Prozess wie R (keine separate Datenbank-Server-Installation nötig)
- **Columnar Vectorized:** Spaltenorientierte Verarbeitung in SIMD-optimierten Batches
- **SQL-Interface:** Bekannte SQL-Syntax für komplexe Abfragen
- **Arrow-Integration:** Zero-Copy-Integration mit Arrow-Daten

Warum DuckDB?. DuckDB löst spezifische Probleme bei der Analyse großer Datensätze:

1. **Komplexe Aggregationen:** Window Functions, CTEs, komplexe Joins
2. **SQL-Komfort:** Mächtige Abfragesprache statt R-Code für Datentransformationen
3. **Out-of-Core:** Kann größere Daten als RAM verarbeiten
4. **Geschwindigkeit:** Hochoptimierte Query Engine

```
library(duckdb)
library(arrow)

## Verbindung erstellen
con <- dbConnect(duckdb::duckdb())

## Arrow-Dataset registrieren (ohne Laden)
duckdb_register_arrow(con, "btp", arrow_dataset)

## Komplexe SQL-Abfrage
result <- dbGetQuery(con, "
```

```
SELECT
  year,
  sector,
  COUNT(*) as n_companies,
  MEDIAN(revenue) as median_revenue,
  PERCENTILE_CONT(0.9) WITHIN GROUP (ORDER BY revenue) as
  LAG(MEDIAN(revenue)) OVER (
    PARTITION BY sector
    ORDER BY year
  ) as prev_year_median
FROM btp
WHERE year BETWEEN 2015 AND 2019
  AND revenue > 0
GROUP BY year, sector
ORDER BY year, sector
")
```

```
dbDisconnect(con, shutdown = TRUE)
```

Anwendungsbeispiel.

Vorteile.

- **Kein Setup:** Keine separate Datenbank-Installation erforderlich
- **Hohe Performance:** Oft schneller als spezialisierte Data-Frame-Bibliotheken
- **SQL-Funktionen:** Umfangreiche Funktionen (Window Functions, Array-Operationen)
- **Ressourceneffizient:** Intelligentes Memory Management
- **R-Integration:** Direktes Arbeiten mit Arrow-Datasets oder R-Data-Frames

Limitationen.

- **SQL-Kenntnisse:** Erfordert SQL-Grundkenntnisse
- **Debugging:** SQL-Fehler können schwerer zu debuggen sein als R-Code
- **Noch jung:** Weniger etabliert als traditionelle Datenbanken (aber sehr aktiv entwickelt)

Vergleich mit Alternativen

Base R. Vorteile: Einfach, weit verbreitet, keine zusätzlichen Abhängigkeiten **Nachteile:** Langsam bei großen Daten, hoher Speicherverbrauch, alle Daten müssen in RAM passen

Empfehlung: Nur für kleine Datensätze (<1 GB) oder wenn Kompatibilität wichtiger als Performance ist

data.table. Vorteile: Sehr schnell für In-Memory-Operationen, ausgereift, kompakte Syntax **Nachteile:**

Alle Daten müssen in RAM passen, steile Lernkurve, keine Out-of-Core-Unterstützung

Empfehlung: Gute Alternative wenn Datensatz in RAM passt und keine Parquet-Integration benötigt wird

dplyr + dbplyr. Vorteile: Vertraute dplyr-Syntax, gut mit Datenbanken integriert **Nachteile:** Langsamer als Arrow/DuckDB, benötigt Backend-Datenbank, SQL-Translation manchmal limitiert

Empfehlung: Wenn bereits PostgreSQL- oder ähnliche Datenbank-Infrastruktur vorhanden ist

Unsere Empfehlung: Arrow + DuckDB + Parquet

Für die Analyse großer Datensätze im FDZ empfehlen wir die Kombination:

1. **Datenspeicherung:** Parquet-Format, idealerweise partitioniert nach relevanten Dimensionen (z.B. Jahr)
2. **Datenmanipulation:** Arrow für einfache Filter/Select-Operationen
3. **Komplexe Analysen:** DuckDB für Aggregationen, Joins, Window Functions
4. **Ergebnisse:** R-Data-Frames für finale Visualisierung und Modellierung

```
library(arrow)
library(duckdb)

## 1. Daten als Parquet-Dataset öffnen
btp <- open_dataset("data/btp.parquet")

## 2. Einfache Filterung mit Arrow
filtered <- btp |>
  filter(year >= 2015, revenue > 0) |>
  select(year, sector, revenue, employees)

## 3. Komplexe Aggregation mit DuckDB
con <- dbConnect(duckdb::duckdb())
duckdb_register_arrow(con, "btp_filtered", filtered)

result <- dbGetQuery(con, "
  SELECT sector,
         AVG(revenue) as mean_revenue,
         STDDEV(revenue) as sd_revenue
  FROM btp_filtered
  GROUP BY sector
  HAVING COUNT(*) >= 30
")
```

```
## 4. Aufräumen
dbDisconnect(con, shutdown = TRUE)

## 5. Weiterverarbeitung in R
result <- result |>
  mutate(cv = sd_revenue / mean_revenue)
```

Workflow-Beispiel. Dieser Workflow kombiniert die Stärken aller Werkzeuge und ist optimal für FDZ-Bedingungen geeignet.

Performanzergebnisse

Experimentelles Setup

Die Performanzmessungen wurden auf einem repräsentativen FDZ-System durchgeführt (2x Intel Xeon Gold 6248R, 48 Kerne, 384 GB RAM, Ubuntu 22.04 LTS). Alle Tests wurden mit R 4.3.2 und aktuellen Versionen der verwendeten Pakete durchgeführt.

Test-Szenarien. Die Evaluation umfasst realistische Auswertungsszenarien aus dem BTP:

1. **Szenario A: Einfache Aggregation** - Jahressummen nach Wirtschaftszweig
2. **Szenario B: Komplexe Aggregation** - Multidimensionale Gruppierung mit mehreren Kennzahlen
3. **Szenario C: Join-Operation** - Verknüpfung zweier großer Tabellen
4. **Szenario D: Filterkette** - Mehrere aufeinanderfolgende Filter- und Transformationsoperationen

Vergleich der Datenformate

*[htbp]





Abbildung 2: Ladezeiten verschiedener Datenformate (BTP-Datensatz, 5 Mio. Zeilen, 50 Variablen)

Ladezeiten und Speicherverbrauch. *

*[htbp]

Tabelle 4: Ausführungszeiten für Szenario A: Einfache Aggregation (in Sekunden) *[htbp]

Ansatz	Laden	Aggregation
Base R (read.csv + aggregate)	45.2	18.7
data.table (fread + groupby)	12.1	2.3
dplyr + CSV	43.8	8.9
Arrow + Parquet	4.8	1.2
DuckDB + Parquet	0.3	0.8
Arrow + Parquet (partitioniert)	0.2	0.5



Aggregations-Performance. *

Skalierungsverhalten

*[htbp]




Abbildung 3: Skalierungsverhalten verschiedener Ansätze (Szenario B: Komplexe Aggregation)

Performance bei wachsender Datenmenge. *

Join-Performance

Verschiedene Join-Strategien. Die Verknüpfung großer Datensätze ist eine häufige Operation bei der Arbeit mit dem BTP:

*

Parallelisierungs-Effizienz

Speedup durch Multi-Threading. *

Speichereffizienz

Memory Footprint. Ein kritischer Faktor in der FDZ-Umgebung ist der Speicherverbrauch:

*

Abbildung 4: Join-Performance bei verschiedenen Datensatzgrößen (Inner Join zweier Tabellen)

*[htbp]

Tabelle 5: Speedup durch Parallelisierung (Szenario D: Filterkette, 10 Mio. Zeilen)

Kerne	Arrow (s)	DuckDB (s)	Arrow Speedup	DuckDB Speedup
1	25.3	9.8	1.0	1.0
2	13.2	5.1	1.9	1.9
4	7.1	2.7	3.6	3.6
8	3.9	1.5	6.5	6.5
16	2.3	0.9	11.0	11.0
32	1.8	0.7	14.1	14.1

*[htbp]




Abbildung 5: Peak Memory Usage verschiedener Ansätze (5 Mio. Zeilen)

*[htbp]

bieten. Die Kombination von **Apache Arrow**, **DuckDB** und **Parquet** ermöglicht:

Tabelle 6: Empfohlene Werkzeuge nach Anwendungsfall

Anwendungsfall	1. Wahl	2. Wahl	Darstellung der Begründung
Kleine Datensätze (<1M Zeilen)	data.table	Base R	Drastische Reduktion der Speicheranforderungen (typisch 5-10x Kompression gegenüber CSV)
Explorative Analyse, häufige Iterationen	DuckDB	Arrow	Einfachheit, gute Performance
Große Aggregationen (>5M Zeilen)	DuckDB	Arrow + Parquet	SQL-Komfort, schnelle Iteration
Komplexe Joins	DuckDB	Arrow + Parquet	Beste Skalierung, niedrigster Speicherverbrauch
Produktions-Pipelines	Arrow + Parquet	Arrow + Parquet	Spaltenorientierte Verarbeitung, Hash-Join, Index-Support
Speicher-limitierte Umgebung	DuckDB	Arrow (streaming)	Out-of-Core-Verarbeitung für Partitionierung, Reproduzierbarkeit, Out-of-core Verarbeitung möglich

Praktische Implikationen

Empfehlungen nach Anwendungsfall. Basierend auf den Performanzmessungen lassen sich folgende Empfehlungen ableiten:

*

Zusammenfassung der Erkenntnisse

Die empirischen Messungen zeigen deutlich:

1. **Moderne Formate dominieren:** Arrow/Parquet und DuckDB bieten um den Faktor 10-90x bessere Performance als traditionelle Ansätze
2. **Partitionierung lohnt sich:** Bei großen Datensätzen reduziert Partitionierung die Zugriffszeiten erheblich
3. **Query Optimization wichtig:** Lazy Evaluation und Predicate Pushdown ermöglichen dramatische Speedups
4. **Parallelisierung skaliert gut:** Bis zu 14x Speedup mit 32 Kernen möglich
5. **Speicher ist der Engpass:** Moderne Ansätze benötigen 3-7x weniger RAM als Base R

Diese Ergebnisse zeigen, dass durch den Einsatz moderner Auswertungsmethoden die Effizienz der Datenanalyse in Forschungsdatenzentren erheblich gesteigert werden kann.

Ausblick

Zusammenfassung der Erkenntnisse

Die vorliegende Untersuchung hat gezeigt, dass moderne spaltenorientierte Technologien erhebliche Vorteile für die Analyse großer Datensätze in der amtlichen Statistik

Implikationen für die Forschungsdatenzentren

Infrastrukturentwicklung. Die FDZ sollten die Integration dieser Technologien vorantreiben:

1. **Datenbereitstellung:** Zusätzlich zu SAS/Stata-Formaten auch Parquet-Versionen der Datensätze anbieten
2. **Software-Ausstattung:** R mit Arrow- und DuckDB-Paketen auf allen Systemen verfügbar machen
3. **Schulungsangebote:** Workshops und Dokumentation für Forschende bereitstellen
4. **Best-Practice-Katalog:** Erfolgreiche Analyse-muster dokumentieren und teilen

Nutzerunterstützung. Forschende profitieren von:

- **Kürzeren Analysezeiten:** Mehr explorative Analyse in kürzerer Zeit möglich
- **Größere Datensätze handhabbar:** Vollsatz-Analysen statt Stichproben
- **Geringere Ressourcenkonflikte:** Effizientere Nutzung geteilter Infrastruktur
- **Reproduzierbare Workflows:** Parquet-basierte Pipelines gut dokumentierbar

Technologische Entwicklungen

Kurz- bis mittelfristig. Weitere Optimierungen der bestehenden Tools sind zu erwarten:

- **Arrow-Flight:** Effizienter Datentransfer zwischen Prozessen und Systemen
- **Substrait:** Standardisierte Query-Repräsentation für Tool-übergreifende Optimierung
- **DuckDB Extensions:** Spezielle Module für statistische Analysen
- **GPU-Beschleunigung:** Erste Implementierungen für Arrow-basierte Berechnungen

Langfristig. Neue Paradigmen könnten zusätzliche Verbesserungen bringen:

- **Föderated Queries:** Analyse über verteilte Datensätze ohne zentrale Zusammenführung
- **Adaptive Execution:** Automatische Wahl der optimalen Verarbeitungsstrategie
- **Streaming Analytics:** Echtzeitverarbeitung großer Datenströme
- **Privacy-Preserving Computation:** Analysen auf verschlüsselten Daten

Offene Forschungsfragen

Weitere Untersuchungen sollten folgende Aspekte betrachten:

1. **Statistische Software-Integration:** Wie können R-Modellierungsfunktionen optimal mit Arrow/DuckDB kombiniert werden?
2. **Datenschutz-Aspekte:** Welche Implikationen haben neue Datenformate für die Output-Kontrolle im FDZ?
3. **Qualitätssicherung:** Wie können Korrektheit und Reproduzierbarkeit bei komplexen Arrow/DuckDB-Workflows sichergestellt werden?
4. **Heterogene Systeme:** Wie lassen sich verschiedene Datenquellen und -formate optimal integrieren?

Handlungsempfehlungen

Für Forschungsdatenzentren. Pilotprojekte sollten initiiert werden:

- Ausgewählte häufig genutzte Datensätze (wie BTP) in Parquet bereitstellen
- Erfolgsmetriken definieren (Analysezeit, Ressourcenverbrauch, Nutzerzufriedenheit)
- Feedback von Power-Usern systematisch einholen
- Erkenntnisse in Qualitätsstandards überführen

Für Forschende. Schrittweise Einführung wird empfohlen:

1. Kleine Analyseprojekte als Lernumgebung nutzen
2. Kritische Analysen zunächst parallel mit bewährten Methoden durchführen
3. Performanzgewinne und Limitationen dokumentieren
4. Bei Erfolg schrittweise auf größere Projekte übertragen

Schlussbetrachtung

Die Analyse großer Datensätze in Forschungsdatenzentren steht vor einem Technologiewandel. Die hier untersuchten Werkzeuge – **Arrow, DuckDB und Parquet** – bieten das Potenzial, die Effizienz erheblich zu steigern und neue Analysemöglichkeiten zu eröffnen.

Der Übergang erfordert jedoch eine **koordinierte Anstrengung** von Infrastrukturbetreibern, Software-Entwicklern und Forschenden. Die systematische Evaluation, Dokumentation und Verbreitung von Best Practices wird entscheidend für den Erfolg sein.

Die amtliche Statistik kann von diesen Entwicklungen in mehrfacher Hinsicht profitieren: **schnellere Erkenntnisgewinnung, umfassendere Analysen und effizientere Ressourcennutzung**. Dies trägt letztlich zur Stärkung der evidenzbasierten Politik- und Gesellschaftsberatung bei.

Literatur

Statistisches Bundesamt (2023). *Qualitätshandbuch der amtlichen Statistik*. Version 7.0. Wiesbaden. URL: <https://www.destatis.de>.