
Oliver Hauke

ist Mathematiker und IT-Referent im Kompetenzzentrum „Analyse und Auswertung“ des Statistischen Bundesamtes. Er verantwortet die Weiterentwicklung der technischen Infrastruktur des Forschungsdatenzentrums und berät das Netzwerk empirische Steuerforschung in der effizienten Nutzung der Systeme.

Annette Kristiansen

ist Ökonomin und Referentin im Referat „Unternehmenssteuern“ des Statistischen Bundesamtes. Sie beschäftigt sich mit der Zusammenführung der Unternehmenssteuerstatistiken und betreut das Netzwerk empirische Steuerforschung. Für ihre externe Promotion an der Universität Bremen untersucht sie die technologische Vielfalt multinationaler Unternehmen.

EFFIZIENTE AUSWERTUNG DES BUSINESS-TAX-PANELS MITHILFE VON R

Oliver Hauke, Annette Kristiansen

🔑 **Schlüsselwörter:** Effiziente Analysen, R-Programmierung, Forschungsdaten, Unternehmenssteuerstatistik, Business-Tax-Panel, Netzwerk empirische Steuerforschung

ZUSAMMENFASSUNG

Das Forschungsdatenzentrum des Statistischen Bundesamtes baut seine technische Infrastruktur gezielt aus, um der Wissenschaft erweiterte Analysemöglichkeiten amtlicher Daten bereitzustellen. Seit November 2025 steht Forschenden exklusiver Zugang zu diesen erweiterten Systemressourcen in R und Stata zur Verfügung. R-basierte Tools – insbesondere Apache Arrow, Parquet und DuckDB – ermöglichen es, gängige Analysen großer Forschungsdatensätze in Echtzeit auszuführen. Am Beispiel des Business-Tax-Panel (2013 bis 2019) werden die erzielbaren Effizienzgewinne bei der Auswertung umfangreicher steuerstatistischer Daten im Rahmen des Netzwerks empirische Steuerforschung demonstriert.

🔑 **Keywords:** *Efficient analysis – R programming – research data – corporate tax statistics – Business Tax Panel – empirical tax research network*

ABSTRACT

The Research Data Centre at the Federal Statistical Office is strategically expanding its technical infrastructure to provide researchers with enhanced analytical capabilities for official data. Since November 2025, researchers have had exclusive access to these extended system resources in R and Stata. R-based tools – particularly Apache Arrow, Parquet, and DuckDB – enable real-time analysis of large research datasets. Using the Business Tax Panel (2013–2019), this paper demonstrates the achievable efficiency gains in analysing large-scale tax statistics within the empirical tax research network.

Inhaltsverzeichnis

1 Anwendungsfall Business-Tax-Panel	2
1.1 Datengrundlage	2
1.2 Kennzahlen	2
1.3 Auswertungsbedarfe	2
1.4	3
1.5 Annette's Input	3
1.6 Überblick zum Business-Tax-Panel	4
1.7 Datenstruktur und Umfang	4
1.8 Technische Requirements	5
1.9 Forschungspotenzial und Nutzung	5
1.10 Zugangsformen im FDZ	5
1.11 BTP als Benchmark-Datensatz	5

1

Anwendungsfall Business-Tax-Panel

1.1 Datengrundlage

- › Umfang über verfügbaren Arbeitsspeicher
- › Besonders breit mit 3000 Merkmalen, 80 Mio. Obs.

1.2 Kennzahlen

1.3 Auswertungsbedarfe

Breites Spektrum: Datenaufbereitung/-bereitstellung und Auswertung von Mikrodaten durch die Wissenschaft.

1. deskriptive Eckdaten, für BTP als Panel im Quer- und Längsschnitt: Fallzahl pro Statistik und Jahr (s.MDR Produkt S. 9f https://www.forschungsdatenzentrum.de/sites/default/files/btp_2013-2019_on-site_mdr-prod.pdf)
2. Verlustvorträge (s. Vortrag NeSt) als Indikator für ... und Einflussgrößen auf Verlustvorträge, für Vermutung von Einfluss der Unternehmensgröße (großes Gesamtvolumen, Löhne, Spenden, tätige Personen; Auslandskontrolle oder WZ) auf positive Verlustvorträge.

Aus technischer Sicht, ist die Kernaufgabe den Großteil (von 2991 Variablen) effizient zu entfernen, sodass lediglich der relevante Ausschnitt von kleinem Umfang ausgewertet werden kann.

Beide Anwendungsfälle können bereits im mit den folgenden X von 3000 Variablen untersucht werden:

Kennzahlen um inhaltlose Testdaten zu generieren werden folgende Eckdaten benötigt und im nächsten BTP berücksichtigt:

- › Befüllung
- › Statistische Eckdaten univariate (Quantile), multivariate (gemeinsame Verteilung)

Update BTP, flexibel reagieren, neue MDR, DSB, ...

- › Datenbereitstellung: MDR
- › Forschungsprojekt

Tabelle 1

Betrachtete Variablen des BTP

Variable	Statistik	Beschreibung
jahr	Allgemein	Berichtsjahr
verk	Allgemein	
k_k65270	KStSt	Verlustvorträge
k_k65823	KStSt	Gesamtbetrag der Einkünfte
k_c15018	KStSt	Summe der Umsätze/Löhne/Gehälter
k_ef20	KStSt	WZ Generierung
k_k65172	KStSt	Spende
urs_we_tp_stichtag	URS	Tätige Personen
urs_rt_gruppen_kennz	URS	Statuskennzeichen, = 3/6 heißt "auslandskontrolliert"

- › Lorenzkurve -> Verteilung der Verlustvorträge
- › Logistische Regression -> Einflussfaktoren auf Verlustvorträge

1.4 ...

- › TODO: Zufügen von öffentlich verfügbaren Informationen zu Struktur und Verteilung des BTP. Verteilung über Statistik und Jahr, ...
 - › was ist wichtig? Randverteilung, missings, vollständigkeit der variablen
 - › erstmal eine Tabelle mit Variablenanzahl, Entfernung durch Hinweis feld. Tabelle: Variablenzahl komplett, Variablenanzahl ohne Hinweisfeld, Variablenanzahl Befüllt?
 - › Hinweis Befüllungsgrad tlw. gering... x Variablen fehlen zu 90%, 80%, 70%, 60%, 50% ?
 - › Verteilung der Zeilen auf Statistik und Jahr, inkl. Trend
 - › Verteilung auf Kombinationen genauer
- › Anwendungsfälle volles Spektrum
 - › Datenbereitstellung, interne Analysen, Schätzungen
 - › Auswertung durch Wissenschaft im FDZ
- › Technische Herausforderung:
 - › effiziente und verständliche Speicherung
 - › Herausfiltern großer Datenmengen irrelevanter Merkmale

<!--

1.5 Annette's Input

Das Business-Tax-Panel kombiniert die Angaben aus verschiedenen Ertrags- sowie Umsatzsteuerstatistiken im Quer- und Längsschnitt. Verfügbar sind Informationen aus den folgenden Statistiken : Gewerbesteuer, Körperschaftsteuer, Umsatzsteuer-Voranmeldung und -Veranlagung, Statistik über die Personengesellschaften und Gemeinschaften, Einnahmenüberschussrechnung und einige Merkmale aus dem Statistischen Unternehmensregister. Alle verwendeten Steuerarten sind ab dem Berichtsjahr 2013 jährlich verfügbar, dies bildet den Beginn des Beobachtungszeitraums. Aufgrund der Festsetzungsfrist von vier Jahren bei den Veranlagungsstatistiken endet der Beobachtungszeitraum aktuell mit dem Berichtsjahr 2020.

Bei den verwendeten Statistiken handelt es sich um Vollerhebungen, teilweise mit Erfassungsgrenze. Insgesamt liegen 77,8 Mio. Beobachtungen vor, die auf 16,7 Mio. Einheiten zurückzuführen sind. Der Merkmalsumfang variiert je nach Statistik zwischen 120 und 1.300 Merkmalen was insgesamt zu einem Merkmalsumfang von über 2.700 Merkmalen führt. Hierdurch sind Analyse von Anpassungsreaktionen sowie Verteilungsanalysen für verschiedene Beobachtungszeiträume möglich. Insgesamt deckt der Forschungsdatensatz eine Vielzahl an Analysemöglichkeiten, die für die evidenzbasierte steuerpolitische Entscheidungen nötig sind, ab.

Tabelle 2

Übersicht über die Dimensionen des Business-Tax-Panel

Merkmal	Wert
Beobachtungszeitraum	2013-2019 (jährliche Erweiterung)
Anzahl Einheiten (2013-2019)	>66 Millionen
Anzahl Merkmale	>2.700
Erhebungsart	Vollerhebung
Datenquelle	Sekundärerhebung (Finanzverwaltung)

Für die vielfältigen Analysewünsche der Forschenden, den Auswertungsbedarf des Fachbereiches bspw. für Sonderauswertungen und der Erstellung des Metadatenreports des Forschungsdatenzentrums ist der Datensatz konzipiert. Für die Abdeckung aller Anforderungen ist der Datensatz möglichst wenig beschränkt worden und dadurch ressourcenintensive. Der damit einhergehende hohe Bedarf an Speicherkapazität, Arbeitsspeicher und Prozessorleistung stellt sowohl im Fachbereich als auch im Forschungsdatenzentrum eine Herausforderung dar.

==Wodurch ...==

1.6 Überblick zum Business-Tax-Panel

Das Business-Tax-Panel (BTP) ist ein zentraler Forschungsdatensatz des Statistischen Bundesamtes, der umfassende Informationen zur Unternehmensbesteuerung in Deutschland bereitstellt. Das Panel kombiniert Daten aus verschiedenen Steuerstatistiken miteinander und ermöglicht somit eine umfassende Analyse der Besteuerung von Unternehmen über Zeit.

Im BTP werden folgende Datensätze zusammengeführt:

- › **Gewerbesteuerstatistik** (EVAS-Nr. 73511)
- › **Körperschaftsteuerstatistik** (EVAS-Nr. 73211)
- › **Umsatzsteuerstatistik - Voranmeldungen** (EVAS-Nr. 73311)
- › **Statistik über Personengesellschaften und Gemeinschaften** (EVAS-Nr. 73121)
- › **Umsatzsteuerstatistik - Veranlagungen** (EVAS-Nr. 73321)
- › **Einnahmenüberschussrechnung** aus der Lohn- und Einkommensteuerstatistik (EVAS-Nr. 73111)
- › Merkmale aus dem **Statistischen Unternehmensregister** (EVAS-Nr. 52111)

1.7 Datenstruktur und Umfang

Dimensionen des Datensatzes.

Das BTP umfasst einen außergewöhnlich umfangreichen Datensatz mit beeindruckenden Dimensionen:

Hauptmerkmale des Datensatzes.

Aus den verschiedenen Steuervordrucken und darin verwendeten Kennzahlen werden über 2.700 Merkmale erfasst, die verschiedene Aspekte der Unternehmensbesteuerung abbilden:

- › **Steuerliche Kennzahlen:** Bemessungsgrundlagen, Steuerbeträge, Vorsteuern aus verschiedenen Steuerarten
- › **Wirtschaftliche Kennzahlen:** Umsätze, Gewinne, Betriebsausgaben
- › **Strukturmerkmale:** Rechtsform, Wirtschaftszweig, Größenklassen
- › **Geografische Informationen:** Bundesland, Gemeindekennziffer
- › **Panelstruktur:** Längsschnittinformationen ermöglichen Zeitreihenanalysen

Datenerhebung und Rechtsgrundlage.

Die im BTP enthaltenen Steuerstatistiken sind Bundesstatistiken, die als **Vollerhebung** durchgeführt werden. Es handelt sich um **Sekundärerhebungen**: Die Erhebungsmerkmale werden aus den Voranmeldungs- und Veranla-

gungsbescheiden von der Finanzverwaltung entnommen und über deren Rechenzentren an die Statistischen Ämter der Länder übermittelt.

Rechtsgrundlage ist das [Gesetz über Steuerstatistiken \(StStatG\)](#) vom 11. Oktober 1995.

1.8 Technische Requirements

- › Größe in Datentypen
- › Vorbereitung OSS

1.9 Forschungspotenzial und Nutzung

Typische Forschungsfragen.

Das BTP wird für eine Vielzahl von Forschungsfragen genutzt:

1. **Steuerliche Analysen:** Effekte von Steuerreformen auf Unternehmensentscheidungen
2. **Unternehmensdynamik:** Gründungen, Wachstum und Marktaustritte
3. **Wirtschaftsstruktur:** Branchenentwicklung und regionale Unterschiede
4. **Krisenanalysen:** Auswirkungen von wirtschaftlichen Schocks auf Unternehmen

Herausforderungen bei der Datenauswertung.

Die Größe und Komplexität des BTP stellt besondere Anforderungen an die Auswertungsinfrastruktur:

- › **Rechenleistung:** Analysen über den gesamten Datensatz erfordern erhebliche Rechenkapazitäten
- › **Speicherbedarf:** Das Vorhalten des Datensatzes im Arbeitsspeicher ist oft nicht möglich
- › **Komplexe Verknüpfungen:** Die Zusammenführung verschiedener Datenquellen erfordert effiziente Join-Operationen
- › **Datenschutz:** Strenge Anforderungen an den Umgang mit sensiblen Unternehmensdaten

1.10 Zugangsformen im FDZ

Das BTP ist über verschiedene Zugangsformen verfügbar:

- › **Gastwissenschafts Arbeitsplatz (GWAP):** On-Site-Zugang mit vollständigen Daten, auswertbar mit SAS oder Stata. Bedingt durch die Speicherplatzgröße kann die Nutzung einer Stichprobe erforderlich sein.
- › **Kontrollierte Datenfernverarbeitung (KDFV):** Remote-Zugang mit Ergebnisfreigabe über KDFV
- › Die Gemeindekennziffer für Bayern steht am GWAP lediglich pseudonymisiert zur Verfügung

1.11 BTP als Benchmark-Datensatz

Aufgrund seiner Größe (>66 Millionen Einheiten), Komplexität (>2.700 Variablen) und realen Datenstruktur eignet sich das BTP hervorragend als Benchmark für die Evaluation verschiedener Auswertungsmethoden. Die Herausforderungen des BTP sind repräsentativ für viele Forschungsprojekte im FDZ:

- › **Datengröße:** Der Datensatz übersteigt oft die verfügbare RAM-Kapazität
- › **Komplexe Joins:** Verknüpfung verschiedener Steuerstatistiken erforderlich
- › **Aggregationen:** Über verschiedene Dimensionen (Zeit, Region, Wirtschaftszweig)
- › **Filteroperationen:** Selektion relevanter Unternehmensgruppen
- › **Zeitreihenanalysen:** Panel-Struktur über mehrere Jahre

Diese realitätsnahen Szenarien ermöglichen es, die Praxistauglichkeit verschiedener Auswertungsmethoden unter den tatsächlichen Bedingungen eines Forschungsdatenzentrums zu bewerten.