

Einleitung

...

Spannungsfeld, Weiterentwicklung und Technologie-Empfehlung...

Forschungsdatenzentrum des Statistischen Bundesamts, hier kurz FDZ Netzwerk empirischer Steuerforschung, hier kurz NeSt

Handlungsbedarf

Steigende Datenmenge der amtlichen Statistik

StBA

- Qualitätsbericht. Wachsende Datenmenge in der amtl. Statistik, Verweis auf [destatis2023]
- Datenverarbeitung im StBA erklären
- neues NeSt Produkt BTP zeigt Umfang, hoch interessant für Wissenschaft
- Datenverarbeitungsaufgaben des StBA erklären
- Nicht mehr durch vorhandene Systemkapazitäten (insb. Arbeitsspeicher) gedeckt

-> wir müssen RAM sparen! Idealerweise auch Laufzeit.

- Herausforderungen (größere Datenmengen, komplexere Analysen, schnellere Antworten notwendig)
 - hohe Anforderungen der Öffentlichkeit und besonders Wissenschaft. Verweis auf Gutachten des Stat. Beirats und Gründung “Netzwerk emp. Steuerforschung”
 - * Schnelle Bereitstellung von am besten vollständigen, wenig Anonymisierten Datensätzen an Wissenschaft via FDZ. Erste Analysen seitens StBA und hohe Expertise erwartet (Exploration der Daten nötig)
 - * Bereitstellung von Zusatzdokumentation durch StBA. Metadatenreport
 - * schnelle Bereitstellung,
 - * zeitnahe Nutzung in FDZ
 - * keine Wartezeiten in FDZ
 - * sofortig Antworten auf Analysefragen
 - * Erhöhte Komplexität Analysen mit größeren, Komplexeren Datensätzen
 - Rückstände/Altlasten: weiterentwickelnde Infrastruktur, nicht state of the art (ausgelegt auf konsistenz und zuverlässigkeit, nicht schnelligkeit), gesetzlicher Auftrag
 - * hauptsächlich SAS für große Datenmenge verwendet, funktioniert, aber langsam
 - * FDZ Bund integriert in Standardarbeitsplätze des StBA

* Bereitstellungsaufwände und Abhängigkeiten moderner Software

Annette: -> Impuls aus der Wissenschaft, dann Fachbereich - Fachbereich/Verbund im Grunde Hauptnutzende da Tools und Daten zur Verfügung stehen Technische Möglichkeit entwickelt sich weiter usw..

Der Sachverständigenrat zur Begutachtung der gesamtwirtschaftlichen Entwicklung (2023) hat in seinem Gutachten 2023/24 auf eine technisch veraltete Infrastruktur und auf die fehlende Nutzerfreundlichkeit hingewiesen. Seitdem hat sich die Infrastruktur in dem Forschungsdatenzentrum des Bundes verbessert. Seit Januar 2025 besteht ein Remote Access System als neuer Zugangsweg für die Wissenschaft. Im Bereich der Steuerstatistiken wird derzeit geprüft, inwiefern auch Einzeldaten aus diesem Bereich über Remote Access genutzt werden können. Als Übergang und Erleichterung für bestehende Forschungsprojekte wird in diesem Kapitel 2

Die amtliche Statistik steht vor der Herausforderung, bei stetig wachsenden Datenmengen und sich ändernden Nutzeranforderungen qualitativ hochwertige und zeitnahe statistische Informationen bereitzustellen [destatis2023]. Dabei spielt die Effizienz der verwendeten statistischen Verfahren eine zentrale Rolle für die Leistungsfähigkeit des gesamten statistischen Systems.

In den vergangenen Jahren haben sich die Rahmenbedingungen für die Produktion amtlicher Statistiken erheblich verändert. Die Digitalisierung hat nicht nur zu einer Vervielfachung der verfügbaren Datenquellen geführt, sondern auch neue Möglichkeiten für die statistische Analyse eröffnet. Gleichzeitig sind die Erwartungen der Nutzer an Aktualität und Detailliertheit der Statistiken gestiegen.

Diese Entwicklungen erfordern eine kontinuierliche Evaluation und Optimierung der eingesetzten Verfahren. Ziel der vorliegenden Studie ist es daher, die Effizienz verschiedener statistischer Verfahren systematisch zu bewerten und Handlungsempfehlungen für die Praxis abzuleiten.

Steigende Anforderungen der Öffentlichkeit insb. Wissenschaft

FDZ, NeSt

- Schnelle Reaktionen erforderlich
- Komplexere (Forschungsfragen) zu beantworten
- FDZ erklären
- Gutachten BMF ansprechen
- NeSt erklären, Bedarfe durch Produkt BTP beantwortet.. aber wie kann es in angme

The Need for Speed

As we start working with larger and larger datasets, the basic tools of the tidyverse start to look a little slow. In the last few years several packages more suited to large datasets have emerged. Some of these are column, rather than row, oriented. Some use parallel processing.

Some are vector optimized. Speedy databases that have made their way into the R ecosystem are data.table, arrow, polars and duckdb. All of these are available for Python as well. Each of these carries with it its own interface and learning curve. duckdb, for example is a dialect of SQL, an entirely different language so our dplyr code above has to look like this in SQL: S. <https://www.r-bloggers.com/2024/04/the-truth-about-tidy-wrappers-3/>

Vorschreitende Innovation der Datenverarbeitungstechnologien

Ausgangslage

SAS für amtl. Statistik und SAS/Stata für FDZ

- SAS, zsl. Stata in den FDZ. Session zu SAS Ablösung
- Weiterentwicklung der Infrastruktur: neue Server für R im StBA und für FDZ eigene neue Server für R und Stata
- hohe Lizenzkosten, Trend zu Abonnements und Cloud nachteilig, technologiLOCK und Privacy.
- Kommen bei unseren Anwendungen Kapazitätär an ihre Grenzen und Performanz in anderen Technologien höher.

Anforderungen an Modernisierung

- hohe Performanz, schnelle Ergebnisse, idealenfalls in Echtzeit (d.h. wenigen Sekunden)
- moderne Interfaces, möglichst leichte Nutzung, wenig Schulungsbedarf, Allgemeinwissen von Statistiker u.Ä. Fachrichtungen (Werkzeug, nicht Gegenstand der Untersuchung)
- leicht einrichtbar, wenig Abhängigkeiten zu vielen Tools, die sich ständig weiterentwickeln, sodass hohe Wartungsaufwände entstehen.

Vormarsch von Open Source

- in der internationalen amtlichen Statistik seit Jahren auf dem Vormarsch. Langsam steigt auch Verbreitung von R steigt auch in den dt. Statistikämtern.

Fokus auf R

R verbreitung steigt, bei uns in Kinderschuhen. Wie fängt man denn am besten an? Was ist von anfang an der richtige Weg daten in R zu verarbeiten?

R ist weltweit bekannt und verbreitet als die Lingua Franca für Statistik, Methodologie und Data Science. Dies macht R zu der natürlichen Wahl für die amtlichen Statistik mit viele attraktive Vorteile.

- aktive globale Community sorgt für schnelle Innovation und Verbesserung

- CRAN bietet offiziell aktuell Zusatzfunktionalitäten in Form von X R-Paketen. Darunter sind viele klassische Pakete für Datenverarbeitung und -analyse.
- R
 - The reasons why the official statistics community is rapidly embracing R are clear. S. Erfolg / Wachstum der Conference uRos <https://r-project.ro/conference2025.html#Presentations>
 - R lingua franca for statisticians, methodologists and data scientists worldwide -> nativ geeignet für amtliche Statistik
 - R Open Source bietet Vorteile
 - * aktive globale Community
 - * support from the industry
 - * it combines a vast amount of functionalities for data preparation, methodology, visualisation and application building
 - * free = ideal environment for sharing, collaboration and industrialising official statistics
 - * Packages CRAN, github...

Arrow bspw. hatte in 2024 und 2025 jeweils 4 Major Releases mit diversen neuen Funktionalitäten und Performanz-Verbesserung

Neue Entwicklung zu R in der dt. OSS, bei Integration in Statistikproduktion und Datenbereitstellung direkt mit den richtigen Features und Methoden beginnen. Wie die folgenden...

Open Source -> breite Auswahl an Paketen zum Einlesen, Transformieren und Auswerten von Daten.

- Unterscheidung klassischer/r-nativer Methoden (base-r, readr / vroom und data.table), effiziente/moderne Methoden (arrow, duckdb, polars)
- Klassische Methoden
 - base-r zu vermeiden
 - readr
 - * in tidyverse
 - * nutzerfreundlich, einfach zu lernen / nutzen
 - data.table
 - * benchmarking: <https://cran.r-project.org/web/packages/data.table/vignettes/datatable-benchmarking.html>
 - datenformate in R: qs, rds
 - dtplyr?

Hoch-performante R-Pakete

Als Desktopanwendung konzipiert ist R nicht für hoch-performante Auswertungen von Big Data bekannt. Wie unsere Untersuchung zeigen wird, beansprucht R nativ übermäßige Systemressourcen, um die Nutzerfreundlichkeit zu erhöhen. Dadurch dass R Open Source ist ändern dies jedoch diverse Entwicklerteams weltweit und stellen R Zusatzfunktionen in Form von R-Paketen zur Verfügung die in R hoch-performante Auswertung großer Datenmengen ermöglichen.

- R darüber hinaus vermehrt hoch-performante Analysetools, die sich ständig verbessern
- ermöglichen sehr schnelle Verarbeitung von Daten, mit einem sehr hohen Gesamtvolumen, das sogar den verfügbaren RAM übersteigt.
- sollte möglichst leicht nutzbar sein, nativ in R ohne viele Abhängigkeiten (organisatorische Einschränkungen)

Umsetzungsideen/-vorschläge im StBA/FDZ

- möglichst leicht nutzbar und gewohnt/verbreitet -> R+dpplr
 - wechselnde Nutzende (Forscher) unterschiedlicher Fachbereiche mit unterschiedlichen Analytischen und technischen Kenntnissen
- stabil
- schnell, optimale Nutzung vorhandener GWAP Zeit und KDFV Zeitraum
- ressourcensparend (RAM Problematik)
- möglichst leicht nutzbar mit den vorhandenen Systemen und organisatorischen Strukturen ergibt Anforderungen
 - hohe-performanz bereits mit R Grundlagenwissen
 - minimale Anforderungen an zsl. Software
- NeSt Förderung, Datenprodukterstellung, Bereitstellung der FDZ auch technischen Infrastruktur und Knowhow der effizienten Nutzung
- Bereitstellung des OSS seit Nov. 2025
- Vorbereitend Exploration und Beratung in geeigneten Äußerst effizienten Methoden -> Ergebnisse in Echtzeit
- Szenario FDZ GWAP Besuch, statt KDFV, sofort Ergebnisse
- Diese Arbeit

Technische Lösungsansätze.

- Modernisierung der amtl. Stat, FDZs -> Zugangswege, Kapazitäten, ...
- Technische Weiterentwicklung, stärkere Hardware, leichtere Bereitstellung, virtualisierung
- Schnelle Weiterentwicklung von Open-Source Software, R, div. Packages, e.g. Verweis auf Changelog von Arrow, Polars

Fokus der Artikels

Zielgruppe: alle Datenanalytiker mit rudimentären R-Kenntnisse, aber breit, FDZ, amtl. Stat,

Scope, Abgrenzung

- Identifizierte Kernaufgabe: 90% irrelevante Informationen aus großen Datenmengen rausfiltern, Untersuchung wie dies am effizientesten geht.

Leitet in den weiteren Artikel über zu der Kernfrage

enchmark Experiment

-> Empfehlung Systemressourcen für IT-Betrieb -> Software- und Methodenempfehlung für Wissenschaft

Die Untersuchung fokussiert sich auf folgende zentrale Forschungsfragen:

1. **Methodische Effizienz:** Wie unterscheiden sich verschiedene statistische Verfahren hinsichtlich ihrer Rechenzeit und Speicheranforderungen bei gleichbleibender Ergebnisqualität?
 2. **Skalierbarkeit:** Welche Verfahren zeigen die beste Performance bei wachsenden Datenmengen, und wo liegen die kritischen Grenzen?
 3. **Praktische Anwendbarkeit:** Welche Infrastrukturanforderungen stellen moderne Auswertungsmethoden an Forschungsdatenzentren?
- Bei der Integration von R und umfangreichen Auswahl, welche Technologie sollte Datenaufbereitung, -analyse und -auswertung genutzt werden?
 - Wir nutzen eine Kontrollierte Benchmark

Die Arbeit gliedert sich wie folgt: Nach dieser Einleitung wird in **?@sec-btp** der Anwendungsfall Business-Tax-Panel vorgestellt, der als empirisches Beispiel für die Analysen dient. **?@sec-infrastruktur** beschreibt die Infrastruktur des Forschungsdatenzentrums des Bundes (FDZ-Bund), in der die Auswertungen durchgeführt werden.

In **?@sec-methoden** werden verschiedene effiziente Auswertungsmethoden vorgestellt und deren theoretische Grundlagen erläutert. **?@sec-performance** präsentiert die empirischen Performanzergebnisse der verschiedenen Ansätze. Die Arbeit schließt mit einem Ausblick auf zukünftige Entwicklungen in **?@sec-ausblick**.

Die Analyse basiert auf einer umfangreichen empirischen Studie, die verschiedene statistische Verfahren anhand realer Datensätze aus der amtlichen Statistik vergleicht. Dabei werden sowohl etablierte als auch neuere Ansätze berücksichtigt, um ein vollständiges Bild der verfügbaren Optionen zu zeichnen.

<!--

Bei den verwendeten Statistiken handelt es sich um Vollerhebungen, teilweise mit Erfassungsgrenze. Insgesamt liegen 77,8 Mio. Beobachtungen vor, die auf 16,7 Mio. Einheiten zurückzuführen sind. Der Merkmalsumfang variiert je nach Statistik zwischen 120 und 1.300 Merkmalen was insgesamt zu einem Merkmalsumfang von über 2.700 Merkmalen führt. Hierdurch sind Analyse von Anpassungsreaktionen sowie Verteilungsanalysen für verschiedene Beobachtungszeiträume möglich. Insgesamt deckt der Forschungsdatensatz eine Vielzahl an Analysemöglichkeiten, die für die evidenzbasierte steuerpolitische Entscheidungen nötig sind, ab.

Für die vielfältigen Analysewünsche der Forschenden, den Auswertungsbedarf des Fachbereiches bspw. für Sonderauswertungen und der Erstellung des Metadatenreports des Forschungsdatenzentrums ist der Forschungsdatensatz konzipiert. Für die Abdeckung aller Anforderungen ist der Datensatz möglichst wenig beschränkt worden und dadurch ressourcenintensive. Der damit einhergehende hohe Bedarf an Speicherkapazität, Arbeitsspeicher und Prozessorleistung stellt sowohl im Fachbereich als auch im Forschungsdatenzentrum eine Herausforderung dar.

==Wodurch ...==Das Business-Tax-Panel kombiniert die Angaben aus verschiedenen Ertrags- sowie Umsatzsteuerstatistiken im Quer- und Längsschnitt. Verfügbar sind Informationen aus den folgenden Statistiken : Gewerbesteuer, Körperschaftsteuer, Umsatzsteuer-Voranmeldung und -Veranlagung, Statistik über die Personengesellschaften und Gemeinschaften, Einnahmenüberschussrechnung und einige Merkmale aus dem Statistischen Unternehmensregister. Alle verwendeten Steuerarten sind ab dem Berichtsjahr 2013 jährlich verfügbar, dies bildet den Beginn des Beobachtungszeitraums. Aufgrund der Festsetzungsfrist von vier Jahren bei den Veranlagungsstatistiken endet der Beobachtungszeitraum aktuell mit dem Berichtsjahr 2020.

Bei den verwendeten Statistiken handelt es sich um Vollerhebungen, teilweise mit Erfassungsgrenze. Insgesamt liegen 77,8 Mio. Beobachtungen vor, die auf 16,7 Mio. Einheiten zurückzuführen sind. Der Merkmalsumfang variiert je nach Statistik zwischen 120 und 1.300 Merkmalen was insgesamt zu einem Merkmalsumfang von über 2.700 Merkmalen führt. Hierdurch sind Analyse von Anpassungsreaktionen sowie Verteilungsanalysen für verschiedene Beobachtungszeiträume möglich. Insgesamt deckt der Forschungsdatensatz eine Vielzahl an Analysemöglichkeiten, die für die evidenzbasierte steuerpolitische Entscheidungen nötig sind, ab.

Für die vielfältigen Analysewünsche der Forschenden, den Auswertungsbedarf des Fachbereiches bspw. für Sonderauswertungen und der Erstellung des Metadatenreports des Forschungsdatenzentrums ist der Forschungsdatensatz konzipiert. Für die Abdeckung aller Anforderungen ist der Datensatz möglichst wenig beschränkt worden und dadurch ressourcenintensive. Der damit

einhergehende hohe Bedarf an Speicherkapazität, Arbeitsspeicher und Prozessorleistung stellt sowohl im Fachbereich als auch im Forschungsdatenzentrum eine Herausforderung dar.