

1 Vorbereitung

1.1 Pakete laden

1.2 Verbindung zu Daten herstellen

2 Datenübersicht

2.1 Fallzahlen

2.2 Numerische Kennzahlen

3 Auswertung

3.1 Lorenzkurve (Verlustvorträge der Körperschaften)

3.2 Logistische Regression (Einflüsse auf positive Verlustvorträge)

Effizientes Programmieren mit R und technische Weiterentwicklung des FDZ

Code ▼

Anhand des Business Tax Panel (BTP)

Oliver Hauke (C31)

11.11.2025

1 Vorbereitung

1.1 Pakete laden

Hide

```
library(arrow)      # Effizienz, R-nativ
library(duckdb)     # Effizienz, SQL-artig
library(dplyr)      # Datenverarbeitung
library(tidyr)      # Datenverarbeitung
library(ggplot2)    # Plots
library(here)       # Navigation im Dateisystem
library(lobstr)     # Speichermessung

arrow::set_cpu_count(16)
proj_path <- file.path("~/auswertung/btp")
```

1.2 Verbindung zu Daten herstellen

Hide

```
fs::dir_info("~/auswertung/btp/daten/") |>
  mutate(filename = basename(path)) |>
  select(filename, size) |>
  filter(grepl("btp", filename)) |>
  arrange(desc(filename))
```

```
#> # A tibble: 28 × 2
#>   filename      size
#>   <chr>      <fs::bytes>
#> 1 btp_kdfv_2019_v1.parquet 2.76G
#> 2 btp_kdfv_2019_v1.csv    26.38G
#> 3 btp_kdfv_2019_v0.zip    4.55G
#> 4 btp_kdfv_2019_v0.dta   100.44G
#> 5 btp_kdfv_2018_v1.parquet 2.78G
#> 6 btp_kdfv_2018_v1.csv    25.9G
#> 7 btp_kdfv_2018_v0.zip    4.21G
#> 8 btp_kdfv_2018_v0.dta    95.72G
#> 9 btp_kdfv_2017_v1.parquet 2.73G
#> 10 btp_kdfv_2017_v1.csv   24.75G
#> # i 18 more rows
```

Hide

```
system.time({
  pq_files <- list.files("~/auswertung/btp/daten/", pattern= ".parquet", full.names = T
RUE)
  da <- open_dataset(pq_files, partitioning = "Jahr")
})
obj_size(da)
```

```
#>   user system elapsed
#> 0.171 0.074 0.576
#> 263.67 kB
```

Hide

```
system.time({
  da |>
    dim() |>
    print()
})
```

```
#> [1] 66993043    2265
#>   user system elapsed
#> 1.010 0.608 1.667
```

Hide

2 Datenübersicht

```
system.time({
  da |>
    select(3 + 1:20) |>
    head(100) |>
    collect() |>
    str()
})
```

```
#> tibble [100 × 20] (S3: tbl_df/tbl/data.frame)
#> $ verk_qual: int [1:100] 1 1 1 1 1 1 1 1 2 1 ...
#> $ g_ef4 : int [1:100] 3 3 3 3 NA 3 3 3 3 3 ...
#> $ g_fef14 : int [1:100] NA 1 NA NA NA NA NA NA NA ...
#> $ g_fef17 : int [1:100] 3 4 3 3 NA 4 3 3 4 1 ...
#> $ g_fef19 : int [1:100] NA NA NA NA NA NA NA NA NA ...
#> $ g_fef20 : chr [1:100] "F" "K" "K" "K" ...
#> $ g_fef21 : int [1:100] NA NA NA NA NA NA NA NA 3 NA ...
#> $ g_fef25 : logi [1:100] NA NA NA NA NA NA ...
#> $ g_fef26 : int [1:100] NA NA NA NA NA NA NA NA NA ...
#> $ g_fef27 : int [1:100] NA NA NA NA NA NA NA NA NA ...
#> $ g_fef28 : int [1:100] 4 4 4 4 NA 4 4 4 4 4 ...
#> $ g_k2110 : int [1:100] 175017 2579583 59005 165186 NA 1596614 20704 6335 -66530 5
000 ...
#> $ g_k2114 : int [1:100] 0 0 0 0 NA 0 0 0 0 0 ...
#> $ g_k2116 : int [1:100] 0 0 0 0 NA 0 0 0 0 0 ...
#> $ g_k2117 : int [1:100] 0 0 0 0 NA 0 0 0 0 0 ...
#> $ g_k2119 : int [1:100] 0 0 0 0 NA 0 0 0 0 0 ...
#> $ g_k2121 : int [1:100] NA NA NA NA NA NA NA NA NA ...
#> $ g_k2122 : int [1:100] 0 0 0 0 NA 0 0 0 0 0 ...
#> $ g_k2126 : int [1:100] 0 0 0 0 NA 0 0 0 0 0 ...
#> $ g_k2127 : int [1:100] 0 0 0 0 NA 0 0 0 0 0 ...
#> user system elapsed
#> 2.015 0.317 0.726
```

2.1 Fallzahlen

2.1.1 Fallzahlen pro Jahr

Hide

```
system.time({
  fallzahlen_jahr <- da |>
    group_by(Jahr) |>
    count() |>
    ungroup() |>
    collect()
})
fallzahlen_jahr
```

```
#>   user  system elapsed
#> 2.123   0.011   1.130
#> # A tibble: 7 × 2
#>   Jahr      n
#>   <int>   <int>
#> 1  2014 8759322
#> 2  2015 9051437
#> 3  2013 8689793
#> 4  2016 9260593
#> 5  2018 10491366
#> 6  2017 9989806
#> 7  2019 10750726
```

2.1.2 Fallzahlen pro Jahr und Statistik

Vorgehen

Hide

```
system.time({
  da|>
    select(Jahr, verk) |>
    head() |>
    collect()
})
```

```
#>   user  system elapsed
#> 0.754   0.054   0.498
```

Hide

```
system.time({

  fallzahlen_stat <- da|>

    select(Jahr, verk) |>

    mutate(
      e = str_detect(verk, "e"),
      g = str_detect(verk, "g"),
      k = str_detect(verk, "k"),
      p = str_detect(verk, "p"),
      r = str_detect(verk, "r"),
      u = str_detect(verk, "u"),
      v = str_detect(verk, "v")) |>

    group_by(Jahr) |>

    summarize(across(where(is.logical), sum)) |>

    arrange(Jahr) |>


    collect()
})
fallzahlen_stat
```

```
#>   user  system elapsed
#> 27.121   0.000   2.296
#> # A tibble: 7 × 8
#>   Jahr      e      g      k      p      r      u      v
#>   <int>   <int>   <int>   <int>   <int>   <int>   <int>   <int>
#> 1  2013 3703982 3633451 1210838 1205110 3474431 3243538 6435280
#> 2  2014 3720318 3714176 1236129 1220521 3550775 3240221 6446620
#> 3  2015 4230871 3819938 1264717 1234537 3634643 3255537 6535948
#> 4  2016 4581982 3887556 1293431 1247699 3674354 3266429 6550960
#> 5  2017 5685661 3981853 1316520 1220067 3708949 3266806 6664535
#> 6  2018 6310028 4050674 1350837 1284121 3736550 3279136 6831036
#> 7  2019 6501292 4099690 1388679 1294898 3723169 3288306 6972252
```

Hide

```
fallzahlen_stat |>
  pivot_longer(-Jahr, names_to="stat", values_to = "n") |>
  mutate(Jahr = factor(Jahr), Fallzahl = n / 1e6) |>
  ggplot(aes(x = Jahr, y = Fallzahl, fill = stat)) +
  geom_bar(stat="identity") +
  ylab("Fallzahl (in Mio.)") +
  ggtitle("BTP - Fallzahlen nach Jahr und Statistik")
```

BTP - Fallzahlen nach Jahr und Statistik



2.2 Numerische Kennzahlen

Hide

```

system.time({
  overview <- function(da){

    select(da, where(is.numeric)) |>

    summarize(
      across(.fns= ~ sum(!is.na(.x)), .names = "{.col}-obs"),
      across(.fns= ~ sum( is.na(.x)), .names = "{.col}-nna"),
      # ! GEHEIM !
      #across(.fns= ~ min(.x, na.rm = TRUE), .names = "{.col}-min"),
      across(.fns= ~ quantile(.x, 0.1, na.rm = TRUE), .names = "{.col}-q10"),
      across(.fns= ~ mean(.x, na.rm = TRUE), .names = "{.col}-mean"),
      across(.fns= ~ median(.x, na.rm = TRUE), .names = "{.col}-median"),
      across(.fns= ~ quantile(.x, 0.9, na.rm = TRUE), .names = "{.col}-q90"),
      # ! GEHEIM !
      #across(.fns= ~ max(.x, na.rm = TRUE), .names = "{.col}-max"),
      across(.fns= ~ sd(.x, na.rm = TRUE), .names = "{.col}-sd")
    )
  }

  # Uebersicht ausrechnen
  descr <- da |>
    filter(str_detect(verk, "p")) |>          # Personengesellschaften
    select(p_ef35:p_ef37, p_ef58, p_ef59, p_ef61, p_ef62) |>
    overview() |>
    collect()

})

# schoenere Darstellung
descr |>
  mutate(across(everything(), as.numeric)) |>
  pivot_longer(cols = everything(), names_to = "key", values_to = "value") |>
  separate(key, into = c("Variable", "metrik"), sep = "-") |>
  pivot_wider(names_from = metrik, values_from = value) |>
  mutate(across(where(is.numeric), as.integer))

```

```

#>   user  system elapsed
#> 10.042   0.428   1.736
#> # A tibble: 6 × 8
#>   Variable    obs    nna    q10   mean median    q90    sd
#>   <chr>      <int> <int> <int> <int> <int> <int> <int>
#> 1 p_ef35    13860 8693093 -324870 6279143  80120 7996924 73228254
#> 2 p_ef36    655352 8051601  -1717  285271 126772  625043  1391716
#> 3 p_ef37    676633 8030320     0    79330     67  11339 12171125
#> 4 p_ef58   3839496 4867457  -4627   17445   3488   39450   484638
#> 5 p_ef59    37732 8669221 -11350   93753   5498  130806  1342766
#> 6 p_ef62   8686088  20865  -5299  144568   6444  195169  7739366

```

3 Auswertung


3.1 Lorenzkurve (Verlustvorträge der Körperschaften)

[Hide](#)

```
system.time({  
  var_lc <- da |>  
    filter(str_detect(verk, "k"), Jahr == 2019) |> # nur Koerperschaftsteuerstat. in 20  
19  
    pull(k_k65270)                                # Verlustvortraege  
  
  lc <- ineq::Lc(var_lc)  
  
  plot(lc)  
})
```

```
#>   user  system elapsed  
#>  1.874    0.056    1.280
```

Lorenz curve



3.2 Logistische Regression (Einflüsse auf positive Verlustvorträge)

[Hide](#)

```

system.time({
  da_clean <- da |> filter(str_detect(verk, "k") & str_detect(verk, "u")) |>
    select(
      ID, Jahr,
      k_k65270, # Verlustvorträge
      k_k65823, # Gesamtbetrag der Einkünfte
      k_c15018, # Summe der Umsätze/Löhne/Gehälter
      k_ef20,   # WZ Generierung
      k_k65172, # Spende

      urs_we_tp_stichtag, # Tätige Personen
      urs_rt_gruppen_kennz # Statuskennzeichen, = 3/6 heißt "auslandskontrolliert"
    ) |>

  compute() |>

  mutate(

    # Positiver Verlustvortrag vorhanden?
    vl_dummy = ifelse(k_k65270 > 0 & !is.na(k_k65270), 1, 0),

    # International taetig?
    ifats_dummy = ifelse(urs_rt_gruppen_kennz %in% c(3,6), 1, 0),

    # Wirtschaftszweig
    key = as.numeric(substr(k_ef20,1,2)),
    wz = case_when(
      key %in% 1:3 ~ "A",
      key %in% 5:9 ~ "B",
      key %in% 10:33 ~ "C",
      key %in% 35 ~ "D",
      key %in% 36:39 ~ "E",
      key %in% 41:43 ~ "F",
      key %in% 45:47 ~ "G",
      key %in% 49:53 ~ "H",
      key %in% 55:56 ~ "I",
      key %in% 58:63 ~ "J",
      key %in% 64:66 ~ "K",
      key %in% 68 ~ "L",
      key %in% 69:75 ~ "M",
      key %in% 77:82 ~ "N",
      key %in% 84 ~ "O",
      key %in% 85 ~ "P",
      key %in% 86:88 ~ "Q",
      key %in% 90:93 ~ "R",
      key %in% 99 ~ "U",
      .default = NA)

    , .keep="unused"

  ) |> select(-key) |>
  mutate(across(where(is.numeric), as.numeric))

mod <- da_clean |>
  # Shift der erklärenden Variablen um ein Jahr

```



```

left_join(
  mutate(da_clean, Jahr = Jahr + 1),
  by = c("ID", "Jahr"), suffix = c("", "_t1")
) |>
select(
  vl_dummy, Jahr,
  k_k65823_t1, k_c15018_t1, k_k65172_t1,
  ifats_dummy_t1, urs_we_tp_stichtag_t1, wz) %>%

# Modell
{glm("vl_dummy ~ .", data = ., family = binomial)}
})
summary(mod)

```

```

#>   user  system elapsed
#> 25.593 15.265 11.959
#>
#> Call:
#> glm(formula = "vl_dummy ~ .", family = binomial, data = .)
#>
#> Coefficients:
#>
#>             Estimate Std. Error z value Pr(>|z|)
#> (Intercept)    7.077e+01  2.787e+00  25.396 < 2e-16 ***
#> Jahr          -3.549e-02  1.382e-03 -25.681 < 2e-16 ***
#> k_k65823_t1    -9.556e-08  1.812e-09 -52.746 < 2e-16 ***
#> k_c15018_t1     4.283e-11  1.619e-11   2.646 0.008138 **
#> k_k65172_t1     8.668e-07  5.192e-08 16.697 < 2e-16 ***
#> ifats_dummy_t1  2.920e-01  1.252e-02 23.326 < 2e-16 ***
#> urs_we_tp_stichtag_t1 -3.369e-05  6.893e-06 -4.887 1.02e-06 ***
#> wzD            -3.689e-01  2.965e-02 -12.441 < 2e-16 ***
#> wzE            -2.790e-01  2.626e-02 -10.623 < 2e-16 ***
#> wzF            -1.129e-01  7.936e-03 -14.229 < 2e-16 ***
#> wzG             7.684e-03  7.257e-03   1.059 0.289718
#> wzH            -5.308e-02  1.409e-02  -3.768 0.000164 ***
#> wzI             4.306e-01  1.375e-02 31.303 < 2e-16 ***
#> wzJ             2.622e-03  1.070e-02   0.245 0.806468
#> wzK            -2.327e-01  2.012e-02 -11.566 < 2e-16 ***
#> wzL             4.850e-01  1.291e-02 37.575 < 2e-16 ***
#> wzM            -2.028e-01  8.579e-03 -23.639 < 2e-16 ***
#> wzN            -5.393e-02  1.127e-02  -4.785 1.71e-06 ***
#> wzP             3.743e-01  2.737e-02 13.675 < 2e-16 ***
#> wzQ            -7.446e-02  2.848e-02  -2.614 0.008947 **
#> wzR             5.465e-01  1.864e-02 29.316 < 2e-16 ***
#> wzU            -8.841e-01  5.438e-01  -1.626 0.103970
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
#> (Dispersion parameter for binomial family taken to be 1)
#>
#>   Null deviance: 1066800  on 868816  degrees of freedom
#> Residual deviance: 1049118  on 868795  degrees of freedom
#> (3320918 observations deleted due to missingness)
#> AIC: 1049162
#>
#> Number of Fisher Scoring iterations: 8

```